

华中科技大学

研究生（文献阅读与选题）报告

☐文献阅读、☐选题、☐文献阅读与选题、☐论文中期进展

标题：工具调用型大语言模型智能体故障诊断的信息表征与交互设计研究

学 号 M202570493

姓 名 陈思静

专 业 设计学

指 导 教 师 何心

院（系、所） 设计学院

填表注意事项

- 一、本表适用于攻读硕士、博士学位研究生文献阅读报告、选题报告、文献阅读与选题报告、论文中期进展报告。
- 二、以上各报告内容及要求由相关院（系、所）做具体要求。
- 三、以上各报告均须存入研究生个人学籍档案。
- 四、本表填写要求文句通顺、内容明确、字迹工整。
- 五、A4 纸正反打印

目 录

一、文献阅读卡	1
二、文献综述	42
1 工具调用型智能体故障诊断.....	(42)
2 程序调试的信息行为.....	(43)
3 大语言模型开发中的人机协作.....	(45)
4 智能体调试的交互设计.....	(46)
5 智能体运行追踪.....	(50)
6 可解释人工智能.....	(53)
7 通过设计开展研究.....	(55)
8 本章小结.....	(57)
三、选题报告	59
1 选题依据.....	(59)
2 国内外研究综述.....	(61)
3 研究问题与方法.....	(65)
4 研究框架.....	(75)
5 计划进度.....	(77)
参考文献	78

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：01

名称 Results-Actionability Gap: Understanding How Practitioners Evaluate LLM Products in the Wild

作者 Willem van der Maden; Malak Sadek; Ziang Xiao; Aske Mottelson; Q. Vera Liao; Jichen Zhu 译者

出处【美国】Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems, 2026: 1-17 页

文献阅读心得（每篇不少于 150 字）：

研究背景 大语言模型（large language model, LLM）产品的评价对象不是孤立模型，而是包含提示词、检索、界面与业务流程的完整系统。传统基准分数很难直接回答产品团队下一步应改什么，实践者因此在不确定性、资源限制和多方目标之间组织评价工作。

研究问题 研究问题一（RQ1）：生产环境中的大语言模型产品目前采用哪些评价实践？

研究问题二（RQ2）：实践者认为评价大语言模型产品时最主要的困难是什么？

研究方法 作者对 19 名跨行业大语言模型产品实践者开展半结构化访谈，并进行主题分析。研究覆盖评价执行、评价方案设计及组织层面的协调工作，分析对象是面向真实用户的完整产品。

主要发现 研究归纳出 10 类评价活动和 5 类挑战。17 名参与者经历了“结果—可行动性鸿沟”：团队能收集反馈或分数，却难以判断失败来自提示、检索、模型还是其他部件。人工判断与“直觉检查”（vibe check）被视为对大语言模型特性的适应，而不只是方法不成熟。

贡献与意义 论文提出“规范化历程”（formalization journey）和“结果—可行动性鸿沟”（results-actionability gap），把评价后的定位、协商与改进纳入评价研究，并从较成熟团队中总结了可实施的组织与流程策略。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：02

名称 Interactive Debugging and Steering of Multi-Agent AI Systems

作者 Will Epperson; Gagan Bansal; Victor Dibia; Adam Fournery; Jack Gerrits; Erkang Zhu; Saleema Amershi 译者

出处【美国】Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems, 2025: 156:1-156:15 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体（multi-agent）系统会产生数十甚至上百条消息，错误可能在早期计划、角色分工或工具调用中出现，并沿后续协作传播。现有开发工具多支持事后阅读日志，缺少暂停、回退和试改轨迹的交互能力。

研究问题 研究问题一（RQ1）：开发者在构建和调试多智能体工作流时面临哪些核心困难？

研究问题二（RQ2）：消息级浏览、编辑与重置如何支持故障诊断和智能体引导（agent steering）？

研究方法 研究先访谈 5 名智能体开发者，据此设计交互调试工具 AGDebugger；随后开展含 14 名参与者的两阶段用户研究。第一阶段比较 AGDebugger 与基线日志界面的错误识别，第二阶段让参与者编辑历史消息并重新运行。

主要发现 参与者通常花约 10 分钟阅读日志后才开始修改。5/6 的第一阶段参与者偏好 AGDebugger；第二阶段 8 人共做 24 次编辑，其中 14 次是补充具体指令，另有简化指令和修改计划。重置与编辑功能评分最高，但只有 2/8 得到完全正确答案。

贡献与意义 AGDebugger 把历史概览、逐条消息检查、回退、编辑与继续执行放进同一界面，使开发者能够用反事实式试验观察某次干预是否改变后续轨迹。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：03

名称 Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems

作者 Shaokun Zhang; Ming Yin; Jieyu Zhang; Jiale Liu; Zhiguang Han; Jingyang Zhang; Beibin Li; Chi Wang; Huazheng Wang; Yiran Chen; Qingyun Wu 译者

出处【美国】Proceedings of Machine Learning Research, 2025, 267: 76583-76599 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体任务失败时，最后输出错误的智能体不一定是决定结果的源头。有效调试需要同时定位责任智能体和关键步骤，但长轨迹、角色交互和错误传播使人工归因成本很高。

研究问题 研究问题一（RQ1）：能否自动识别导致任务失败的智能体，即回答“谁”造成失败？

研究问题二（RQ2）：能否定位该智能体产生决定性错误的具体步骤，即回答“何时”出错？

研究方法 作者将修正某个“智能体一时间”对后能否把失败变为成功作为决定性错误的反事实定义，并以最早的决定性错误为标注目标。Who&When 数据集包含 127 个多智能体系统、184 个失败归因任务，比较一次性分析（all-at-once）、二分搜索（binary search）和逐步分析（step-by-step）三类方法。

主要发现 最佳方法的智能体级准确率为 53.5%，步骤级准确率仅 14.2%，部分方法低于随机基线；包括先进推理模型在内的方法仍未达到实用水平。自动判断“谁”已有有限信号，而精确判断“何时”更困难。

贡献与意义 论文首次系统形式化多智能体自动故障归因，提供同时含责任智能体、决定性步骤和自然语言原因的细粒度数据集，并把智能体级与步骤级能力分开评价。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：04

名称 Finding AI's Faults with AAR/AI: An Empirical Study

作者 Roli Khanna; Jonathan Dodge; Andrew Anderson; Rupika Dikkala; Jed Irvine; Zeyad Shureih; Kin-Ho Lam; Caleb R. Matthews; Zhengxian Lin; Minsuk Kahng; Alan Fern; Margaret Burnett 译者

出处【美国】ACM Transactions on Interactive Intelligent Systems, 2022, 12(1): 1:1-1:33 页

文献阅读心得（每篇不少于 150 字）：

研究背景 总体成败或平均性能无法告诉领域用户人工智能究竟在哪些情境下不可靠。要决定何时依赖智能体，用户需要把问题定位到具体决策和内部预测，而不只是给出笼统的通过或失败判断。

研究问题 研究问题一（RQ1）：人工智能行动后复盘流程（After-Action Review for AI, AAR/AI）能否帮助具备领域知识的用户定位人工智能故障？

研究问题二（RQ2）：故障类型不同，用户发现故障的效果是否也不同？

研究方法 65 名有即时战略游戏经验但无人工智能或机器学习背景的参与者被随机分到复盘组和对照组，分析强化学习智能体完成《星际争霸 II》拉锯战任务的过程。研究用 10 个经验证的自然故障实例计算问题报告的召回率和精确率。

主要发现 AAR/AI 组召回率为 0.233，对照组为 0.080；精确率分别为 0.179 和 0.116，差异均显著。AAR/AI 参与者在每类故障上表现更好，发现任一特定故障的可能性平均接近对照组的 6 倍。

贡献与意义 论文用可核对的故障真值、召回率和精确率评价人类诊断，而非只测满意度；结构化复盘和标签活动还可能帮助用户从单个实例上升到故障类别。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：05

名称 Debugging Reinvented: Asking and Answering Why and Why Not Questions about Program Behavior

作者 Andrew J. Ko; Brad A. Myers 译者

出处 【美国】Proceedings of the 30th International Conference on Software Engineering, 2008: 301-310 页

文献阅读心得（每篇不少于 150 字）：

研究背景 开发者观察到异常输出后，传统调试器仍要求他们先猜测相关代码，再用断点和单步执行验证。由于初始猜测经常错误，问题表述与工具操作之间的转换会产生大量无关搜索。

研究问题 研究问题一（RQ1）：如何从程序代码和一次执行中自动提取用户可能提出的“为什么”与“为什么没有”（why and why-not）问题？

研究问题二（RQ2）：如何用静态、动态分析回答这些问题，并把答案映射到相关运行事件和代码？

研究方法 论文给出 Java Whyline 的系统设计与算法：记录完整执行历史，从文本和图形输出生成问题，结合动态切片、静态切片、调用图、可达性分析和值来源分析构造因果解释，并讨论性能与覆盖限制。

主要发现 “为什么发生”可沿已执行依赖回溯；“为什么没有发生”必须分析潜在定义、未满足条件与未到达路径，计算和问题空间更复杂。原型证明可以从可见输出进入相关代码，而无需先猜故障位置。

贡献与意义 文章把调试问题作为一等交互对象，并提出面向大型 Java 程序自动生成、筛选和回答“为什么”与“为什么没有”问题的完整技术架构。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：06

名称 Designing the Whyline: A Debugging Interface for Asking Questions about Program Behavior

作者 Andrew J. Ko; Brad A. Myers 译者

出处 【美国】Proceedings of the 2004 ACM Conference on Human Factors in Computing Systems, 2004: 151-158 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试本质上从对运行行为的疑问开始，但断点、单步和打印语句迫使程序员先定位代码。Whyline 尝试让用户直接针对输出提问，再由系统呈现与该问题有关的运行时因果链。

研究问题 研究问题一（RQ1）：用户是否认为基于“为什么”与“为什么没有”提问的 Whyline 有用？

研究问题二（RQ2）：Whyline 能否缩短调试时间并帮助程序员完成更多任务？

研究方法 作者在 Alice 编程环境中实现 Whyline，并对既有无 Whyline 研究和新增有 Whyline 研究中的相同场景进行比较。无工具组 4 人、有工具组 5 人，在 90 分钟内完成 6 项 Pac-Man 编程任务并出声思考。

主要发现 在 6 个可比调试场景中，Whyline 把调试时间平均缩短 7.8 倍；有工具组平均完成 3.20 项任务，无工具组为 2.25 项，提升约 40%。19/24 次提问中工具被认为有用，“为什么没有”问题又明显多于“为什么”问题。

贡献与意义 Whyline 把可见程序输出转成问题菜单，并用时间游标、因果箭头和可逆历史把现象、运行事件与代码连接起来，改变了从代码位置开始的调试顺序。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：07

名称 Finding Causes of Program Output with the Java Whyline

作者 Andrew J. Ko; Brad A. Myers 译者

出处 【美国】Proceedings of the 27th ACM Conference on Human Factors in Computing Systems, 2009: 1569-1578 页

文献阅读心得（每篇不少于 150 字）：

研究背景 大型 Java 程序中，断点调试要求开发者先选对代码位置，而用户通常更容易识别界面中出现或缺失的输出。Java Whyline 把“从结果反查原因”的思路扩展到真实开源项目。

研究问题 研究问题一（RQ1）：Java Whyline 是否比断点调试器更快、更成功地帮助开发者定位真实缺陷？

研究问题二（RQ2）：两种工具如何改变开发者浏览文件、使用问题和接近关键函数的路径？

研究方法 研究采用组间实验，两组各 10 名软件工程硕士生，分别使用 Whyline 或具有相同外观的断点调试器，诊断 ArgoUML 的两个真实缺陷。每项任务限时 30 分钟，并记录成功率、时间、文件访问和导航距离。

主要发现 任务 1 中 Whyline 组 10/10 成功，对照组 3/10，且前者约快 2 倍；任务 2 中分别为 4/10 和 0/10。总体上 Whyline 用户约有 3 倍成功率，并更快接近关键代码；但工具更善于找到故障方法，不一定能解释方法为何错误。

贡献与意义 研究把输出选择、执行录像、依赖可视化、书签与问题导航集成为可实证比较的调试界面，并使用真实大型项目而非人工小程序。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：08

名称 How Programmers Debug, Revisited: An Information Foraging Theory Perspective

作者 Joseph Lawrance; Christopher Bogart; Margaret Burnett; Rachel Bellamy; Kyle Rector; Scott D. Fleming 译者

出处 【美国】IEEE Transactions on Software Engineering, 2013, 39(2): 197-215 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试大型代码库时，程序员不断判断下一条线索是否值得追踪。仅用“提出并验证假设”描述这一过程，很难解释他们在文件、方法和调用关系之间的实际导航，也难为工具设计提供直接建议。

研究问题 研究问题一（RQ1）：专业程序员调试时的语言和导航是否主要体现信息气味追踪，而非显式假设？

研究问题二（RQ2）：信息气味与代码拓扑模型能否预测程序员下一步会访问哪里？

研究方法 作者提出基于信息觅食理论的调试模型，并观察 10 名专业程序员调试真实开源程序，分析出声思考与导航日志；随后构建可执行模型，与不考虑信息气味的替代模型比较预测能力。

主要发现 参与者的言语更多涉及寻找和比较线索，而不是陈述完整假设。错误信息、标识符、文件名和调用关系形成信息气味；纳入气味的模型更准确地预测导航，代码拓扑则决定线索间移动成本。

贡献与意义 论文以信息气味（scent）和代码拓扑（topology）两个可观测、可计算的构念解释调试导航，减少对难以直接测量的心理假设的依赖，并把理论转成可执行预测模型。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：09

名称 Mental Procedures in Real-Life Tasks: A Case Study of Electronic Trouble Shooting

作者 Jens Rasmussen; A. Jensen 译者

出处 【英国】Ergonomics, 1974, 17(3): 293-307 页

文献阅读心得（每篇不少于 150 字）：

研究背景 熟练维修人员面对电子设备故障时，不会穷举所有测量，而是在系统、功能单元和部件组成的层级结构中搜索。真实工作还要求兼顾诊断时间、认知负荷和测量成本。

研究问题 研究问题一（RQ1）：熟练电子维修人员如何把设备表示为层级系统并组织故障搜索？

研究问题二（RQ2）：不同搜索例程在观察数量、知识深度和心理加工复杂度上有什么差异？

研究方法 研究在维修人员的正常工作环境中收集口述协议，对真实电子排故过程进行细致编码，分析症状判断、层级切换、测量选择及反复出现的搜索例程。

主要发现 排故可分解为多种循环搜索例程，分别依赖不同深度的内部机理知识。维修人员偏好快速连续的好/坏判断，即使某些观察在信息论上冗余；若目标是减少时间和心理负担，这种做法仍然合理。

贡献与意义 论文较早把真实排故中的认知过程描述为层级系统上的搜索，并揭示“信息最省”与“时间、心智成本最优”并不相同。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：10

名称 Making Sense of Sensemaking 1: Alternative Perspectives

作者 Gary Klein; Brian Moon; Robert R. Hoffman 译者

出处 【美国】IEEE Intelligent Systems, 2006, 21(4): 70-73 页

文献阅读心得（每篇不少于 150 字）：

研究背景 意义建构（sensemaking）在心理学、组织研究、自然情境决策和人机交互（human-computer interaction, HCI）中有多种含义。复杂任务中的理解不是对信息做一次摘要，而是持续寻找联系、解释意外并为下一步行动建立可用认识。

研究问题 研究问题一（RQ1）：不同研究传统如何界定意义建构，它与理解、情境意识等概念有何关系？

研究问题二（RQ2）：哪种定义能解释人在不确定环境中为了预测和行动而持续组织联系？

研究方法 本文是概念综述与立场论文。作者比较多个学科的定义和代表性案例，讨论意义建构的触发条件、目的与分析尺度，并为后续宏认知模型建立概念边界。

主要发现 作者强调意义建构是一种有动机、持续的努力：理解人、地点和事件之间的联系，以预测其发展并有效行动。它常由惊讶、冲突或知识缺口触发，结果是可行动的解释，而非静态信息表征。

贡献与意义 论文跨学科澄清了意义建构的不同视角，把“联系—预测—行动”作为共同核心，为研究真实复杂工作中的理解活动提供了统一入口。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：11

名称 Making Sense of Sensemaking 2: A Macrocognitive Model

作者 Gary Klein; Brian Moon; Robert R. Hoffman 译者

出处 【美国】IEEE Intelligent Systems, 2006, 21(5): 88-92 页

文献阅读心得（每篇不少于 150 字）：

研究背景 人在不确定任务中会借助已有框架筛选数据，数据又可能迫使框架改变。把意义建构理解成固定步骤，会忽略专家在解释、注意分配、反馈和行动之间的往返。

研究问题 研究问题一（RQ1）：数据与解释框架如何相互依存并推动意义建构？

研究问题二（RQ2）：人何时会扩展、质疑、比较、保留或重构当前框架？

研究方法 作者基于自然情境决策研究提出数据—框架（Data/Frame）宏认知模型，并用因果推理、假设承诺、反馈学习、专家差异和确认偏差等经验研究检验模型含义。

主要发现 框架管理注意并定义、连接和过滤数据；异常与不一致可触发质疑或重构。过早形成框架并非必然有害，适度承诺能产生可检验预期；过程反馈通常比只告知成败的结果反馈更有助于改进。

贡献与意义 论文以双向的数据—框架循环替代线性“先收集数据、后得出解释”，并提出连接、扩展、质疑、比较、重构和寻找框架等可观察活动。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：12

名称 A Data-Frame Theory of Sensemaking

作者 Gary Klein; Jennifer K. Phillips; Erica L. Rall; Deborah A. Peluso 译者

出处 【美国】Expertise Out of Context, Mahwah, NJ: Lawrence Erlbaum Associates, 2007: 113-155 页

文献阅读心得（每篇不少于 150 字）：

研究背景 传统微观认知研究多解释人如何理解单词、句子等简单刺激，难以覆盖真实工作中对模糊、矛盾、动态信息形成可行动理解的过程。数据—框架理论（Data-Frame theory）由此转向自然情境中的宏观意义建构。

研究问题 研究问题一（RQ1）：数据如何被框架选择和解释，框架又如何由少量关键锚点被识别或建构？

研究问题二（RQ2）：当数据与框架不一致时，意义建构有哪些可能形式与转换路径？

研究方法 本章综合自然情境决策、专业知识和问题解决研究，借助真实事件材料提出 9 条理论命题，并系统描述连接数据与框架、扩展、质疑、保留、比较、重构和寻找新框架等活动。

主要发现 数据不是完全中性的输入，而是在框架中被辨认和赋义；框架也由关键线索推断。意义建构通常在二者达到足够一致时停止，并服务于“接下来做什么”的功能性理解。专家与新手主要差在可调用框架的丰富度。

贡献与意义 理论同时说明数据驱动和框架驱动过程，明确列出多种非线性活动及其触发关系，可用于分析解释如何被建立、维护和推翻。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：13

名称 AgentGUI: An Interface for Observing and Steering Long-Running AI Agents

作者 Xuan Zhao; Jiwoong Sohn; Qinyue Zheng; Michael Moor 译者

出处 【瑞士】arXiv preprint arXiv:2607.26300, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 长时运行的智能体可同时执行多个任务，但人类监督仍依赖终端输出和分散日志。用户需要在不中断整体工作的情况下掌握轨迹、产物、成本和偏移，并在必要时实施人工或自动纠偏。

研究问题 研究问题一（RQ1）：统一的轨迹可视化能否提高用户理解长时智能体执行的速度和准确性？

研究问题二（RQ2）：人工与自动的管理者式引导（steering）能否在任务漂移时改善最终完成率？

研究方法 系统整合多会话轨迹、工作区快照、人工输入和自动管理模块。8 名硕博参与者在被试内、顺序平衡实验中比较 AgentGUI 与 Hermes 仪表盘（Hermes Dashboard）；另对多种模型各运行 50 次以测试自动纠偏。

主要发现 参与者用 AgentGUI 回答轨迹问题平均快 38%（90 秒对 145 秒， $p = .023$ ），准确率为 93% 对 80%（ $p = .031$ ），且没有速度—准确率交换；自动管理模块在部分模型上将完成率提高最多 34 个百分点。

贡献与意义 论文把并行会话、轨迹理解、工作区产物、人工指令和自动审计放进同一桌面式界面，并用客观理解速度、准确率和 workload 评价可观测性。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：14

名称 An Exploratory Study of How Developers Seek, Relate, and Collect Relevant Information during Software Maintenance Tasks

作者 Amy J. Ko; Brad A. Myers; Michael J. Coblenz; Htet Htet Aung 译者

出处 【美国】IEEE Transactions on Software Engineering, 2006, 32(12): 971-987, DOI: 10.1109/TSE.2006.116 页

文献阅读心得（每篇不少于 150 字）：

研究背景 软件维护不仅需要读懂局部代码，还要在多文件、多工具和多任务之间寻找、关联并暂存相关信息。现代集成开发环境（integrated development environment, IDE）的导航机制可能既提供线索，也制造误导与重复切换。

研究问题 研究问题一（RQ1）：开发者在维护任务中如何搜索、关联和收集相关代码与运行信息？

研究问题二（RQ2）：集成开发环境的线索、依赖导航和交互状态如何支持或妨碍这些活动？

研究方法 研究从 31 名 Java 开发者中选取经验最高的 10 名，要求其在 70 分钟内完成同一 503 行 Java Paint 程序的 5 个维护任务，并接受定时中断。作者逐帧分析屏幕录像、语音和交互日志。

主要发现 开发者平均 35% 的有效时间用于源文件内外的导航，许多跳转是重复且本可避免的；失败搜索常由误导性信息气味开始。记忆不可靠、纸笔缓慢、集成开发环境的交互状态易被后续任务覆盖，均难稳定保存任务上下文。

贡献与意义 论文提出“搜索—关联—收集”的程序理解模型，将信息觅食与集成开发环境的具体交互结合，并以真实多任务和中断条件揭示导航成本及外部记忆需求。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：15

名称 Debugging: An Analysis of Bug-Location Strategies

作者 Irvin R. Katz; John R. Anderson 译者

出处 【美国】Human-Computer Interaction, 1987-1988, 3(4): 351-399, DOI: 10.1207/S15327051HCI0304_2 页

文献阅读心得（每篇不少于 150 字）：

研究背景 具备语言知识的程序员往往能在看到错误行后修正它，真正困难的是从程序行为中定位哪一行有错。调试策略可能因代码归属、可用线索和搜索顺序而改变。

研究问题 研究问题一（RQ1）：熟悉表处理语言（LISP）的学生在定位程序错误时采用哪些策略，错误更接近知识缺陷还是偶发失误？

研究问题二（RQ2）：调试自己的程序与他人程序是否改变定位策略，策略又如何影响检查与修复？

研究方法 论文报告 4 项表处理语言调试实验，比较错误重复性、自然使用的定位策略、自编与他编程序情境，以及不同策略对被检查代码行和后续判断修复的影响。

主要发现 参与者的错误多为不易重复的 slip，通常一旦定位即可修复；他们会使用多种错误定位策略，且自编与他编程序的策略选择不同。策略主要改变搜索哪些代码行，对选中一行后的正确性判断和修复能力影响较小。

贡献与意义 研究把“找错位置”与“判断并修复错误”分解为不同阶段，并通过连续实验说明调试瓶颈并非总是缺少编程知识，而是搜索与定位。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：16

名称 Theory of Troubleshooting: The Developer's Cognitive Experience of Overcoming Confusion

作者 Arty Starr; Margaret-Anne Storey 译者

出处 【美国】ACM Transactions on Software Engineering and Methodology, 2026, DOI: 10.1145/3800945; arXiv:2602.10540 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试研究常聚焦工具和步骤，却较少解释开发者面对意外行为时的内部体验。长时间困惑会持续占用注意、工作记忆和心理模型构建资源，并可能转化为疲劳与项目可持续性风险。

研究问题 研究问题一（RQ1）：开发者在排查意外系统行为时，思考、感受和努力随时间如何变化？

研究问题二（RQ2）：困惑、经验直觉、试探性实验、进展与认知疲劳之间存在怎样的关系？

研究方法 作者访谈 27 名职业开发者，合计 570 年经验，并开展 7 次回访；采用建构主义扎根理论，从 681 条扎根编码形成 8 个核心理论类别，在前 12 份访谈后达到理论饱和，并以参与者反馈检验共鸣。

主要发现 排故从困惑体验启动，经验直觉引导策略，开发者通过“试一试、看结果”缩小解释空间；获得正或负知识都可被体验为进展。持续无进展会耗竭注意并引发补偿努力、盲视和疲劳，最终在“想通了”时解除。

贡献与意义 论文把排故定义为识别、理解并建立意外行为原因心理模型的认知过程，用连贯理论连接情绪、注意、实验、直觉和疲劳，而不只描述技术操作。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：17

名称 The Sensemaking Process and Leverage Points for Analyst Technology as Identified Through Cognitive Task Analysis

作者 Peter Pirolli; Stuart K. Card 译者

出处 【美国】 Proceedings of the 2005 International Conference on Intelligence Analysis, 2005 页

文献阅读心得（每篇不少于 150 字）：

研究背景 情报分析需要从大量异质材料形成结构、假设和可交付结论，但规范性流程很少说明专家真实工作中如何往返搜索、筛选、重组和验证证据。

研究问题 研究问题一（RQ1）：专家分析者如何在信息觅食与意义建构之间循环，将信息转化为模式、洞见和产品？

研究问题二（RQ2）：认知任务分析揭示了哪些可由交互技术降低成本的关键杠杆点？

研究方法 作者采用认知任务分析、分析者访谈和出声思考协议，结合专家图式与信息觅食理论，构建从外部数据源到证据文件、图式、假设和最终报告的双环模型。

主要发现 分析并非线性阅读，而是在探索、富集、利用与表示重构之间机会主义往返；常见外部结构包括资料箱（shoebox）、证据文件（evidence file）和图式（schema）。高成本环节集中在搜索、筛选、重新表示、比较假设和组装证据。

贡献与意义 论文将信息觅食循环（foraging loop）与意义建构循环（sensemaking loop）连接起来，并从每个转换的时间和注意成本推导工具设计杠杆，为总览—筛选—证据—假设界面提供理论基础。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：18

名称 AgentStepper: Interactive Debugging of Software Development Agents

作者 Robert Hutter; Michael Pradel 译者

出处 【德国】arXiv preprint arXiv:2602.06593, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 软件开发智能体会在模型请求、工具调用和代码修改之间形成长轨迹。原始日志虽然保留了大量信息，却缺少适合开发者理解高层行为的结构，也不能像传统调试器那样暂停、单步和检查中间状态。

研究问题 研究问题一（RQ1）：将传统调试中的断点、单步执行和状态检查提升到智能体动作层，能否帮助开发者理解智能体轨迹？

研究问题二（RQ2）：AgentStepper 接入现有软件开发智能体需要多少改动，它是否改善轨迹理解、智能体程序缺陷识别和主观负荷？

研究方法 作者把 AgentStepper 接入 ExecutionAgent、SWE-Agent 和 RepairAgent，统计集成改动量；随后邀请 12 名参与者完成一项轨迹理解任务和两项智能体调试任务，比较 AgentStepper 与自行选择的常规日志工具。

主要发现 三种智能体各需插入 5—7 个应用程序编程接口（application programming interface, API）调用并修改 39—42 行代码。AgentStepper 条件下轨迹理解平均表现由 64% 升至 67%，智能体程序缺陷识别成功率由 17% 升至 60%，挫败感由 5.4/7 降至 2.4/7。

贡献与意义 论文把智能体轨迹表示为“模型—智能体程序”和“智能体程序—工具”两条交织会话，并整合总览、细节、代码变更和断点控制。它是本研究原型最直接的人侧调试先例，也说明“理解轨迹”和“定位运行框架实现缺陷”应分开测量。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：19

名称 AgentSight: System-Level Observability for AI Agents Using eBPF

作者 Yusheng Zheng; Yanpeng Hu; Tong Yu; Andi Quinn 译者

出处 【美国】arXiv preprint arXiv:2508.02736, 2025 页

文献阅读心得（每篇不少于 150 字）：

研究背景 智能体的高层意图存在于模型提示和响应中，实际效果却表现为进程、文件和网络事件。现有工具通常只能看到其中一侧，导致开发者无法判断某个系统行为是否由智能体意图、工具实现或外部环境造成。

研究问题 研究问题一（RQ1）：能否在不修改智能体框架代码的情况下关联模型层语义意图与系统层实际行为？

研究问题二（RQ2）：这种跨层观测能否以可接受的开销识别安全攻击、低效循环和多智能体协调问题？

研究方法 作者提出边界追踪（boundary tracing），利用扩展伯克利包过滤器（extended Berkeley Packet Filter, eBPF）监视内核事件，同时截获传输层安全协议（Transport Layer Security, TLS）加密的模型流量以提取语义意图，再通过实时关联引擎和辅助大语言模型跨进程连接两类事件，并在多种攻击和故障场景中评估。

主要发现 AgentSight 能够检测提示注入、识别浪费资源的推理循环并发现隐藏的多智能体协调瓶颈，运行开销低于 3%。研究也表明，系统级事实和语义解释来自不同观测通道。

贡献与意义 论文具体展示了跨层证据如何被关联，并揭示“直接记录的系统事件”和“经过模型分析得到的语义关系”不能混为同一种证据。它为本研究原型的记录、推导和未知三类证据状态提供了技术边界。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：20

名称 From Failed Trajectories to Reliable LLM Agents: Diagnosing and Repairing Harness Flaws

作者 Mengzhuo Chen; Junjie Wang; Zhe Liu; Yawen Wang; Haiming Zheng; Qing Wang 译者

出处 【中国】arXiv preprint arXiv:2606.06324v2, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 智能体失败往往由执行环境、工具、上下文、生命周期、可观测、验证或治理机制共同塑造。仅依据最终成败调整提示词，难以确定失败证据位于哪一步，也难以把运行现象映射到具体运行框架工件。

研究问题 研究问题一（RQ1）：如何把碎片化运行轨迹编译成能够表达步骤级数据流、控制流和运行框架实现锚点的统一表示？

研究问题二（RQ2）：基于该表示形成的局部诊断和范围化修复，能否在不引入不可接受回归的情况下改善智能体表现？

研究方法 HarnessFix 将原始轨迹与运行框架工件编译为面向运行框架的轨迹中间表示（Harness-aware Trace Intermediate Representation, HTIR），定位责任步骤和实现工件，把重复诊断合并为缺陷记录，再按缺陷类型生成补丁并做回归约束验证；实验覆盖四个公开基准。

主要发现 相较初始运行框架，HarnessFix 在四个基准上的性能提高 6.3 至 18.4 个百分点，并优于人工设计和自演化基线。结果显示，失败轨迹可被组织成指向具体运行框架机制的结构化证据。

贡献与意义 论文证明数据流、控制流和实现锚点可以同时进入面向运行框架的轨迹表示，是与本研究原型最接近的技术工作。其自动修复不是本研究的目标，但 HTIR 所物化的关联类型构成了人侧理解界面的关键比较对象。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：21

名称 Agentic Harness Engineering: Observability-Driven Automatic Evolution of Coding-Agent Harnesses

作者 Jiahang Lin; Shichun Liu; Chengjun Pan; Lizhi Lin; Shihan Dou; Zhiheng Xi; Xuanjing Huang; Hang Yan; Zhenhua Han; Tao Gui; Yu-Gang Jiang 译者

出处 【中国】arXiv preprint arXiv:2604.25850v4, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 智能体运行框架包含工具、中间件、长期记忆、系统提示和运行规则，修改空间异构，轨迹规模巨大，而且一次修改与下一轮结果之间的关系难以归因。自动演化若缺少可观测证据，容易退化为试错。

研究问题 研究问题一（RQ1）：组件、运行经验和修改决策需要怎样的可观测表示，才能形成可验证的运行框架演化闭环？

研究问题二（RQ2）：可观测性驱动自动演化能否提高编码智能体性能，并跨模型迁移而非只适配单一基准？

研究方法 作者提出组件可观测、经验可观测和决策可观测三支柱，在 Terminal-Bench 2 上执行 10 轮运行框架演化，并通过消融和跨模型、跨基准迁移检验各类组件修改的作用。

主要发现 Terminal-Bench 2 的单次通过率（pass@1）由 69.7% 升至 77.0%；冻结后的运行框架在其他模型家族上带来 5.1—10.1 个百分点提升，并以比种子运行框架少 12% 的词元（token）取得 SWE-bench Verified 上的领先结果。增益主要来自工具、中间件和长期记忆，而非系统提示。

贡献与意义 论文把可观测性从日志采集提升为组件、经验和决策三个层次，并要求每次修改都有可证伪预测。它说明本研究不能只研究提示词，而应将上下文和工具等机制放入统一运行框架结构。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：22

名称 AgentLens: Visual Analysis for Agent Behaviors in LLM-Based Autonomous Systems

作者 Jiaying Lu; Bo Pan; Jieyi Chen; Yingchaojie Feng; Jingyuan Hu; Yuchen Peng; Wei Chen 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2025, 31(8): 4182-4197, DOI: 10.1109/TVCG.2024.3394053 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体自治系统产生大量随时间演化的事件、记忆和交互。线性日志难以呈现跨时间行为模式，也难以让用户从总体演化下钻到单个智能体行为及其可能原因。

研究问题 研究问题一（RQ1）：如何把原始执行事件组织成支持多粒度查看的智能体行为模型，并追踪行为之间的潜在因果关系？

研究问题二（RQ2）：层级时间视图、单智能体细节视图和环境监视视图能否支持用户发现并解释复杂行为？

研究方法 作者建立事件处理、行为摘要和原因追踪流程，开发包含概览（Outline）、智能体（Agent）和监视（Monitor）三类联动视图的 AgentLens，并通过两个使用场景和用户研究评价系统。

主要发现 参与者能够沿层级时间线发现行为模式、下钻检查事件，并回看可能影响当前行为的历史操作。系统有效性和可用性得到验证，但部分因果关系依据文本相似度推断，并非直接观测事实。

贡献与意义 论文提供总览—细节联动和原因追踪的成熟视觉设计，也暴露了本研究原型要解决的风险：界面若不说明连线来自日志、算法推断还是缺失信号，使用者可能把潜在关系理解为实际因果。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：23

名称 AgentGraph: Trace-to-Graph Platform for Interactive Analysis and Robustness Testing in Agentic AI Systems

作者 Zekun Wu; Seonglae Cho; Cristian Enrique Munoz Villalobos; Theo King; Umar Mohammed; Emre Kazim; Maria Perez-Ortiz; Sahan Bulathwela; Adriano Koshiyama
译者

出处 【美国】Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41721-41723, DOI: 10.1609/aaai.v40i48.42393 页

文献阅读心得（每篇不少于 150 字）：

研究背景 现有智能体可观测平台多记录提示输入输出和运行指标，却仍要求用户手工从线性轨迹恢复任务、工具、数据和人员之间的结构关系。

研究问题 研究问题一（RQ1）：如何把智能体执行日志转换为带类型节点和边的交互知识图，并保持每个图元素可回到原始轨迹？

研究问题二（RQ2）：统一图表示能否同时支持故障分析、优化建议和扰动条件下的稳健性测试？

研究方法 AgentGraph 把智能体、任务、工具、数据输入输出和人建模为节点，用消费、委托、顺序、工具使用、输出交付和人工干预等类型边连接，并让每个元素指向精确轨迹片段（trace span）；系统还加入扰动和因果归因分析。

主要发现 原型能够在同一图中开展基于轨迹的定性故障分析和定量稳健性测试。论文属于演示轨道，主要证明系统能力，尚未提供充分的人类理解效果证据。

贡献与意义 论文将关系图与精确原始证据链接，是本研究原型“关联必须可核验”的直接先例；同时也说明系统功能展示不能替代对理解正确率、误判率和无证据结论的受控评估。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：24

名称 Graph of Trace: Visualizing Execution Traces of Scientific Agents

作者 Tianci Gao; Haoxuan Li; Jian He Li; Tianxiang Zhao; Shi Runze; Weiran Wang; Zezhao Wu; Lu Mi 译者

出处【美国】Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics: System Demonstrations, 2026:297-306, DOI: 10.18653/v1/2026.acl-demo.29 页

文献阅读心得（每篇不少于 150 字）：

研究背景 科学智能体可以自动执行环境配置、代码运行、数据分析和结论生成，但展开后的工作流难以供领域专家检查，限制了结果复核和后续人机协作。

研究问题 研究问题一（RQ1）：如何实时记录细粒度执行事件并把科学智能体工作流组织成可检查的有向图？

研究问题二（RQ2）：结构化轨迹图是否改善领域专家对工作流、失败位置和结果生成过程的理解？

研究方法 系统记录工具调用、代码执行和中间产物，由监视模块构建实时更新的有向图，并提供对话、图和节点细节检查器；作者在复杂科研任务上邀请人工智能、神经科学和生物学专家评价。

主要发现 专家认为结构化轨迹提高了工作流理解、感知可解释性和进一步分析交互的可用性。评价以专家反馈为主，尚未通过同证据基线比较理解准确率和无依据判断。

贡献与意义 论文提供与本研究原型相近的实时轨迹图和总览一节点细节结构，同时构成重要方法学对照：本研究需要把主观可用性扩展为具有客观真值（ground truth）的理解和证据判断实验。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：25

名称 AUTOGEN STUDIO: A No-Code Developer Tool for Building and Debugging Multi-Agent Systems

作者 Victor Dibia; Jingya Chen; Gagan Bansal; Suff Syed; Adam Fourney; Erkang Zhu; Chi Wang; Saleema Amershi 译者

出处 【美国】Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 2024: 72 - 79, DOI: 10.18653/v1/2024.emnlp-demo.8 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体 workflow 涉及模型、工具、角色和编排参数，直接通过代码配置和日志排查门槛较高。开发者需要同时查看系统声明结构和具体运行结果。

研究问题 研究问题一（RQ1）：声明式规范和无代码界面如何降低多智能体 workflow 构建、调试和评价的复杂度？

研究问题二（RQ2）：哪些界面原则能够让模型、工具、智能体和编排关系被复用并在运行中检查？

研究方法 作者基于 AutoGen 开发网页（Web）界面和 Python 应用程序编程接口，以 JavaScript 对象表示法（JavaScript Object Notation, JSON）声明智能体及 workflow，提供拖放式结构编辑、交互运行与调试、结果评估和可复用组件库，并通过系统案例说明设计。

主要发现 AutoGen Studio 把 workflow 结构、组件配置和运行查看统一到一个开发环境中，支持快速原型和非代码式调试。论文主要是系统演示，没有隔离不同呈现方式对理解正确率的影响。

贡献与意义 论文证明“声明结构”和“运行轨迹”可以在同一开发工具中组织，并提供可复用的智能体系统表达方式；本研究进一步关心静态声明与本次运行事实之间的证据差异。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：26

名称 AgentTrace: A Structured Logging Framework for Agent System Observability

作者 Adam AlSayyad; Kelvin Yuxiang Huang; Richik Pal 译者

出处 【美国】arXiv preprint arXiv:2602.10133, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 传统日志偏向操作事件，难以同时表达智能体的模型交互、环境动作和上下文状态。静态审计也难以应对由模型推断产生的非确定行为。

研究问题 研究问题一（RQ1）：智能体运行时日志应覆盖哪些观测面，才能支持调试、安全审计和责任追踪？

研究问题二（RQ2）：结构化日志能否在较少侵入智能体代码的情况下接入现有遥测基础设施？

研究方法 作者提出操作（operational）、认知（cognitive）和上下文（contextual）三类日志面，设计图式化（schema-based）运行时记录机制，并展示其与开放遥测框架（OpenTelemetry）等基础设施的集成方式。

主要发现 框架能够持续记录工具和环境动作、模型相关状态以及上下文信息，为实时监控和事后检查提供共同结构。论文以框架设计为主，尚未验证开发者如何理解这些日志。

贡献与意义 论文把上下文状态明确列为与操作和认知并列的观测面，直接支持本研究聚焦上下文构建与变换；同时提醒研究区分“记录结构完整”与“人能正确理解”两类贡献。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：27

名称 From Agent Traces to Trust: Evidence Tracing and Execution Provenance in LLM Agents

作者 Yiqi Wang; Jiaqi Zhang; Taotao Cai; Zirui Liu; Qingqiang Sun; Zequn Sun; Zhangkai Wu; Mingkai Zhang; Yanming Zhu 译者

出处 【中国】arXiv preprint arXiv:2606.04990, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 最终答案正确与否不能说明证据如何进入结论、工具调用是否合理、记忆怎样影响后续决策，也不能定位执行失败。相关工作分散在检索归因、工具安全、记忆、可观测和调试领域。

研究问题 研究问题一（RQ1）：大语言模型智能体中的证据单元、执行单元和溯源关系可以怎样统一分类？

研究问题二（RQ2）：现有方法在表示、粒度、时间、评价和信任功能上有哪些覆盖与缺口？

研究方法 作者开展系统性综述，从轨迹（trace）来源、证据与执行单元、溯源（provenance）关系、追踪粒度与时机、表示形式和信任功能建立统一分类，并映射数据集、基准和评价指标。

主要发现 现有研究能够追踪检索、工具、记忆和动作的部分来源，但缺少统一的轨迹图式（trace schema）、语义级溯源、真实执行基准和面向恢复的过程评价，隐私与审计基础设施也不成熟。

贡献与意义 论文直接把证据追踪与执行溯源连接起来，为本研究定义“关联证据”提供最新综述框架，也支持把评价从最终答案扩展到过程可核验性和证据边界。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：28

名称 LADYBUG: an LLM Agent DeBUGger for Data-Driven Applications

作者 Joel Rorseth; Parke Godfrey; Lukasz Golab; Divesh Srivastava; Jarek Szlichta

译者

出处【荷兰】Proceedings of the 28th International Conference on Extending Database Technology, 2025: 1082-1085, DOI: 10.48786/EDBT.2025.94 页

文献阅读心得（每篇不少于 150 字）：

研究背景 数据驱动智能体常以多步工作流生成代码、转换数据并汇总结果。某一步的隐蔽错误可能不触发异常，却污染后续结果，用户需要检查中间输入输出并限定重新执行范围。

研究问题 研究问题一（RQ1）：交互式时间线能否支持用户检查智能体每一步的输入、输出和代码，并在任意步骤介入？

研究问题二（RQ2）：大语言模型辅助调试器如何在用户难以发现隐蔽错误时提出候选错误步骤和干预？

研究方法 作者实现 LADYBUG 演示系统，把智能体执行表示为按时间排列的步骤，允许用户查看中间状态、修改任意步骤并只重算受影响部分，同时加入基于自我反思的大语言模型辅助调试器。

主要发现 系统能在示例数据应用中定位并修正未直接报错的中间错误，并通过依赖关系减少重算范围。论文是演示短文，没有人类对照实验，也不能把大语言模型提出的原因视为已证实事实。

贡献与意义 论文展示了步骤、依赖和局部重算如何共同支持智能体调试。对本研究而言，其更重要的意义是区分可直接检查的步骤事实、系统计算的依赖关系和大语言模型提出的候选解释。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：29

名称 Open Agent Specification: Enabling Cross-Framework Comparison of AI Agents

作者 Soufiane Amini; Yassine Benajiba; Cesare Bernardis; Paul Cayet; et al. 译者

出处 【美国】Proceedings of the ACM Conference on AI and Agentic Systems, 2026: 404-418, DOI: 10.1145/3786335.3813130 页

文献阅读心得（每篇不少于 150 字）：

研究背景 不同智能体框架具有不同的提示处理、工具适配、编排和执行语义。即使智能体设计看似相同，运行时也可能产生不同路径和结果，导致跨框架比较缺少共同参照。

研究问题 研究问题一（RQ1）：如何用统一声明表示固定的智能体结构、数据流和控制流，并在不同运行时中生成可比执行？

研究问题二（RQ2）：相同智能体规范在不同框架中是否仍会出现准确率、时延和执行行为差异？

研究方法 作者提出框架无关的智能体规范（Agent Specification）及标准化评估运行框架，在 LangGraph、CrewAI、AutoGen 和 WayFlow 四种运行时上执行 SimpleQA Verified、 τ^2 -Bench 和 BIRD-SQL 三个基准，并记录统一结构的运行轨迹（trace）。

主要发现 在共享规范下，不同运行时仍表现出显著的准确率、时延和执行差异，说明框架适配器、提示和编排实现会塑造运行行为，不能由静态规范直接推断。

贡献与意义 论文为结构与运行的对照提供了统一表示和跨框架证据，直接支撑本研究区分“预设结构”与“本次实际执行”；它也为构造相同任务、不同运行框架机制的实验材料提供方法。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：30

名称 X-Trace: A Pervasive Network Tracing Framework

作者 Rodrigo Fonseca; George Porter; Randy H. Katz; Scott Shenker; Ion Stoica 译者

出处 【美国】Proceedings of the 4th USENIX Symposium on Networked Systems Design and Implementation, 2007: 271-284 页

文献阅读心得（每篇不少于 150 字）：

研究背景 复杂网络服务跨越应用、协议和管理域，单层日志不能重建一次用户任务经过的完整路径。即使各组件都产生日志，也缺少将分散事件关联到同一任务的机制。

研究问题 研究问题一（RQ1）：如何在跨层、跨应用执行中传播统一任务标识并重建因果任务树？

研究问题二（RQ2）：该机制在 DNS、Web 和覆盖网络等异构系统中能否提供可用于诊断的端到端视图？

研究方法 X-Trace 在初始任务中注入元数据，并沿协议调用、转发和递归请求传播；各组件记录带共同任务标识的事件，系统据此重建任务树，并在 DNS、三层网站和覆盖网络场景中部署。

主要发现 跨组件任务树能把原本分散的日志连接起来并定位错误数据或异常路径；即使只在部分层部署，仍可提供局部诊断价值，但未被记录的分支不能被当作未发生。

贡献与意义 论文奠定了端到端执行溯源的任务树思想，说明可靠关联依赖显式传播的记录机制。它为本研究界定“直接记录”提供技术基础，也说明信号缺失应标为未知。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：31

名称 Pivot Tracing: Dynamic Causal Monitoring for Distributed Systems

作者 Jonathan Mace; Ryan Roelke; Rodrigo Fonseca 译者

出处 【美国】Proceedings of the 25th ACM Symposium on Operating Systems Principles, 2015: 378-393, DOI: 10.1145/2815400.2815415 页

文献阅读心得（每篇不少于 150 字）：

研究背景 分布式系统中的日志和指标通常预先定义且以单组件为中心，发生未知问题时，开发者难以在运行中提出新的跨组件问题，也难以关联不同位置的事件。

研究问题 研究问题一（RQ1）：能否动态定义监测查询，并在跨机器和跨组件事件之间保留因果关系？

研究问题二（RQ2）：动态因果监测能否以低开销定位软件缺陷、错误配置和性能退化等不同根因？

研究方法 作者结合动态插桩与先发生关系连接（happened-before join），使用户可在系统某处定义指标，却按其他组件中的因果先行事件选择、过滤和分组；原型在包含 HDFS、HBase、MapReduce 和 YARN 的 Hadoop 集群中评估。

主要发现 Pivot Tracing 能够跨层查询并定位软件错误、配置问题和慢硬件等多类根因，同时保持较低运行开销。它表明关系可以由明确的因果传播规则计算，而不一定逐条直接记录。

贡献与意义 论文为本研究的“按规则推导”提供清晰先例：关系有可检查规则和输入证据，但仍不同于原生日志事实。界面应把推导方法、覆盖范围和无法关联的事件一起呈现。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：32

名称 Dapper, a Large-Scale Distributed Systems Tracing Infrastructure

作者 Benjamin H. Sigelman; Luiz André Barroso; Mike Burrows; Pat Stephenson; Manoj Plakal; Donald Beaver; Saul Jaspan; Chandan Shanbhag 译者

出处 【美国】Google Technical Report dapper-2010-1, 2010 页

文献阅读心得（每篇不少于 150 字）：

研究背景 大规模互联网服务由不同团队、语言和机器上的组件组成。开发者需要理解一次请求跨组件的路径和耗时，但全面插桩会带来开发负担、运行开销与海量数据。

研究问题 研究问题一（RQ1）：如何在低开销、应用透明和大规模持续部署之间取得平衡，记录端到端请求轨迹？

研究问题二（RQ2）：采样式分布追踪是否能支持开发和运维团队理解系统行为并构建多种诊断工具？

研究方法 Dapper 在少量公共库中插桩，以追踪标识（trace）和跨度标识（span）记录请求层级及时间信息，通过采样控制开销；论文总结系统在 Google 内部两年多的构建、部署、使用和衍生工具经验。

主要发现 公共库插桩和采样使追踪能够在超大规模生产环境持续运行，并支持性能分析、依赖发现和异常诊断。但采样和未插桩区域意味着轨迹天然不完整。

贡献与意义 论文建立了现代分布式追踪的追踪/跨度标识基础，并揭示观测证据的覆盖边界。对本研究而言，界面必须避免把被采样或未插桩造成的空白解释成机制没有运行。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：33

名称 A Controlled Experiment for Program Comprehension through Trace Visualization

作者 Bas Cornelissen; Andy Zaidman; Arie van Deursen 译者

出处 【美国】IEEE Transactions on Software Engineering, 2011, 37(3): 341-355,
DOI: 10.1109/TSE.2010.47 页

文献阅读心得（每篇不少于 150 字）：

研究背景 执行轨迹可视化常被用于程序理解，但早期工具多依赖案例演示，缺少把可视化与常规开发环境直接比较的量化证据。

研究问题 研究问题一（RQ1）：大型执行轨迹可视化是否能提高典型程序理解任务的正确率？

研究问题二（RQ2）：在提供相同目标系统的情况下，可视化是否能减少完成理解任务所需的时间？

研究方法 作者设计 8 项面向代表性软件系统的程序理解任务，以 Eclipse 作为对照条件，以 Eclipse 加 Extravis 执行轨迹可视化作为实验条件，比较完成时间和答案正确性。

主要发现 使用轨迹可视化的实验组完成任务所需时间降低 22%，正确性提高 43%，两项差异均达到统计显著。研究证明结构化轨迹的价值可以用客观理解任务而非满意度评价。

贡献与意义 论文为本研究的三条件受控实验提供直接方法学依据：应保持任务和证据可比，测量理解正确率与时间，并把“可视化好看”与“实际理解更准确”区分开。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：34

名称 Debugging Strategies and Tactics in a Multi-Representation Software Environment

作者 Pablo Romero; Benedict du Boulay; Richard Cox; Rudi Lutz; Sallyann Bryant
译者

出处【英国】International Journal of Human-Computer Studies, 2007, 65(12): 992-1009, DOI: 10.1016/j.ijhcs.2007.07.005 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试环境同时提供代码、图形和运行输出时，用户不仅要理解每种表示，还要在表示之间切换和建立对应关系。表示越多并不自动带来更好表现。

研究问题 研究问题一（RQ1）：程序员如何把高层调试策略与低层界面操作结合，并在多种表示之间组织搜索？

研究问题二（RQ2）：编程经验、图形表示知识和呈现形式如何影响调试准确率及策略适应？

研究方法 研究观察不同经验水平的程序员在多表示软件环境中完成调试任务，结合任务表现和交互过程分析他们查看代码、图形和输出的时间、切换方式及策略变化。

主要发现 成功者更系统地把代码与输出对应起来，并能随呈现条件调整策略；经验较少者更频繁地在表示间切换，形成重复且低效的浏览模式。掌握外部表示规则与编程经验同样重要。

贡献与意义 论文说明本研究的结构图、轨迹和上下文视图必须有明确对应关系，不能只增加表示数量。评价还应观察跨视图跳转、回退和关系核验，而不只记录最终答案。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：35

名称 Are Automated Debugging Techniques Actually Helping Programmers?

作者 Chris Parnin; Alessandro Orso 译者

出处 【加拿大】Proceedings of the 20th International Symposium on Software Testing and Analysis, 2011: 199-209, DOI: 10.1145/2001420.2001445 页

文献阅读心得（每篇不少于 150 字）：

研究背景 自动故障定位常以错误语句排名为目标，并假设程序员只要看到正确位置就能理解和修复问题。然而真实调试还包含依赖导航、状态检查、重跑和根因理解。

研究问题 研究问题一（RQ1）：现有自动调试研究关于程序员如何使用故障排名的假设是否符合实际调试行为？

研究问题二（RQ2）：调试技术应如何评价，才能反映其是否真正帮助开发者理解根因并完成修复？

研究方法 作者分析自动调试和故障定位方法的常见假设，并通过面向开发者的调试任务考察排名信息如何被检查、解释和用于后续导航，进而反思只以错误位置排名评价工具的做法。

主要发现 程序员不会机械地逐项检查排名，也不能仅凭孤立语句理解根因；即使正确语句排名靠前，用户仍需控制流、数据流、状态和上下文证据才能判断。

贡献与意义 论文确立了“自动定位准确”不等于“人能够理解并行动”的方法学原则。本研究因此应直接测量人的事件—机制映射和证据定位，而不能用自动算法指标替代人侧实验。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：36

名称 Characterizing Provenance in Visualization and Data Analysis: An Organizational Framework of Provenance Types and Purposes

作者 Eric D. Ragan; Alex Endert; Jibonananda Sanyal; Jian Chen 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 31-40, DOI: 10.1109/TVCG.2015.2467551 页

文献阅读心得（每篇不少于 150 字）：

研究背景 可视分析中的溯源信息（provenance）既可指数据来源、系统操作历史，也可指分析者的推理和洞见。概念混用会导致系统记录了大量历史，却不能回答这些记录服务什么任务。

研究问题 研究问题一（RQ1）：可视化与数据分析中的溯源信息可按哪些信息类型和使用目的组织？

研究问题二（RQ2）：不同溯源信息类型应如何影响捕获方式、界面设计和评价方法选择？

研究方法 作者综合多个领域的溯源系统和研究，对记录对象、语义层次、捕获方式及使用目的进行交叉整理，提出组织框架，并讨论类型、目的和评估之间的关系。

主要发现 溯源信息不仅是操作日志，还包括数据、可视状态、分析步骤、推理和洞见等不同层次；回溯、复现、协作、审计和理解等目的需要不同信息，不能由单一历史记录满足。

贡献与意义 论文为本研究区分运行事实、界面推导和人的解释提供概念工具，也说明证据状态必须与具体关系和使用目的绑定，而不能只给整条轨迹一个统一可信度。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：37

名称 Analytic Provenance for Sensemaking: A Research Agenda

作者 Kai Xu; Simon Attfield; T. J. Jankun-Kelly; Ashley Wheat; Phong H. Nguyen; Nallini Selvaraj 译者

出处 【美国】IEEE Computer Graphics and Applications, 2015, 35(3): 56-64, DOI: 10.1109/MCG.2015.50 页

文献阅读心得（每篇不少于 150 字）：

研究背景 意义建构包含信息搜索、假设生成、证据比较和框架修正。若系统只保存点击而不保存分析步骤及其关系，就难以支持反思、恢复中断或追踪不确定性。

研究问题 研究问题一（RQ1）：分析过程中的数据、操作、子任务、假设和推理应以怎样的层级被捕获和呈现？

研究问题二（RQ2）：分析溯源（analytic provenance）如何支持意义建构、协作以及不确定性和信任管理？

研究方法 论文汇总电气电子工程师学会可视化会议（IEEE VIS）相关研讨会和既有研究，围绕溯源信息的捕获、可视化和利用提出研究议程，并用分层模型讨论从低层交互到高层任务语义的推断。

主要发现 低层事件容易自动记录，高层任务和意图难以可靠推断；溯源信息可支持过程反思、探索引导和质量追踪，但推断、隐私、规模化与不确定性传播仍是开放问题。

贡献与意义 论文直接连接溯源信息与数据—框架意义建构，支持本研究把“证据从哪里来、怎样进入结论”作为界面主结构，并要求对自动推断的高层语义显示不确定性。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：38

名称 Capturing and Supporting the Analysis Process

作者 Nazanin Kadivar; Victor Chen; Dustin Dunsmuir; Eric Lee; Cheryl Qian; John Dill; Christopher Shaw; Robert Woodbury 译者

出处 【美国】Proceedings of the IEEE Symposium on Visual Analytics Science and Technology, 2009: 131-138, DOI: 10.1109/VAST.2009.5333020 页

文献阅读心得（每篇不少于 150 字）：

研究背景 分析者会反复调整参数、返回旧状态并探索替代路径，但多数可视分析工具只保存当前结果，不能让人查看、恢复或理解分析过程本身。

研究问题 研究问题一（RQ1）：如何捕获并可视化分析者的交互历史、分支和结果依赖？

研究问题二（RQ2）：可编辑、可回放的分析历史能否支持过程理解、替代路径探索和分析模式复用？

研究方法 作者开发 CzSaw，把用户交互翻译为脚本，生成可编辑的历史视图和结果依赖图，并通过文档集合分析场景展示状态恢复、分支探索和分析流程复用。

主要发现 历史视图使用户能够查看分析进展和替代路径，依赖图则揭示每一步与后续结果之间的逻辑关系；脚本化记录还支持修改和重新执行分析步骤。

贡献与意义 论文提供了“时间历史 + 依赖关系”双重表示的经典先例，与本研究的轨迹和机制并列结构高度对应；它也提示两类视图应联动而非各自展示重复信息。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：39

名称 The Role of Uncertainty, Awareness, and Trust in Visual Analytics

作者 Dominik Sacha; Hansi Senaratne; Bum Chul Kwon; Geoffrey Ellis; Daniel A. Keim 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 240-249, DOI: 10.1109/TVCG.2015.2467591 页

文献阅读心得（每篇不少于 150 字）：

研究背景 可视分析系统从数据、模型到界面和人的解释都会引入或继承不确定性。若使用者看不到不确定性如何传播，就可能对结果形成过强或过弱的信任。

研究问题 研究问题一（RQ1）：不确定性如何在可视分析的数据处理、模型、可视化和人类推理之间传播？

研究问题二（RQ2）：不确定性意识如何影响证据搜索、验证循环和信任形成？

研究方法 作者整合可视分析、认知和信任研究，提出包含知识生成、探索、验证、不确定性传播与信任构建的概念模型，并通过分析场景说明各环节关系。

主要发现 不确定性会在系统组件中继承和累积，使用者的意识决定其是否继续寻找证据、质疑结果或采取行动；信任应建立在可检查证据和验证循环上，而非结果外观。

贡献与意义 论文为本研究的证据状态提供理论支撑：界面不仅要显示关系，还要让使用者意识到关系的证据强度与未知范围，从而减少由完整结构图诱发的过度确定。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：40

名称 Why Authors Don't Visualize Uncertainty

作者 Jessica Hullman 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2020, 26(1): 130-139, DOI: 10.1109/TVCG.2019.2934287 页

文献阅读心得（每篇不少于 150 字）：

研究背景 尽管不确定性表达方法很多，公开可视化仍经常给出确定性的单一叙事。问题不仅是缺少图形技术，还包括作者对受众、说服力和信息复杂度的假设。

研究问题 研究问题一（RQ1）：经常制作可视化的作者为何承认不确定性重要，却仍选择不直接呈现？

研究问题二（RQ2）：哪些工作实践、态度和传播目标维持了不确定性省略的规范？

研究方法 研究调查 90 名经常为他人制作可视化的作者，并访谈 13 名有影响力的可视化设计者；作者据此归纳实践障碍和信念矛盾，提出不确定性省略的修辞模型。

主要发现 作者普遍认可不确定性的价值，但担心它削弱清晰信息、增加受众负担或破坏叙事。现实中不确定性因此经常被省略，完整而确定的图形外观会掩盖推断自由度和证据边界。

贡献与意义 论文解释了为什么“证据状态应显示”并不会自然转化为界面实践。本研究需要验证三类状态怎样呈现才既不造成认知负担，也不让结构图以确定外观掩盖未知。

二、文献综述

1 工具调用型智能体故障诊断

1.1 智能体执行机制

大语言模型（large language model, LLM）能够根据自然语言目标生成操作方案，并调用外部工具执行任务。Yao 等^[1]提出的推理与行动协同方法（ReAct）将语言推理和环境操作组织为交替过程，为大语言模型智能体（large language model agent）提供了一种基本实现方式。Cemri 等^[2]对多智能体失败的分析以及 Chen 等^[3]对智能体框架缺陷的研究均表明，失败分析涉及模型输出、工具交互、状态传递和流程控制。

1.2 故障诊断任务

Epperson 等^[4]的开发者研究记录了长轨迹检查、干预位置选择和运行调整中的困难；Wu 等^[5]则将任务、工具、数据和人工干预组织为可追溯的图结构，以支持失败分析。基于这些研究，本课题将故障诊断界定为开发者从失败症状出发，查找相关运行事件、形成原因判断并通过后续检查加以核验的过程。信息表征指运行事件及其属性、关系和来源在界面中的组织与呈现；交互设计指开发者进入、查找、比较和核验这些材料的操作方式。

1.3 以人为中心的人工智能

国内人机交互研究为这一问题提供了学科背景。范俊君等^[6]讨论了智能时代交互模型、界面与设计原则的发展，强调人的能力与机器能力在交互中的结合；许为、葛列众^[7]将人机合作、决策控制和以人为中心的人工智能纳入工程心理学

研究框架。这些工作提出了研究方向。具体到智能体排错，仍需通过开发者的实际诊断行为，说明界面应支持什么活动，以及设计效果如何被观察和评价。

2 程序调试的信息行为

2.1 信息觅食理论

程序调试研究较早就把搜索位置与理解原因作为两个相互联系的活动。Katz 和 Anderson^[8]通过四项程序调试实验分析学习者的缺陷定位策略，发现搜索策略会影响检查路径，而定位到某一位置之后，仍然需要判断局部行为是否正确。该研究的对象是程序学习者，其价值在于把“查到哪里”和“如何判断”分开考察。对于智能体运行记录，快速到达一次异常调用只是诊断过程的一部分，开发者还需解释该调用与任务失败之间的联系。

Ko 等^[9]观察十名开发者完成软件维护任务，将其活动概括为查找、关联和收集相关信息。开发者需要在代码位置、依赖关系和临时收集的材料之间往返，信息线索不足及导航成本会妨碍理解。该研究将材料访问和信息保持确定为程序理解中的具体问题。本研究据此考察开发者怎样在提示、参数、工具返回和状态记录之间查找并关联材料。

Lawrance 等^[10]以信息觅食（information foraging）视角分析专业程序员的调试行为，研究信息线索、预期价值和获取成本如何影响下一步搜索。其解释重点在于开发者为何沿某条路径继续查找，以及什么时候离开当前材料。界面中的标签、摘要和跳转关系由此构成可观察的搜索线索，其作用需要结合实际访问路径和诊断结果评价。

这些研究共同建立了一组可观察的行为：进入材料、选择线索、建立关联、保留发现和判断原因。由于单独的访问次数和停留时间不能说明诊断是否有效，本研究将操作记录、参与者当时的问题和最终判断结合分析。

2.2 程序理解

Starr 和 Storey^[11]通过对二十七名专业开发者的访谈，运用建构主义扎根理论（constructivist grounded theory）研究排错中的认知经历。他们将理解异常行为的过程与困惑、心理模型构建以及认知疲劳联系起来。基于该研究，本研究记录参与者的编程经验、智能体开发经验和案例熟悉程度，并为正式任务提供统一的系统背景，以控制前置理解差异。

Romero 等^[12]研究多表征软件环境中的调试策略，发现表征使用与编程经验、表征知识及具体任务有关。本研究据此将表征理解、跨视图操作和参与者经验纳入原型走查与正式评价。

2.3 意义建构理论

意义建构（sensemaking）关注人如何把分散信息组织为能够理解情境和指导行动的解释。Pirolli 和 Card^[13]基于认知任务分析与口语报告，描述情报分析中的信息搜集和解释形成活动，并讨论技术介入的位置。其研究提供了从材料选择到解释形成的过程视角，但具体活动结构需要结合智能体诊断资料确定。

Klein 等^[14]提出的宏观认知模型强调资料与解释框架之间的相互作用：已有理解影响人注意哪些信息，新信息又可能促使人保留、补充或调整理解。该模型可用于分析原因假设如何随诊断材料发生变化，分析对象包括假设提出、材料选择、解释修订和后续检查。

Dritsa 和 Houben^[15]通过设计研究者使用健康相关数据可视化的经验研究，提出关注不确定性的意义建构模型，讨论数据、表征和使用背景如何影响洞见形成。该研究展示了依据实践资料修订过程模型的方法，也说明理论框架需要通过具体活动资料检验。

本研究将信息觅食理论用于分析材料入口、搜索线索和访问成本，将意义建构理论用于分析原因假设的形成与修订。两种理论在形成性研究中的适用范围

依据实际资料确定。

2.4 自动故障定位

自动故障定位（automated fault localization）根据程序运行信息生成可疑位置或排序。Parnin 和 Orso^[16]通过用户研究考察自动故障定位技术对程序员的实际帮助，指出提供可疑代码排序之后，开发者仍需要上下文才能理解和修复问题。该研究把算法提供的线索与人完成的诊断工作联系起来，也表明评价自动定位工具时，需要观察使用者能否把提示转化为可执行的检查。

自动生成的原因解释属于诊断输入，其实际作用取决于开发者能否理解和核验建议依据。本研究将“取得线索—解释异常—检验判断”作为初始分析框架，并通过形成性研究检验这些活动在智能体任务中的具体表现。

3 大语言模型开发中的人机协作

3.1 生成式人工智能评价

Barke 等^[17]观察二十名程序员使用代码生成工具，并通过扎根分析描述加速既定实现和探索可能方案两种交互方式。当开发者已有明确意图时，生成结果可以加快实现；当其探索陌生任务时，需要通过阅读、试用和修改来建立理解。该研究提示，人使用生成系统的目标和知识状态会改变其信息需要。

Zamfirescu-Pereira 等^[18]研究非人工智能专家设计提示的过程，发现参与者会基于有限输出进行机会式修改，并将日常人际交流经验带入对模型的判断。该研究的参与者主要是非人工智能专家，其结论尚不能直接说明专业开发者的诊断行为。

van der Maden 等^[19]访谈十九名大语言模型产品实践者，分析评价工作如何连接产品改进。研究发现，识别质量问题、解释问题来源和决定修改措施之间存在可行性缺口。本课题据此关注失败被识别之后的原因判断和检查决策。

以上研究分别涉及代码生成、提示设计和产品评价，共同指向一种持续存在的工作：使用者需要判断生成结果的含义及其对下一步行动的影响。智能体增加了多步骤执行和外部工具反馈，因此需要进一步研究，开发者究竟依据哪些事件建立解释，如何排除相似原因，以及何时决定补充观测。

3.2 编程智能体协作

Kumar 等^[20]研究十九名开发者与编程智能体协作处理三十三个真实仓库问题的过程。参与者处理自己曾贡献过的仓库任务，研究观察到增量交互、主动干预和持续评价在协作中的作用。其材料保留了任务意图、仓库约束和既有知识，能够揭示行为模式及关联，具体交互方式的因果效果仍需控制条件下的比较。本研究参照其取样思路，先从真实事件中识别诊断困难，再使用可复现系统构建正式任务。

3.3 自动化透明度

自动化透明度（automation transparency）关注系统过程和状态信息如何向使用者呈现。Pareek 等^[21]结合文献分析与实验室研究，让十二名参与者使用五种多智能体界面完成信息查找和逻辑推理任务，并分别收集透明性、帮助程度和可靠性判断。该研究说明主观评价包含多个维度，本研究据此将主观感受与诊断表现、证据使用和判断信心分别测量。

4 智能体调试的交互设计

4.1 执行轨迹可视化

Cornelissen 等^[22]通过受控实验研究执行轨迹可视化对程序理解的影响，在其任务设置下观察到正确性和完成时间方面的改善。该实验把可视化效果与具

体程序理解任务相联系，为诊断界面采用任务表现和完成时间指标提供了依据。

Ko 和 Myers^[23]开发面向原因问答的调试界面（Whyline），让开发者从可见程序输出提出“为什么发生”与“为什么没有发生”的问题，再进入相关执行事件。该研究通过用户任务检验了问题入口与执行事件连接的作用。本研究将从失败症状进入相关运行记录的操作作为候选设计方向，其必要性由形成性研究确定。

上述研究处理的执行记录具有明确的程序语义。工具调用型智能体的运行材料同时包含调用结构、数据传递和自动分析结果。本研究将在案例材料中标记关系来源，并在原型评价中检查参与者对关系语义的理解。

4.2 结构化复盘

Khanna 等^[24]通过人工智能复盘工具（AAR/AI）的实证研究，考察结构化反思如何帮助使用者发现人工智能系统的缺陷。研究将相同解释材料置于不同组织条件下，以“发生了什么、为什么、需要改变什么”等问题支持复盘，并测量故障回忆和描述。结果为信息组织方式影响缺陷理解提供了证据。其研究对象和任务具有特定背景，应用于大语言模型智能体时，需要检验结构化问题是否符合开发者的诊断活动。

Arawjo 等^[25]提出提示与输出比较工具（ChainForge），通过可视化流程支持提示、模型和输入的组合试验。其评价包括二十一个人的实验室研究，以及六次涉及八名使用者的访谈，揭示了工具在输出探索、假设检验和评价迭代中的使用方式。该工作说明，将多个输出放在可比较的结构中，可以支持对模型行为的考察。

上述研究分别检验了结构化复盘和输出比较。本研究不预设比较对象，将依据形成性研究中出现的诊断任务确定比较内容，并通过任务表现、操作记录和使用成本评价其作用。

4.3 分层可视化

Lu 等^[26]提出智能体行为可视分析系统（AgentLens），通过层级结构和多粒度时间信息支持对自主智能体行为的探索。论文报告了使用案例和十四名参与者的用户研究，体现了从概览进入局部行为的设计价值。该系统主要处理行为分析问题，研究材料能够说明使用者如何理解复杂运行过程；其结果还需要结合具体故障答案，才能支持关于诊断正确性的结论。

Gao 等^[27]提出科学智能体执行轨迹可视化工具（Graph of Trace），将运行过程组织为可交互的事件图，并请相关领域专家评价系统。专家反馈提供了可理解性和使用价值方面的证据。科学任务中，领域知识会影响对中间结果的解释，工具对专业使用者的帮助需要结合其任务背景理解。

这些工作展示了概览、分层和关系连接的实现方式，但其评价主要集中于可理解性和使用价值。时间顺序、调用包含、数据依赖和原因假设具有不同语义，本研究将关系识别和局部材料访问纳入原型评价。

4.4 交互式调试

Dibia 等^[28]提出多智能体开发工具（AutoGen Studio），整合组件配置、执行过程查看和调试功能。该系统论文展示了开发流程与工具能力，为案例组织和基础界面提供了参考。其部署经验有助于识别常见操作需求，具体设计对人的诊断效果仍需相应用户任务数据。

Epperson 等^[4]通过五名开发者的形成性访谈提出交互调试工具（AGDebugger），随后分别开展诊断和运行引导研究。诊断研究涉及六名参与者，运行引导研究涉及八名参与者。参与者对编辑、重置和局部重执行等功能表现出偏好，但研究也记录了判断修改位置和修改方式的困难。本研究将在形成性研究中考察重执行是否属于核心诊断活动；若纳入原型，则记录干预内容、受控条件和结果变化。

Rorseth 等^[29]提出面向数据应用的智能体调试器（LADYBUG），展示逐步追踪、局部干预及受影响环节重新执行的实现。Hutter 和 Pradel^[30]提出软件开发智能体调试器（AgentStepper），提供暂停、检查和编辑等功能，并报告小规模学生参与者研究。前者属于系统演示，后者提供了小规模任务评价，尚未形成专业开发者在多类故障上的比较证据。

4.5 诊断工具评价

表 2.1 诊断工具研究比较

研究	主要研究对象与方 法	已提供的证据	对本课题仍需检验 的内容
Whyline ^[23]	程序输出原因查询 与用户任务评价	问题入口与执行 事件连接的价值	自然语言记录及不 完整观测中的关系 理解
AAR/AI ^[24]	结构化复盘的对照 研究	相同解释材料的 组织方式影响缺 陷描述	结构化复盘在专业 智能体排错中的作 用
ChainForge ^[25]	实验室研究与实际 使用访谈	输出比较、假设 检验和评价迭代 的使用方式	跨步骤故障解释与 下一步检查
AgentLens ^[26]	使用案例与用户研 究	层级轨迹支持复 杂行为探索	诊断正确性、原因 判断及证据使用

表 2.1 诊断工具研究比较（续）

研究	主要研究对象与方 法	已提供的证据	对本课题仍需检验 的内容
AGDebugger ^[4]	开发者访谈、诊断 与运行引导研究	编辑和重执行的 需求及使用困难	哪种信息支持使用 者选择干预位置
AgentStepper ^[30]	小规模任务研究	单步检查与编辑 的初步可用性证 据	经验差异及多类案 例上的效果
Graph of Trace ^[27]	科学智能体案例与 专家评价	事件图的可理解 性与使用价值	主观理解和客观诊 断表现之间的关系

现有工具研究采用了问题入口、结构化复盘、输出比较、层级轨迹和局部重执行等设计方式。其评价对象、任务和样本差异较大，尚不足以比较这些方式对专业开发者故障诊断的作用。本研究将依据形成性研究选择核心设计主张，并通过可比较任务检验其效果。

5 智能体运行追踪

5.1 分布式追踪

分布式追踪（distributed tracing）研究为跨组件运行信息的关联提供了技术基础。Fonseca 等^[31]提出跨层任务追踪框架（X-Trace），通过传播任务信息重建请求经过的组件与操作。Sigelman 等^[32]总结大规模追踪基础设施（Dapper）的部署经验，讨论追踪开销、采样及跨服务关联。Mace 等^[33]提出动态因果监测系统

(Pivot Tracing)，通过动态插桩和查询支持跨组件分析。这些工作说明，统一标识与关系记录能够将分散事件组织为可查询的执行过程。

分布式追踪研究表明，事件关联取决于统一标识、上下文传播和数据采集范围。本研究将先依据诊断任务确定所需材料，再核查案例中的记录能力；无法由原始记录支持的关系将标明其推断来源。

Zheng 等^[34]提出系统级智能体观测工具 (AgentSight)，关联模型交互与底层系统活动，并在异常行为和性能分析场景中展示其作用。该研究补充了应用层对话记录之外的信息来源。采集层级的扩展能够帮助解释某些运行问题，同时也会增加材料种类；开发者怎样选择和组合这些信息，仍然是交互研究需要回答的问题。

5.2 自动故障归因

Cemri 等^[2]分析多智能体系统的失败运行并建立分类，涉及系统设计、智能体间协调以及任务验证等问题。该分类有助于理解智能体失败并不限于单次模型输出，也可作为案例采样的参考。多智能体协作中的协调和责任分配包含额外变量，因此借鉴其故障类型时，应逐项判断是否适用于单个工具调用型智能体。

Zhang 等^[35]围绕“哪个智能体在何时导致失败”构建自动失败归因任务，并比较不同归因方法。研究表明，在已有轨迹中定位责任主体和责任步骤仍具有挑战。这类评测回答机器方法能否接近标注答案；对于人使用诊断工具的研究，还需检查参与者是否理解建议依据、是否能够识别错误建议，以及是否会把局部责任步骤视为完整原因。

Chen 等^[3]研究智能体运行框架缺陷的诊断和修复，将失败轨迹与数据流、控制流及实现位置联系起来。研究提供了从运行表现追查框架问题的技术路径，其评价重点是自动诊断和修复。轨迹与实现的关联可以成为界面候选功能，但其必要性需要根据开发者的具体任务判断：有些问题可以在工具输入输出层面解释，有些则需要继续进入配置或实现细节。

上述研究为故障案例构建提供分类和实现依据，也表明自动建议需要保留来源、模型、输入和生成版本。本研究将自动归因结果与原始运行事实分别记录，用于分析使用者怎样接受、质疑或放弃建议。

5.3 运行关系可视化

Wu 等^[5]提出轨迹转图分析平台（AgentGraph），将智能体、任务、工具、输入输出和人工干预组织为具有类型的节点与关系，并将图元素链接到原始轨迹片段。系统还展示了失败分析和扰动测试。该工作说明，图结构可以同时承载运行对象、关联信息和原始出处。

AgentGraph 的图元素同时包含调用关系、数据关系和分析结果。由于这些关系的证据来源不同，本研究将来源标识、关系说明和原始材料访问作为图结构方案的评价内容。

5.4 来源追溯

来源追溯（provenance）研究关注数据与分析结果从何而来。Ragan 等^[36]提出可视化和数据分析中的来源类型与用途框架，区分数据、操作、交互、洞见和理由等记录。该区分提示，智能体执行历史与开发者的分析历史承担不同作用：前者描述系统发生的事件，后者描述使用者如何形成判断。研究过程需要同时保留两者，才能将界面操作与诊断解释联系起来。

Kadivar 等^[37]提出可编辑和可回放分析历史的可视分析系统（CzSaw），支持使用者回顾、调整和复用分析过程。Xu 等^[38]进一步讨论分析来源如何服务于理解、审计和协作，并提出将操作记录与推理活动连接的研究议程。这些工作为记录已检查材料、保留暂定假设和比较分析分支提供了设计资源。

来源追溯研究区分系统执行记录和使用者的分析记录。本研究据此在操作记录之外采集参与者的阶段性判断和理由，用于分析运行材料如何进入诊断结论。

6 可解释人工智能

6.1 解释需求

可解释人工智能（explainable artificial intelligence, XAI）研究将解释放在人使用系统的情境中考察。Liao 等^[39]访谈二十名相关设计实践者，并借助问题提示讨论解释需求，形成面向用户问题的设计资源。研究显示，使用者需要的解释与其角色、任务及所处环节有关。本研究据此区分故障理解、修改位置选择和补充观测等解释用途。

Ehsan 等^[40]以情境化设计材料访谈二十九名人工智能使用者与实践者，研究社会透明性（social transparency），将其他人的使用情境、行动和结果纳入解释。该研究表明，解释需求包含技术输出之外的工作背景。本研究将在真实事件访谈中记录配置变更、既往检查和协作信息，再依据跨案例分析决定是否纳入设计。

基于上述研究，形成性访谈将围绕具体诊断事件询问参与者试图确认的问题、使用的材料和采取行动的依据，避免仅收集脱离任务情境的功能偏好。

6.2 解释使用偏差

Kaur 等^[41]结合十一名数据科学家的情境研究与一百九十七人的调查，考察解释工具在机器学习分析中的实际使用。研究观察到使用者对解释结果的误解和过度依赖。该发现表明，解释功能的使用和理解需要分别评价。

Buçinca 等^[42]在一百九十九名参与者的人工智能辅助决策实验中比较多种交互条件，发现促使使用者独立思考的认知强制措施（cognitive forcing functions）可以减少对错误建议的过度依赖，但也伴随接受度和使用成本方面的变化。该研究据此分别报告界面偏好、操作时间和判断正确性。

Sieker 等^[43]在视觉问答任务中操纵系统可见的图像信息，考察解释是否帮助使用者理解系统能力与局限。研究中，提供解释提高了使用者对系统能力的评价，却未帮助其更准确地识别系统限制。使用者是否感觉“理解了”，需要与其

能否识别系统限制及错误结果一起评价。

三项研究共同表明，主观理解、判断正确性、使用时间和对系统建议的依赖需要分别测量。本研究据此将诊断表现、证据使用、判断信心和使用体验设为不同评价指标。

6.3 不确定性可视化

Hullman^[44]调查九十名可视化作者并访谈十三名设计者，研究实际传播中为何常省略不确定性。其结果揭示了信息简洁性、沟通目标、受众预期和表达成本之间的张力。研究对象是可视化作者，本研究将通过开发者任务另行考察不确定性信息对后续检查的作用。

Guo 等^[45]通过用户实验比较图边不确定性与其他边属性的配对视觉编码，发现编码效果受到视觉变量组合和任务类型影响。本研究因此在具体诊断任务中评价不确定性编码，检查使用者能否区分数据缺失、关系不确定和推断强度。

Sacha 等^[46]从可视分析过程讨论不确定性、意识与信任的关系，为分析不确定性在处理和理解环节中的传播提供概念框架。Ehsan 等^[47]通过四十三名参与者的情境化协同设计，研究如何在解释中显露系统接缝、限制和工作条件。前者提供分析视角，后者提供设计探索的经验材料，共同支持把系统限制作为可供判断的信息。

结合来源追溯和不确定性研究，本研究在案例构建中区分三类信息状态：运行事实已经记录但存在多种解释、关键事实缺失、自动建议尚未核验。该分类用于组织初始案例，并根据形成性研究资料修订。

7 通过设计开展研究

7.1 设计原则的形成

Amershi 等^[48]通过多轮形成、评议和验证提出十八条人机交互指南，评价涉及四十九名设计实践者和二十种产品。该研究展示了通用指导如何通过多种产品和使用情境检验其清晰性与适用性。原则的价值既体现在表述，也体现在其能否帮助设计者识别问题和作出设计决策。

Weisz 等^[49]结合文献、设计实践者反馈、现有生成式人工智能应用以及两个应用的设计过程，迭代形成六项设计原则及相应策略。研究把原则的抽象表述与具体实施方式联系起来，并通过多种来源修订其内容。上述两项研究表明，设计原则的形成需要经验问题、设计操作、任务结果和应用条件相互对应。

7.2 中层知识

Zimmerman 等^[50]讨论通过设计开展研究（research through design）的知识生产方式，将设计实践与研究贡献联系起来。Höök 和 Löwgren^[51]以强概念（strong concepts）讨论交互设计中的中层知识（intermediate-level knowledge），说明知识可以位于单个实例与宏观理论之间。两项工作支持设计研究提炼可迁移认识，同时要求研究者明确其知识形态及依据。

本课题的设计学贡献定位为具有条件的设计原则，以及支撑这些原则的跨案例经验描述。研究原型承担设计主张的物化和检验功能，形成性研究、方案比较和实证评价共同构成设计知识的生成过程。原则应说明面对哪类诊断困难，设计者可以怎样组织信息或提供操作，预期影响什么活动，现有证据来自哪些参与者和任务，以及何时效果减弱或成本增加。原则可以借助一个原型检验，但其表述需要让其他设计者在另一种界面中实施。

7.3 研究严谨性

Sedlmair 等^[52]总结可视化设计研究的方法，将问题理解、抽象、设计实现和验证联系起来，并讨论各阶段的研究风险。Meyer 和 Dykes^[53]进一步从可视化设计研究的经验出发讨论严谨性，强调研究过程的反思、论证和材料呈现。本研究依据这些方法记录设计选择、修改理由和对应证据。

候选原则需要追溯到跨案例困难、可比较方案和评价结果。实验条件同时改变多个功能时，研究结论限定为组合设计的整体效果；单项功能的作用需要相应的条件比较或过程证据。

7.4 实证评价方法

Malterud 等^[54]提出信息力（information power），将定性样本的充分性与研究目标、样本特征、理论使用、访谈质量和分析方式联系起来。该观点支持以研究问题和资料质量决定招募，而不是仅以访谈人数判断充分性。对于本课题，关键在于是否获得不同开发背景下可分析的诊断事件，以及这些事件能否支持跨案例比较。

Gale 等^[55]介绍框架法（framework method），通过编码和矩阵组织案例与主题，适用于系统比较多名参与者的经验。本研究将建立案例—主题矩阵，并保留不符合主要模式的案例，用于区分跨案例困难、特定任务困难和个体差异。

对照实验中的样本量需要另行论证。Lakens^[56]讨论最小有意义效应、估计精度和研究资源等样本量依据；Green 和 MacLeod^[57]提供广义线性混合模型的模拟功效分析方法。参与者反复处理多个案例时，人员和案例都可能造成差异，样本论证应纳入这种结构。预实验适合用于检查任务难度、测量流程和参数范围，正式比较应在明确主要指标和分析计划之后开展。

8 本章小结

现有文献形成了四方面认识。第一，调试包含材料搜索、关系理解、假设形成与检查，自动提供可疑位置仍需要人的解释工作。第二，生成式系统的实践者持续面临结果评价和改进行动之间的衔接问题，智能体增加了跨步骤执行、工具反馈和干预选择。第三，轨迹可视化、问题式入口、输出比较和局部重执行提供了多种设计资源，效果与任务、使用者经验及信息条件有关。第四，清晰解释和透明性感受需要与客观判断分别评价，不确定性和系统限制会影响使用者的检查行为。

国内研究在智能时代人机协作与工程心理学方面形成了重要议题，国际相关文献积累了程序调试、生成式工具使用和智能体可视分析的具体经验。现阶段，工具调用型智能体的专业开发者诊断行为，尤其是运行材料怎样影响原因判断和下一步检查，仍需要更直接的经验研究。

首先，需要补充从真实诊断事件出发的过程证据。现有工具评价揭示了使用需求和部分任务表现，但关于开发者如何在工具参数、返回内容、状态变化和配置之间寻找原因，仍缺少足以支撑设计选择的细致描述。研究应确定困难出现的条件，并区分材料未被记录、材料难以访问以及材料虽已取得但难以解释。

其次，需要补充针对核心设计选择的比较证据。多种功能组合可以改善工具体验，但研究还需说明设计改变了哪项诊断活动。可在控制材料与基础功能的情况下比较信息组织方式，也可明确研究“新增信息及其呈现”的整体效果。评价对象的界定决定结论能否解释具体设计的作用。

再次，需要补充对判断依据和材料边界的评价。只按最终原因名称评分无法区分有证据支持的判断、无依据猜测和材料不足时的合理保留。本研究将实际故障原因和可见材料允许作出的判断分别用于案例记录和评分。

最后，需要补充设计知识在新案例中的适用证据。新案例可以改变工具组合、任务内容、故障传播方式或记录完整性，研究据此检查某项原则是否依赖具

体案例或界面实现。跨案例验证能够逐步明确知识适用的情境，支持后续设计者判断能否借鉴。

本课题聚焦具有工具调用和状态更新过程的单个主要智能体，研究开发者在任务失败后如何利用运行材料形成并检验诊断判断。研究首先通过访谈和任务观察建立跨案例描述，再选择一项具有共同性且能够通过设计改善的困难，形成可比较的原型方案，随后开展对照评价与新案例检验。

核心研究问题为：在工具调用型智能体故障诊断中，哪些信息条件使开发者难以建立和检验原因判断，以及怎样的信息表征与交互支持能够改善这些活动？研究拟形成诊断困难与信息条件的经验描述，以及由实证结果支持的设计原则。原型用于检验设计主张，对照实验评价其作用和成本，新案例研究界定适用范围。

三、选题报告

1 选题依据

1.1 研究来源

本课题来源于工具调用型大语言模型智能体的实际开发工作。智能体完成一项任务时，通常需要多次请求模型、调用外部工具并更新运行状态。任务失败后，开发者需要查阅提示、调用参数、工具返回、状态变化和错误信息，判断问题发生的环节及其对后续步骤的影响。这些材料分散在调用平台、日志、配置和代码中，增加了查找和理解的难度。

1.2 研究背景

大语言模型（large language model, LLM）通过工具调用参与外部任务执行，形成大语言模型智能体（large language model agent）。Yao 等^[1]提出的推理与行动协同方法（ReAct）将语言推理与环境操作相结合，使模型能够根据任务进展继续采取行动。Cemri 等^[2]对多智能体失败的分析以及 Chen 等^[3]对智能体框架缺陷的研究表明，故障可能涉及模型输出、工具交互、状态传递和流程控制等多个环节。开发者需要把最终症状与运行事件联系起来，比较原因解释并决定后续检查。

近期研究开始提供这一问题的直接证据。Epperson 等^[4]通过开发者访谈和用户研究发现，长对话检查、问题定位及运行调整存在困难，提供编辑和重执行功能后，使用者仍需判断修改位置和方式。van der Maden 等^[19]对十九名大语言模型产品实践者的访谈揭示，发现评价问题与采取具体改进行动之间存在缺口。Kumar 等^[20]对开发者与编程智能体协作的观察，也体现了持续评价、增量交互

和人工干预在真实任务中的作用。

本课题研究开发者形成诊断判断的过程，重点关注运行材料的组织和使用。信息表征指运行事件及其属性、关系和来源在界面中的呈现方式；交互设计指开发者查找、关联、比较和核验这些信息的操作。研究将从实际诊断事件出发，确定具有共同性的困难，再形成和检验具体设计。

1.3 研究目的及意义

本研究拟建立工具调用型智能体故障诊断的信息条件与开发者活动之间的经验联系，围绕一项经研究确认的核心困难，探索能够改善诊断判断的信息表征与交互方式，并提炼具有适用条件的设计原则。

具体目标包括：

- 1) 通过真实事件访谈和诊断任务观察，描述开发者查找材料、形成原因解释和检验判断的过程，识别反复出现的困难及其条件。
- 2) 根据经验研究确定设计问题，比较备选方案，形成能够表达和检验核心设计主张的原型。
- 3) 通过对照任务和新案例观察，评价设计对诊断判断、证据使用和操作成本的影响，明确原则的作用与适用范围。

1.3.1 理论意义

本研究面向交互设计领域，拟形成经验描述和设计原则两类学术成果。经验描述用于说明开发者在什么任务和信息条件下难以定位相关事件、建立事件关系、区分原因解释或决定后续检查，补充程序调试研究在自然语言记录、概率性输出和外部工具混合情境中的经验材料。

设计原则概括针对共同诊断困难的设计操作、预期作用和适用条件。Höök和 Löwgren^[51]讨论的中层知识（intermediate-level knowledge）为这一贡献定位提

供了参考。原则将具体实例与可迁移的设计认识联系起来，使其他设计者能够判断其适用性并在不同界面中实施。原则由形成性研究、方案比较和评价结果共同形成，按照“问题条件—设计操作—预期作用—经验依据—适用边界”的结构表述。研究原型用于把设计主张转化为可操作方案，并在诊断任务中接受检验。

1.3.2 实践意义

本研究将形成可复现的诊断案例、研究原型和评价材料，为智能体调试工具的设计提供依据。研究结果可帮助工具设计者判断哪些信息需要被记录，哪些关系需要被呈现，以及哪些操作有助于使用者检查自己的判断。案例与评分材料还可为开发团队评价调试界面和改进运行记录提供参考。

2 国内外研究综述

2.1 工具调用型智能体故障诊断

Yao 等^[1]提出的推理与行动协同方法使大语言模型能够交替开展语言推理和外部操作。Cemri 等^[2]对多智能体失败的分析以及 Chen 等^[3]对智能体框架缺陷的研究表明，失败可能涉及模型输出、工具交互、状态传递和流程控制等多个环节。

Zhang 等^[35]通过自动失败归因任务评价责任主体和责任步骤的定位方法；Epperson 等^[4]则通过开发者研究记录长轨迹检查、问题定位和运行调整中的困难。前者关注自动方法能否接近标注答案，后者说明开发者仍需理解运行材料并决定检查和干预位置。本研究关注人的诊断过程及其交互支持。

2.2 程序调试的信息行为

Ko 等^[9]观察开发者完成软件维护任务，发现其需要持续查找、关联和收集信息，线索不足和导航成本会妨碍理解。Lawrance 等^[10]通过信息觅食（information foraging）视角解释专业程序员的搜索行为，说明信息线索、预期价值和访问成

本影响下一步检查位置。Starr 和 Storey^[11]通过二十七名专业开发者的访谈，将排错中的困惑与系统理解、心理模型构建及认知疲劳联系起来。这些研究支持从具体活动和信息条件分析诊断困难。

信息表征的作用已有实验证据。Romero 等^[12]发现多表征环境中的调试行为与经验及表征知识有关；Cornelissen 等^[22]通过受控实验报告执行轨迹可视化对程序理解的帮助；Ko 和 Myers^[23]通过面向原因问答的调试界面（Whyline）将程序输出问题连接到执行事件。Parnin 和 Orso^[16]则发现，自动给出可疑位置之后，开发者仍需要上下文完成理解。

上述研究分别揭示了材料查找和原因理解中的困难。本研究将两类活动同时纳入形成性研究，并通过工具调用型智能体开发者的任务资料分析二者之间的联系。

2.3 大语言模型开发中的人机协作

Barke 等^[17]通过程序员使用代码生成工具的观察，描述加速既定实现和探索可能方案两种交互方式，揭示使用目的与知识状态对交互的影响。van der Maden 等^[19]将研究推进到产品实践中的评价工作，指出评价结果与改进行动之间的衔接困难。Kumar 等^[20]在真实仓库任务中观察开发者与智能体协作，提供了持续检查和人工干预的过程证据。

Arawjo 等^[25]提出提示与输出比较工具（ChainForge），通过实验室研究和访谈展示输出探索、假设检验及评价迭代的工作方式。这些研究说明，生成结果需要在具体任务中被检查和解释。对于长链路智能体失败，仍需进一步明确开发者使用哪些跨步骤信息，以及怎样把观察转化为下一步检查。

2.4 智能体调试的交互设计

Lu 等^[26]提出智能体行为可视分析系统 (AgentLens)，利用层级结构和多粒度时间信息支持行为探索，并通过使用案例和用户研究进行评价。Epperson 等^[4]提出交互调试工具 (AGDebugger)，分别开展诊断和运行引导研究，显示局部编辑和重执行的需求，也记录了选择干预位置的困难。Hutter 和 Pradel^[30]提出软件开发智能体调试器 (AgentStepper)，以小规模研究考察暂停、检查与编辑功能。

近期工作扩展了事件关联和原始材料核验。Gao 等^[27]通过科学智能体执行轨迹可视化工具 (Graph of Trace) 获得专家关于理解和使用价值的反馈。Wu 等^[5]提出轨迹转图平台 (AgentGraph)，以类型化关系关联任务、工具、数据和人工干预，并将图元素连接到原始轨迹。

现有工具已经展示了层级轨迹、事件图、局部编辑和重执行等设计实现，但评价对象、任务和样本存在差异。围绕开发者诊断活动，尚缺少信息组织方式与实际困难的对应证据、设计对判断和检查行为的比较证据，以及不同任务条件下的适用证据。

2.5 智能体运行追踪

Sigelman 等^[32]总结大规模分布式追踪基础设施 (Dapper) 的部署经验，为跨组件记录的关联提供工程参考。Ragan 等^[36]区分数据、操作、交互和分析理由等来源记录，提示执行历史与使用者的分析过程需要分别处理。

自动故障分析提供了案例与建议来源。Cemri 等^[2]建立多智能体失败分类；Zhang 等^[35]评价自动定位责任主体和步骤的方法；Chen 等^[3]将失败轨迹与运行框架实现联系起来，研究缺陷诊断和修复。它们分别提供失败类型、归因评价和实现关联的方法，人的诊断研究还需考察开发者怎样理解和核验这些结果。

本课题将实际故障原因和现有记录允许作出的判断分别记录。材料充分的

案例要求参与者依据可见信息识别原因；材料不足的案例要求参与者指出尚未区分的解释、缺失信息和后续检查。该区分同时用于案例构造、任务要求和评分。

2.6 可解释人工智能

可解释人工智能（explainable artificial intelligence, XAI）研究关注解释怎样被不同使用者理解和使用。Liao 等^[39]通过设计实践者访谈说明，解释需求与使用者角色、任务和问题有关。Kaur 等^[41]研究数据科学家使用解释工具的过程，发现误解和过度依赖现象。Buçinca 等^[42]通过对照实验发现，促使使用者独立思考的交互措施能够减少对错误建议的依赖，同时增加使用成本。Sieker 等^[43]进一步研究解释对系统能力判断的影响，发现主观理解评价与系统局限识别并不一致。

这些结果支持将诊断表现、证据使用、信心和使用体验分别评价。Guo 等^[45]关于图关系不确定性的实验也说明，视觉编码的效果受到任务及编码组合影响。若原型表达推断关系、缺失信息或自动建议，研究需要检查参与者是否正确理解其含义。

2.7 通过设计开展研究

通过设计开展研究（research through design）以设计实践作为提出和检验知识主张的研究过程。Zimmerman 等^[50]讨论了这一方法的知识生产方式；Höök 和 Löwgren^[51]提出的中层知识为连接具体设计实例和可迁移认识提供了贡献形式。

Amershi 等^[48]通过多轮评议和产品评价形成交互指南；Weisz 等^[49]结合文献、实践者反馈、现有应用及实际设计过程形成生成式人工智能设计原则。两项研究展示了设计原则的形成和修订方法。Sedlmair 等^[52]以及 Meyer 和 Dykes^[53]则强调问题理解、设计实现和评价证据之间的论证关系。

2.8 本章小结

综合以上文献，本课题聚焦工具调用型智能体开发者的诊断活动，研究信息条件与判断困难的关系，通过原型比较检验设计作用，并在新案例中考察适用条件。原型功能依据形成性研究结果确定。

3 研究问题与方法

3.1 研究问题

本课题的核心问题是：在工具调用型智能体故障诊断中，哪些信息条件使开发者难以形成和检验原因判断，怎样的信息表征与交互支持能够改善这些活动？

围绕核心问题提出三个研究问题：

研究问题一 (RQ1)：在智能体发生任务失败后，开发者如何利用运行信息判断故障原因，诊断过程中存在哪些反复出现的困难？

研究问题二 (RQ2)：针对上述诊断困难，如何组织和呈现相关运行信息，并通过交互支持开发者形成和验证故障原因假设？

研究问题三 (RQ3)：所提出的交互设计如何影响开发者的故障诊断结果与诊断过程，这种影响在不同故障案例中有何表现？

3.2 研究对象

研究对象为具有实际开发或排错经验的工具调用型智能体开发者。目标系统包含一个主要智能体，能够通过多次模型请求和工具调用完成任务，并保留可供检查的运行记录。研究任务从失败结果出发，要求开发者解释异常、指出依据并提出下一步检查。

主要分析单位为一次具有明确任务目标、失败表现和诊断活动的事件。案例将覆盖跨步骤信息传递、工具交互及流程控制等运行条件。多智能体研究为相关

工作和案例设计提供参考，正式研究范围集中在单个主要智能体，以保持责任关系和任务条件的可分析性。

研究关注对运行行为的诊断，包括工具参数、返回内容、状态更新和配置条件。模型内部表征、训练机制和参数级解释不构成本课题的研究对象。

3.3 理论基础

本研究以任务活动和运行材料为分析起点，将任务症状、可见材料、参与者问题、原因假设、检查行动和判断变化作为初始分析概念，并在开放编码过程中补充和修订。

信息觅食视角用于解释材料入口、搜索线索和访问成本。意义建构（sensemaking）视角用于分析分散材料如何被组织为原因解释，以及解释怎样随新材料改变。Pirolli 和 Card^[13]的认知任务分析提供了信息搜集与解释形成的过程参照；Klein 等^[14]关于资料与解释框架相互作用的讨论，可用于识别假设维持与修订的条件。

资料分析分别编码材料访问、搜索线索、原因假设、判断修订和检查行动。研究保留不能由初始理论框架解释的资料，并据此调整分类。

3.4 研究方法

3.4.1 形成性研究

参与者招募。

形成性研究拟招募 12—16 名参与者，通过公司和领英（LinkedIn）等外部专业渠道招募，覆盖不同组织、开发经验和工具使用背景。纳入条件为：近六个月内实际搭建、修改或维护过工具调用型智能体，且能够描述至少一次亲自参与的排错事件。招募将记录开发年限、智能体经验、系统类型、排错频率和来源渠道，并针对已有样本的缺项补充参与者。

Malterud 等^[54]提出的信息力（information power）将定性样本充分性与目标、样本特征、访谈质量和分析方式联系起来。本研究据此评估资料是否足以回答研究问题，重点检查核心困难是否有跨参与者和跨任务的支持，反例是否得到解释，以及不同经验背景的材料是否充分。计划人数用于安排研究资源，实际招募根据资料质量和案例覆盖进行调整。

资料收集。

每次研究约 60—90 分钟，包括关键事件回溯和诊断任务观察。关键事件回溯围绕参与者亲历的故障展开，依次询问任务目标、最初症状、已取得的材料、曾怀疑的原因、采取的检查 and 最终判断。优先请参与者借助获得授权并脱敏的记录说明过程；无法提供记录时，以事件时间线和具体操作回忆补充，并标记资料来源。

任务观察使用初步构建的失败案例，让参与者查阅运行材料并完成诊断。研究记录屏幕、操作和同步口语报告（think-aloud），在自然停顿处询问当前判断及其依据。任务结束后回看关键片段，核对研究者对操作含义的理解。真实事件用于理解工作情境，统一任务便于比较不同参与者在相近条件下的活动。

资料包括访谈转录、事件概要、运行片段、操作时间线、参与者提出的假设及判断变化。研究将区分参与者回忆的经历、任务中直接观察的行为和研究者的解释。

资料分析。

研究采用框架法（framework method）。Gale 等^[55]提出的案例—主题矩阵适合组织多名参与者的过程资料。分析先选取不同背景的案例开放编码，再结合初步分析框架形成编码表，随后在其余资料中应用和修订。

编码内容主要包括：当前诊断问题、所需与实际取得的信息、事件关系、原因解释、检查行动、判断变化及活动结果。跨案例比较识别同一困难是否出现于不同系统或任务，并结合口语报告、操作记录和阶段性判断区分相似行为所对应的活动。

研究拟邀请另一名研究人员复核约四分之一的资料，比较编码依据并记录分歧处理。分析保留反例和条件差异，形成核心困难、支持案例及适用条件的矩阵。结果进入设计阶段前，将邀请部分参与者核对事件解释是否符合其经历。

3.4.2 案例构建

案例来源。

研究以开源智能体框架自行构建可复现案例，并依据实践研究修订其任务和故障条件。初步考虑资料检索、结构化数据查询和多步骤工具处理等任务，最终选择取决于访谈结果及实现可行性。公司案例主要用于理解实际困难和核查任务真实性，正式实验材料以可公开或可授权复现的系统为主。

拟建立 12—16 个候选案例，经过专家核查和预实验后选取 12 个进入正式案例池。每个案例保存任务说明、系统版本、工具定义、正常运行材料、失败运行材料、配置及故障构造记录。保留完成诊断所需的背景和合理干扰事件，控制内容长度与领域知识要求。

案例条件依据形成性研究中的高频困难和差异条件确定。正式实验选择一项与核心设计主张直接相关的案例条件作为主要比较因素，其余条件用于平衡任务难度。

证据评定。

每个案例建立两份记录。故障记录说明实际改变了哪些系统条件、故障如何发生，以及哪些复现或干预支持这一解释。任务记录说明参与者可看到哪些材料、能够据此作出什么判断，以及仍有哪些无法确定的内容。

材料充分的案例要求参与者指出与证据相符的原因及其作用过程。材料不足的案例允许保留多个解释，但要求说明具体缺少什么，以及哪项检查能够区分这些解释。研究将以有针对性的缺失构造后一类任务，并核查剩余线索是否意外泄露答案。

案例拟由两名具有相关开发经验的人员独立检查。核查内容包括情境合理

性、故障可复现性、可见材料充分性、替代解释和评分规则。存在多个有效诊断路径时，将其纳入评分手册。构造时选定的故障只是实际原因记录，评分还需依据参与者可见材料判断答案是否合理。

3.4.3 原型设计

本阶段采用通过设计开展研究的方法。原型用于外化设计假设、组织任务材料并产生可分析的使用证据，其迭代过程与取舍记录构成设计知识提炼的依据。

研究围绕形成性研究确认的核心困难提出至少两种备选方案。每种方案记录对应问题、设计操作、预期作用和实现条件，具体信息结构和交互方式在形成性研究后确定。

设计探索拟开展两轮任务式走查，共招募 6—8 名参与者，每轮约 4—5 人，部分参与者参与两轮以观察修改效果，并补充首次使用者检查学习成本。走查使用相同或难度相近的任务，收集理解错误、检查行为、未满足的信息需要和操作障碍。

原型分为通用功能和研究功能。通用功能包括任务说明、事件查看、必要搜索和材料展开；研究功能承载核心设计主张。每次迭代保存对应困难、设计意图、观察结果及修改理由，淘汰仅受偏好支持但未改善目标活动的方案。

最终原型优先使用保存的运行材料，以保证任务可复现。若形成性研究确认交互重执行对核心问题不可缺少，将为相关工具提供固定响应或受控执行，并记录每次修改和执行条件。正式评价前冻结原型版本。

3.4.4 对照实验

实验条件。

正式研究采用被试内设计（within-subject design），比较基础界面与研究界面。基础界面提供可用的时间序列、事件详情、搜索和展开功能；研究界面在此基础上实现选定的信息组织或交互支持。训练使用独立练习案例，确保参与者能

够操作两种界面。

比较前建立条件清单，逐项核对原始材料、派生内容、搜索能力、默认展开状态和访问步骤。若研究重点为信息组织，两种界面提供相同语义内容，差异集中于其呈现和操作。若选定方案引入新的派生信息，则把“派生信息及其呈现”的整体作用作为评价对象，并在研究主张和分析中保持一致。

正式评价比较研究界面和基础界面在有依据的诊断达成率上的差异，并考察完成时间、材料核验、判断信心和使用负担。形成性研究确定设计机制后提出方向性假设，预实验完成后预注册具体假设、主要指标和评分规则。

任务分配。

正式实验的招募条件与形成性研究一致，并记录参与者经验。预实验拟招募4—6人，用于检查任务时长、理解难度、评分可操作性和测量流程。预实验参与者不进入正式实验；正式实验参与者不提前接触所用案例。

正式案例池初步按12个案例规划，每人完成6个，每种界面各3个。最终案例数量和单人任务量依据预实验中的任务时长和难度确定。通过平衡任务分配，使每个案例在两种界面下均获得评价，同一参与者只接触每个案例一次。界面顺序与案例分配交叉平衡，避免将某类故障固定给某一条件。全部任务时长和休息安排依据预实验确定。

样本量依据主要指标、最小有实际意义的差异、参与者和案例的变异范围进行模拟论证。Lakens^[56]的样本量论证方法以及Green和MacLeod^[57]的模拟方法为此提供依据。研究在正式招募前确定目标人数和分析计划，将预实验参数与保守参数范围共同纳入计算，避免仅依赖单一试测效应。

评价指标。

每个任务要求参与者提交：对失败原因的判断、支持判断的运行事件、尚未排除的解释、下一步检查及判断信心。正式计时任务不要求持续口述，过程资料以操作记录为主，并在任务后进行简短回顾，减少口述对完成时间的影响。

主要指标为有依据的诊断达成率。每个答案依据预先确定的标准判断是否

达成：

- 1) 原因或无法确定的判断符合案例可见材料允许的结论。
- 2) 引用的运行事件准确且能够支持关键判断。
- 3) 提出的下一步检查与剩余疑问相匹配；材料已经充分时，可提出有针对性的确认或修复检查。

三个条件分别评分，再按预注册规则形成达成判定，同时保留分项结果。承认无法判断需要指出具体缺口和可区分解释的检查，空泛保留意见不计为达成。

表 3.1 诊断评价指标

指标类别	具体测量	解释用途
主要结果	有依据的诊断达成率	比较两种界面对诊断任务的支持
判断组成	原因或信息不足判断、引用依据、下一步检查的分项得分	识别改善发生的环节
时间与操作	完成时间、关键材料访问、比较与回查行为	描述获得结果所需的成本及过程
信心	作答后 0—100 分信心，与答案达成情况对应	检查错误判断是否伴随过高信心
使用体验	心智努力、操作困难及访谈反馈	解释使用负担和接受程度

任务达到时间上限时结束并保存当前判断；完成时间按未完成任务的截尾情况处理。两名评分者依据匿名化答案独立评分，评分材料隐藏界面条件，先报告

一致性，再按评分手册讨论分歧。评分手册在正式数据分析前冻结。

数据分析。

主要结果拟使用广义线性混合模型（generalized linear mixed model），以界面条件为主要固定效应，纳入参与者与案例的随机效应，并按预注册计划处理顺序和经验因素。模型结构、参数估计及拟合异常的处理方式在预实验后确定。结果报告效应估计及置信区间。

时间、分项得分和使用体验分别分析。过程资料用于检查关键材料是否被发现、原因解释是否得到核验，以及错误判断如何形成。经验和案例条件的差异主要用于描述效果范围，探索性分析与主要检验分别呈现。

研究将主要结果、分项得分和过程资料与设计的预期作用对应分析。结论范围依据实际出现的诊断表现、检查行为和使用成本确定。

3.4.5 迁移检验

对照评价后，拟另外构建 3—4 个未参与设计迭代的新案例，改变任务内容、工具组合或框架实现中的至少一项条件，保留待检验的共同诊断问题。拟招募 6—8 名具有相关经验的参与者开展任务走查，分析同一设计操作在新案例中的使用过程、所需前提和失效情境。该阶段用于修订原则的适用范围，不承担新的总体效果检验。

研究同时尝试将一项核心原则用另一种低保真表现方式表达，并结合任务走查检查使用者能否完成相同检查活动。该步骤帮助区分原则依赖的操作与某个界面布局的偶然特征。结果将与正式实验一同用于修订原则。

每项原则按照以下结构整理：

表 3.2 设计原则的表述结构

内容	需要回答的问题
适用情境	哪类任务、信息条件或使用者困难需要这项原则？
设计操作	设计者应怎样组织信息或提供检查操作？
预期作用	该操作影响哪项诊断活动？
支持证据	哪些观察、比较结果和新案例支持这一判断？
实施条件与成本	需要哪些记录、背景知识和操作投入？
适用边界	哪些情况下效果减弱、无效或产生新的困难？

研究保留未得到支持的设计主张，并说明其结果。最终原则数量根据证据决定。

3.4.6 质量控制

本研究重点是建立实践问题、设计选择与评价结论之间的对应关系。形成性研究确定可重复观察的困难，原型表达针对这一困难的设计主张，实验检查主张是否获得支持，新案例研究界定适用条件。

另一个重点是诊断答案的合理性。研究将区分实际故障、可见证据和参与者判断，避免只按最终原因名称评价任务表现。原始材料、派生信息和自动建议保留来源，使评分和过程分析具有可追溯依据。

表 3.3 研究风险控制

难点	应对安排
实际案例包含公司或个人信息	以授权脱敏事件理解情境，用开源系统构建可复现任务
自建案例与真实困难脱节	依据访谈选择案例，由实践者核查背景、歧义和检查路径
多种原因符合表面症状	分别记录实际原因与可见材料支持的解释，允许多条合理诊断路径
原型同时改变过多因素	围绕一个核心问题设计条件，核对各条件的信息和操作差异
参与者经验与案例难度造成差异	记录经验，训练基础操作，平衡任务，联合分析人员与案例差异
专业参与者招募不足	提前开展公司与外部渠道招募，分阶段维护招募矩阵并调整计划
模型和工具更新影响重复评价	固定运行材料、版本与配置，保存构造记录及可复现环境

3.5 可行性分析

课题来自实际开发工作中的问题观察，已完成文献调研和方案设计。访谈、案例、原型和实验尚未开展，文中样本及研究安排均属计划。

研究者可通过公司渠道接触若干具有智能体开发经验的人员，并计划通过外部专业社群扩展招募。技术实现拟使用开源框架，研究原型主要处理保存的运行材料和必要的检查操作，开发范围与核心研究问题保持一致。

整体工作按阶段推进。先以访谈和轻量案例确认问题，再通过低保真方案和任务走查确定设计，正式实现集中于评价需要的功能。中期前完成形成性研究、原型和预实验，并争取取得正式评价的阶段性的数据；中期后完成评价、迁移检验和论文写作。

3.6 研究伦理

涉及参与者的研究将在完成学校要求的伦理程序后开展。知情同意材料说明研究目的、参与内容、录音及屏幕记录范围、补偿方式、退出权利和数据保存安排。公司渠道招募遵循自愿原则，参与情况不用于工作评价。

研究仅收集完成分析所需的材料。真实案例须取得授权并进行脱敏，排除密钥、个人信息及不可公开的业务内容。联系信息与研究编号分开保存，原始录音、屏幕记录和文本资料限制访问。论文使用匿名编号和必要摘录，公开材料遵守参与者授权及开源许可。

自动生成的摘要或建议保留生成配置与来源标记。案例、评分手册、原型版本和分析材料统一归档，以支持研究复核。

4 研究框架

根据 Zimmerman 等^[50]关于通过设计开展研究的论述，以及 Meyer 和 Dykes^[53]对设计研究严谨性的讨论，本研究依次开展诊断实践研究、设计探索、对照评价、新案例检验和知识提炼。各阶段的产出作为后续阶段的输入。

表 3.4 研究实施阶段

阶段	核心工作	阶段产出	进入下一阶段的依据
诊断实践研究	关键事件访谈、任务观察、跨案例分析	困难与信息条件矩阵	核心困难有多个案例支持，能够通过设计进行比较
设计探索	提出备选方案、任务式走查、迭代原型	明确设计主张与原型	方案可用，设计差异可描述，评价材料能够回答问题
对照评价	冻结条件、开展正式任务、分析判断和过程	效果估计与行为解释	获得足以讨论核心主张的任务及过程资料
新案例检验	更换任务或工具条件，观察作用变化	支持案例、失效案例及修订依据	能够说明原则适用与不适用的条件
知识提炼	综合实证材料与设计记录	经验描述和设计原则	原则各项论断均有对应材料与证据范围

核心困难的选择依据包括出现范围、诊断后果、材料可获得性、设计可介入性和实验可检验性。原型围绕最终选定的问题实现必要功能。

5 计划进度

表 3.5 研究计划

时间	研究工作	阶段成果
2026.09— 2026.10	完成开题，细化研究协议，办 理伦理程序，构建初始案例	研究协议、招募材料、案例 模板
2026.11— 2027.01	开展关键事件访谈与任务观 察，同步整理资料	访谈及观察资料、初步编码
2027.02— 2027.03	跨案例分析，补充样本，确定 核心设计问题	困难与信息条件矩阵、设计 要求
2027.03— 2027.05	比较备选方案，完成两轮任 务式走查	设计记录、核心主张、原型 方案
2027.05— 2027.06	实现研究原型，核查案例与 评分规则	原型、正式案例池、评分手册
2027.06— 2027.08	预实验、样本量论证与预注 册，启动正式评价	预实验结果、正式研究计划、 阶段数据
2027.09	中期答辩	形成性研究、设计依据、原 型及评价进展
2027.09— 2027.10	完成正式评价与新案例检验	完整研究数据、原则修订依据

表 3.5 研究计划（续）

时间	研究工作	阶段成果
2027.11— 2028.02	综合分析并撰写论文	经验描述、设计原则、论文 初稿
2028.03— 2028.05	论文修改、送审与答辩准备	学位论文定稿、归档材料

参考文献

- [1] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C/OL]//International Conference on Learning Representations. 2023. arXiv: 2210.03629. <https://arxiv.org/abs/2210.03629>.
- [2] Cemri M, Pan M Z, Yang S, et al. Why Do Multi-Agent LLM Systems Fail? [C/OL]//Advances in Neural Information Processing Systems: vol. 38. 2025. https://papers.nips.cc/paper_files/paper/2025/hash/b1041e52d3be19f0a9bc491657488e4a-Abstract-Datasets_and_Benchmarks_Track.html. DOI: 10.52202/085713-4082.
- [3] Chen M, Wang J, Liu Z, et al. From Failed Trajectories to Reliable LLM Agents: Diagnosing and Repairing Harness Flaws[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2606.06324v2>. arXiv: 2606.06324 [cs.SE].
- [4] Epperson W, Bansal G, Dibia V, et al. Interactive Debugging and Steering of Multi-Agent AI Systems[C/OL]//Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems. 2025: 156:1-156:15. DOI: 10.1145/37

06598.3713581.

- [5] Wu Z, Cho S, Villalobos C E M, et al. AgentGraph: Trace-to-Graph Platform for Interactive Analysis and Robustness Testing in Agentic AI Systems[C/OL]// Proceedings of the AAAI Conference on Artificial Intelligence: vol. 40: 48. 2026: 41721-41723. DOI: 10.1609/aaai.v40i48.42393.
- [6] 范俊君, 田丰, 杜一, 等. 智能时代人机交互的一些思考[J/OL]. 中国科学: 信息科学, 2018, 48(4): 361-375. DOI: 10.1360/N112017-00221.
- [7] 许为, 葛列众. 智能时代的工程心理学[J/OL]. 心理科学进展, 2020, 28(9): 1409-1425. DOI: 10.3724/SP.J.1042.2020.01409.
- [8] Katz I R, Anderson J R. Debugging: An Analysis of Bug-Location Strategies [J/OL]. Human-Computer Interaction, 1987-1988, 3(4): 351-399. DOI: 10.1207 /s15327051hci0304_2.
- [9] Ko A J, Myers B A, Coblenz M J, et al. An Exploratory Study of How Developers Seek, Relate, and Collect Relevant Information during Software Maintenance Tasks[J/OL]. IEEE Transactions on Software Engineering, 2006, 32(12): 971-987. DOI: 10.1109/TSE.2006.116.
- [10] Lawrance J, Bogart C, Burnett M, et al. How Programmers Debug, Revisited: An

- Information Foraging Theory Perspective[J/OL]. IEEE Transactions on Software Engineering, 2013, 39(2): 197-215. DOI: 10.1109/TSE.2010.111.
- [11] Starr A, Storey M-A. Theory of Troubleshooting: The Developer's Cognitive Experience of Overcoming Confusion[J/OL]. ACM Transactions on Software Engineering and Methodology, 2026. DOI: 10.1145/3800945.
- [12] Romero P, du Boulay B, Cox R, et al. Debugging Strategies and Tactics in a Multi-Representation Software Environment[J/OL]. International Journal of Human-Computer Studies, 2007, 65(12): 992-1009. DOI: 10.1016/j.ijhcs.2007.07.005.
- [13] Pirolli P, Card S K. The Sensemaking Process and Leverage Points for Analyst Technology as Identified Through Cognitive Task Analysis[C/OL]//Proceedings of the 2005 International Conference on Intelligence Analysis. 2005. https://www.e-education.psu.edu/geog885/sites/www.e-education.psu.edu/geog885/files/geog885q/file/Lesson_02/Sensemaking_206_Camera_Ready_Paper.pdf.
- [14] Klein G, Moon B, Hoffman R R. Making Sense of Sensemaking 2: A Macro-cognitive Model[J/OL]. IEEE Intelligent Systems, 2006, 21(5): 88-92. DOI: 10.1109/MIS.2006.100.

- [15] Dritsa D, Houben S. How Design Researchers Make Sense of Data Visualizations in Data-Driven Design: An Uncertainty-Aware Sensemaking Model[J/OL]. ACM Transactions on Computer-Human Interaction, 2024, 31(6): 72:1-72:53. DOI: 10.1145/3685268.
- [16] Parnin C, Orso A. Are Automated Debugging Techniques Actually Helping Programmers?[C/OL]//Proceedings of the 20th International Symposium on Software Testing and Analysis. 2011: 199-209. DOI: 10.1145/2001420.2001445.
- [17] Barke S, James M B, Polikarpova N. Grounded Copilot: How Programmers Interact with Code-Generating Models[J/OL]. Proceedings of the ACM on Programming Languages, 2023, 7(OOPSLA1): 78:1-78:27. DOI: 10.1145/3586030.
- [18] Zamfirescu-Pereira J D, Wong R Y, Hartmann B, et al. Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts[C/OL]//Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems. 2023. DOI: 10.1145/3544548.3581388.
- [19] Van der Maden W, Sadek M, Xiao Z, et al. Results-Actionability Gap: Understanding How Practitioners Evaluate LLM Products in the Wild[C/OL]//Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems. 2026:

- 1-17. DOI: 10.1145/3772318.3791069.
- [20] Kumar A, Bajpai Y, Gulwani S, et al. Why AI Agents Still Need You: Findings from Developer-Agent Collaborations in the Wild[C/OL]//Proceedings of the 40th IEEE/ACM International Conference on Automated Software Engineering. 2025: 432-444. <https://arxiv.org/abs/2506.12347v3>. DOI: 10.1109/ASE63991.2025.00043.
- [21] Pareek S, Govers J, Kollerup N K, et al. Sensemaking in Multi-Agent LLM Interfaces: How Users Interpret Transparency and Trustworthiness Cues[C/OL]//Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems. 2026: 1-20. DOI: 10.1145/3772318.3791157.
- [22] Cornelissen B, Zaidman A, van Deursen A. A Controlled Experiment for Program Comprehension through Trace Visualization[J/OL]. IEEE Transactions on Software Engineering, 2011, 37(3): 341-355. DOI: 10.1109/TSE.2010.47.
- [23] Ko A J, Myers B A. Finding Causes of Program Output with the Java Whyline [C/OL]//Proceedings of the 27th ACM Conference on Human Factors in Computing Systems. 2009: 1569-1578. DOI: 10.1145/1518701.1518942.
- [24] Khanna R, Dodge J, Anderson A, et al. Finding AI's Faults with AAR/AI: An Em-

- pirical Study[J/OL]. ACM Transactions on Interactive Intelligent Systems, 2022, 12(1): 1:1-1:33. DOI: 10.1145/3487065.
- [25] Arawjo I, Swoopes C, Vaithilingam P, et al. ChainForge: A Visual Toolkit for Prompt Engineering and LLM Hypothesis Testing[C/OL]//Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems. 2024. DOI: 10.1145/3613904.3642016.
- [26] Lu J, Pan B, Chen J, et al. AgentLens: Visual Analysis for Agent Behaviors in LLM-Based Autonomous Systems[J/OL]. IEEE Transactions on Visualization and Computer Graphics, 2025, 31(8): 4182-4197. DOI: 10.1109/TVCG.2024.3394053.
- [27] Gao T, Li H, Li J H, et al. Graph of Trace: Visualizing Execution Traces of Scientific Agents[C/OL]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics: System Demonstrations. 2026: 297-306. <https://aclanthology.org/2026.acl-demo.29/>.
- [28] Dibia V, Chen J, Bansal G, et al. AutoGen Studio: A No-Code Developer Tool for Building and Debugging Multi-Agent Systems[C/OL]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System

- Demonstrations. 2024: 72-79. DOI: 10.18653/v1/2024.emnlp-demo.8.
- [29] Rorseth J, Godfrey P, Golab L, et al. LADYBUG: An LLM Agent DeBUGger for Data-Driven Applications[C/OL]//Proceedings of the 28th International Conference on Extending Database Technology. 2025: 1082-1085. DOI: 10.48786/EDBT.2025.94.
- [30] Hutter R, Pradel M. AgentStepper: Interactive Debugging of Software Development Agents[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2602.06593>. 3. arXiv: 2602.06593.
- [31] Fonseca R, Porter G, Katz R H, et al. X-Trace: A Pervasive Network Tracing Framework[C/OL]//Proceedings of the 4th USENIX Symposium on Networked Systems Design and Implementation. 2007: 271-284. <https://www.usenix.org/conference/nsdi-07/x-trace-pervasive-network-tracing-framework>.
- [32] Sigelman B H, Barroso L A, Burrows M, et al. Dapper, a Large-Scale Distributed Systems Tracing Infrastructure: dapper-2010-1[R/OL]. Google. 2010. <https://research.google/pubs/dapper-a-large-scale-distributed-systems-tracing-infrastructure/>.
- [33] Mace J, Roelke R, Fonseca R. Pivot Tracing: Dynamic Causal Monitoring for Dis-

- tributed Systems[C/OL]//Proceedings of the 25th ACM Symposium on Operating Systems Principles. 2015: 378-393. DOI: 10.1145/2815400.2815415.
- [34] Zheng Y, Hu Y, Yu T, et al. AgentSight: System-Level Observability for AI Agents Using eBPF[PP/OL]. arxiv(2025) [2026-09-20]. <https://arxiv.org/abs/2508.02736v2>. arXiv: 2508.02736.
- [35] Zhang S, Yin M, Zhang J, et al. Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems[C/OL]//Proceedings of Machine Learning Research: vol. 267. 2025: 76583-76599. <https://proceedings.mlr.press/v267/zhang25cq.html>.
- [36] Ragan E D, Endert A, Sanyal J, et al. Characterizing Provenance in Visualization and Data Analysis: An Organizational Framework of Provenance Types and Purposes[J/OL]. IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 31-40. DOI: 10.1109/TVCG.2015.2467551.
- [37] Kadivar N, Chen V, Dunsmuir D, et al. Capturing and Supporting the Analysis Process[C/OL]//Proceedings of the IEEE Symposium on Visual Analytics Science and Technology. 2009: 131-138. DOI: 10.1109/VAST.2009.5333020.
- [38] Xu K, Attfield S, Jankun-Kelly T J, et al. Analytic Provenance for Sensemak-

- ing: A Research Agenda[J/OL]. IEEE Computer Graphics and Applications, 2015, 35(3): 56-64. DOI: 10.1109/MCG.2015.50.
- [39] Liao Q V, Gruen D, Miller S. Questioning the AI: Informing Design Practices for Explainable AI User Experiences[C/OL]//Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems. 2020: 1-15. DOI: 10.1145/3313831.3376590.
- [40] Ehsan U, Liao Q V, Muller M, et al. Expanding Explainability: Towards Social Transparency in AI Systems[C/OL]//Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems. 2021: 1-19. DOI: 10.1145/3411764.3445188.
- [41] Kaur H, Nori H, Jenkins S, et al. Interpreting Interpretability: Understanding Data Scientists' Use of Interpretability Tools for Machine Learning[C/OL]//Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems. 2020: 1-14. DOI: 10.1145/3313831.3376219.
- [42] BUÇINCA Z, Malaya M B, Gajos K Z. To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-Assisted Decision-Making[J/OL]. Proceedings of the ACM on Human-Computer Interaction, 2021,

- 5(CSCW1): 188:1-188:21. DOI: 10.1145/3449287.
- [43] Sieker J, Junker S, Utescher R, et al. The Illusion of Competence: Evaluating the Effect of Explanations on Users' Mental Models of Visual Question Answering Systems[C/OL]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 19459-19475. DOI: 10.18653/v1/2024.emnlp-main.1084.
- [44] Hullman J. Why Authors Don't Visualize Uncertainty[J/OL]. IEEE Transactions on Visualization and Computer Graphics, 2020, 26(1): 130-139. DOI: 10.1109/TVCG.2019.2934287.
- [45] Guo H, Huang J, Laidlaw D H. Representing Uncertainty in Graph Edges: An Evaluation of Paired Visual Variables[J/OL]. IEEE Transactions on Visualization and Computer Graphics, 2015, 21(10): 1173-1186. DOI: 10.1109/TVCG.2015.2424872.
- [46] Sacha D, Senaratne H, Kwon B C, et al. The Role of Uncertainty, Awareness, and Trust in Visual Analytics[J/OL]. IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 240-249. DOI: 10.1109/TVCG.2015.2467591.
- [47] Ehsan U, Liao Q V, Passi S, et al. Seamful XAI: Operationalizing Seamful Design

- in Explainable AI[J/OL]. Proceedings of the ACM on Human-Computer Interaction, 2024, 8(CSCW1): 119:1-119:29. DOI: 10.1145/3637396.
- [48] Amershi S, Weld D, Vorvoreanu M, et al. Guidelines for Human-AI Interaction [C/OL]//Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. 2019: 1-13. DOI: 10.1145/3290605.3300233.
- [49] Weisz J D, He J, Muller M, et al. Design Principles for Generative AI Applications [C/OL]//Proceedings of the CHI Conference on Human Factors in Computing Systems. 2024. DOI: 10.1145/3613904.3642466.
- [50] Zimmerman J, Forlizzi J, Evenson S. Research through Design as a Method for Interaction Design Research in HCI[C/OL]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. 2007: 493-502. DOI: 10.1145/1240624.1240704.
- [51] Höök K, Löwgren J. Strong Concepts: Intermediate-Level Knowledge in Interaction Design Research[J/OL]. ACM Transactions on Computer-Human Interaction, 2012, 19(3): 23:1-23:18. DOI: 10.1145/2362364.2362371.
- [52] Sedlmair M, Meyer M, Munzner T. Design Study Methodology: Reflections from the Trenches and the Stacks[J/OL]. IEEE Transactions on Visualization and Com-

- puter Graphics, 2012, 18(12): 2431-2440. DOI: 10.1109/TVCG.2012.213.
- [53] Meyer M, Dykes J. Criteria for Rigor in Visualization Design Study[J/OL]. IEEE Transactions on Visualization and Computer Graphics, 2020, 26(1): 87-97. DOI: 10.1109/TVCG.2019.2934539.
- [54] Malterud K, Siersma V D, Guassora A D. Sample Size in Qualitative Interview Studies: Guided by Information Power[J/OL]. Qualitative Health Research, 2016, 26(13): 1753-1760. DOI: 10.1177/1049732315617444.
- [55] Gale N K, Heath G, Cameron E, et al. Using the Framework Method for the Analysis of Qualitative Data in Multi-Disciplinary Health Research[J/OL]. BMC Medical Research Methodology, 2013, 13: 117. DOI: 10.1186/1471-2288-13-117.
- [56] Lakens D. Sample Size Justification[J/OL]. Collabra: Psychology, 2022, 8(1): 33267. DOI: 10.1525/collabra.33267.
- [57] Green P, MacLeod C J. SIMR: An R Package for Power Analysis of Generalized Linear Mixed Models by Simulation[J/OL]. Methods in Ecology and Evolution, 2016, 7(4): 493-498. DOI: 10.1111/2041-210X.12504.

华中科技大学

研究生（文献阅读与选题）报告

☐文献阅读、☐选题、☐文献阅读与选题、☐论文中期进展

标题：工具调用型大语言模型智能体故障诊断的信息表征与交互设计研究

学 号 M202570493

姓 名 陈思静

专 业 设计学

指 导 教 师 何心

院（系、所） 设计学院