

华中科技大学

研究生（文献阅读与选题）报告

☐文献阅读、☐选题、☐文献阅读与选题、☐论文中期进展

题目：面向 AI 智能体运行问题分析的证据呈现与交互设计研究

学号 M202570493

姓名 陈思静

专业 设计学

指导教师 何心

院（系、所） 设计学院

填表注意事项

- 一、本表适用于攻读硕士、博士学位研究生文献阅读报告、选题报告、文献阅读与选题报告、论文中期进展报告。
- 二、以上各报告内容及要求由相关院（系、所）做具体要求。
- 三、以上各报告均须存入研究生个人学籍档案。
- 四、本表填写要求文句通顺、内容明确、字迹工整。
- 五、A4 纸正反打印

目 录

文献阅读卡	1
1 文献综述	42
1.1 AI 智能体运行问题分析的研究基础	(42)
1.2 开发者故障分析的信息行为与认知基础	(44)
1.3 运行证据的组织与交互呈现	(47)
1.4 AI 智能体可观测与交互调试研究	(49)
1.5 证据呈现的设计研究与评价方法	(52)
1.6 国内外研究进展与本研究定位	(53)
1.7 本章小结	(54)
2 选题报告	56
2.1 研究背景	(56)
2.2 研究目的与意义	(57)
2.3 国内外研究现状	(58)
2.4 研究问题	(59)
2.5 研究内容与技术路线	(59)
2.6 研究材料与案例构建	(62)
2.7 评价指标与分析方法	(63)
2.8 研究框架	(65)
2.9 可行性、风险与伦理	(66)
2.10 进度安排	(67)
2.11 预期成果与创新点	(68)
参考文献	68

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：01

名称 Results-Actionability Gap: Understanding How Practitioners Evaluate LLM Products in the Wild

作者 Willem van der Maden; Malak Sadek; Ziang Xiao; Aske Mottelson; Q. Vera Liao; Jichen Zhu 译者

出处【美国】Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems, 2026: 1-17 页

文献阅读心得（每篇不少于 150 字）：

研究背景 大语言模型（large language model, LLM）产品的评价对象不是孤立模型，而是包含提示词、检索、界面与业务流程的完整系统。传统基准分数很难直接回答产品团队下一步应改什么，实践者因此在不确定性、资源限制和多方目标之间组织评价工作。

研究问题 研究问题一（RQ1）：生产环境中的大语言模型产品目前采用哪些评价实践？

研究问题二（RQ2）：实践者认为评价大语言模型产品时最主要的困难是什么？

研究方法 作者对 19 名跨行业大语言模型产品实践者开展半结构化访谈，并进行主题分析。研究覆盖评价执行、评价方案设计及组织层面的协调工作，分析对象是面向真实用户的完整产品。

主要发现 研究归纳出 10 类评价活动和 5 类挑战。17 名参与者经历了“结果—可行动性鸿沟”：团队能收集反馈或分数，却难以判断失败来自提示、检索、模型还是其他部件。人工判断与“直觉检查”（vibe check）被视为对大语言模型特性的适应，而不只是方法不成熟。

贡献与意义 论文提出“规范化历程”（formalization journey）和“结果—可行动性鸿沟”（results-actionability gap），把评价后的定位、协商与改进纳入评价研究，并从较成熟团队中总结了可实施的组织与流程策略。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：02

名称 Interactive Debugging and Steering of Multi-Agent AI Systems

作者 Will Epperson; Gagan Bansal; Victor Dibia; Adam Fournery; Jack Gerrits; Erkang Zhu; Saleema Amershi 译者

出处【美国】Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems, 2025: 156:1-156:15 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体（multi-agent）系统会产生数十甚至上百条消息，错误可能在早期计划、角色分工或工具调用中出现，并沿后续协作传播。现有开发工具多支持事后阅读日志，缺少暂停、回退和试改轨迹的交互能力。

研究问题 研究问题一（RQ1）：开发者在构建和调试多智能体工作流时面临哪些核心困难？

研究问题二（RQ2）：消息级浏览、编辑与重置如何支持故障诊断和智能体引导（agent steering）？

研究方法 研究先访谈 5 名智能体开发者，据此设计交互调试工具 AGDebugger；随后开展含 14 名参与者的两阶段用户研究。第一阶段比较 AGDebugger 与基线日志界面的错误识别，第二阶段让参与者编辑历史消息并重新运行。

主要发现 参与者通常花约 10 分钟阅读日志后才开始修改。5/6 的第一阶段参与者偏好 AGDebugger；第二阶段 8 人共做 24 次编辑，其中 14 次是补充具体指令，另有简化指令和修改计划。重置与编辑功能评分最高，但只有 2/8 得到完全正确答案。

贡献与意义 AGDebugger 把历史概览、逐条消息检查、回退、编辑与继续执行放进同一界面，使开发者能够用反事实式试验观察某次干预是否改变后续轨迹。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：03

名称 Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems

作者 Shaokun Zhang; Ming Yin; Jieyu Zhang; Jiale Liu; Zhiguang Han; Jingyang Zhang; Beibin Li; Chi Wang; Huazheng Wang; Yiran Chen; Qingyun Wu 译者

出处【美国】Proceedings of Machine Learning Research, 2025, 267: 76583-76599 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体任务失败时，最后输出错误的智能体不一定是决定结果的源头。有效调试需要同时定位责任智能体和关键步骤，但长轨迹、角色交互和错误传播使人工归因成本很高。

研究问题 研究问题一（RQ1）：能否自动识别导致任务失败的智能体，即回答“谁”造成失败？

研究问题二（RQ2）：能否定位该智能体产生决定性错误的具体步骤，即回答“何时”出错？

研究方法 作者将修正某个“智能体一时间”对后能否把失败变为成功作为决定性错误的反事实定义，并以最早的决定性错误为标注目标。Who&When 数据集包含 127 个多智能体系统、184 个失败归因任务，比较一次性分析（all-at-once）、二分搜索（binary search）和逐步分析（step-by-step）三类方法。

主要发现 最佳方法的智能体级准确率为 53.5%，步骤级准确率仅 14.2%，部分方法低于随机基线；包括先进推理模型在内的方法仍未达到实用水平。自动判断“谁”已有有限信号，而精确判断“何时”更困难。

贡献与意义 论文首次系统形式化多智能体自动故障归因，提供同时含责任智能体、决定性步骤和自然语言原因的细粒度数据集，并把智能体级与步骤级能力分开评价。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：04

名称 Finding AI's Faults with AAR/AI: An Empirical Study

作者 Roli Khanna; Jonathan Dodge; Andrew Anderson; Rupika Dikkala; Jed Irvine; Zeyad Shureih; Kin-Ho Lam; Caleb R. Matthews; Zhengxian Lin; Minsuk Kahng; Alan Fern; Margaret Burnett 译者

出处【美国】ACM Transactions on Interactive Intelligent Systems, 2022, 12(1): 1:1-1:33 页

文献阅读心得（每篇不少于 150 字）：

研究背景 总体成败或平均性能无法告诉领域用户人工智能究竟在哪些情境下不可靠。要决定何时依赖智能体，用户需要把问题定位到具体决策和内部预测，而不只是给出笼统的通过或失败判断。

研究问题 研究问题一（RQ1）：人工智能行动后复盘流程（After-Action Review for AI, AAR/AI）能否帮助具备领域知识的用户定位人工智能故障？

研究问题二（RQ2）：故障类型不同，用户发现故障的效果是否也不同？

研究方法 65 名有即时战略游戏经验但无人工智能或机器学习背景的参与者被随机分到复盘组和对照组，分析强化学习智能体完成《星际争霸 II》拉锯战任务的过程。研究用 10 个经验证的自然故障实例计算问题报告的召回率和精确率。

主要发现 AAR/AI 组召回率为 0.233，对照组为 0.080；精确率分别为 0.179 和 0.116，差异均显著。AAR/AI 参与者在每类故障上表现更好，发现任一特定故障的可能性平均接近对照组的 6 倍。

贡献与意义 论文用可核对的故障真值、召回率和精确率评价人类诊断，而非只测满意度；结构化复盘和标签活动还可能帮助用户从单个实例上升到故障类别。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：05

名称 Debugging Reinvented: Asking and Answering Why and Why Not Questions about Program Behavior

作者 Andrew J. Ko; Brad A. Myers 译者

出处 【美国】Proceedings of the 30th International Conference on Software Engineering, 2008: 301-310 页

文献阅读心得（每篇不少于 150 字）：

研究背景 开发者观察到异常输出后，传统调试器仍要求他们先猜测相关代码，再用断点和单步执行验证。由于初始猜测经常错误，问题表述与工具操作之间的转换会产生大量无关搜索。

研究问题 研究问题一（RQ1）：如何从程序代码和一次执行中自动提取用户可能提出的“为什么”与“为什么没有”（why and why-not）问题？

研究问题二（RQ2）：如何用静态、动态分析回答这些问题，并把答案映射到相关运行事件和代码？

研究方法 论文给出 Java Whyline 的系统设计与算法：记录完整执行历史，从文本和图形输出生成问题，结合动态切片、静态切片、调用图、可达性分析和值来源分析构造因果解释，并讨论性能与覆盖限制。

主要发现 “为什么发生”可沿已执行依赖回溯；“为什么没有发生”必须分析潜在定义、未满足条件与未到达路径，计算和问题空间更复杂。原型证明可以从可见输出进入相关代码，而无需先猜故障位置。

贡献与意义 文章把调试问题作为一等交互对象，并提出面向大型 Java 程序自动生成、筛选和回答“为什么”与“为什么没有”问题的完整技术架构。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：06

名称 Designing the Whyline: A Debugging Interface for Asking Questions about Program Behavior

作者 Andrew J. Ko; Brad A. Myers 译者

出处 【美国】 Proceedings of the 2004 ACM Conference on Human Factors in Computing Systems, 2004: 151-158 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试本质上从对运行行为的疑问开始，但断点、单步和打印语句迫使程序员先定位代码。Whyline 尝试让用户直接针对输出提问，再由系统呈现与该问题有关的运行时因果链。

研究问题 研究问题一（RQ1）：用户是否认为基于“为什么”与“为什么没有”提问的 Whyline 有用？

研究问题二（RQ2）：Whyline 能否缩短调试时间并帮助程序员完成更多任务？

研究方法 作者在 Alice 编程环境中实现 Whyline，并对既有无 Whyline 研究和新增有 Whyline 研究中的相同场景进行比较。无工具组 4 人、有工具组 5 人，在 90 分钟内完成 6 项 Pac-Man 编程任务并出声思考。

主要发现 在 6 个可比调试场景中，Whyline 把调试时间平均缩短 7.8 倍；有工具组平均完成 3.20 项任务，无工具组为 2.25 项，提升约 40%。19/24 次提问中工具被认为有用，“为什么没有”问题又明显多于“为什么”问题。

贡献与意义 Whyline 把可见程序输出转成问题菜单，并用时间游标、因果箭头和可逆历史把现象、运行事件与代码连接起来，改变了从代码位置开始的调试顺序。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：07

名称 Finding Causes of Program Output with the Java Whyline

作者 Andrew J. Ko; Brad A. Myers 译者

出处 【美国】Proceedings of the 27th ACM Conference on Human Factors in Computing Systems, 2009: 1569-1578 页

文献阅读心得（每篇不少于 150 字）：

研究背景 大型 Java 程序中，断点调试要求开发者先选对代码位置，而用户通常更容易识别界面中出现或缺失的输出。Java Whyline 把“从结果反查原因”的思路扩展到真实开源项目。

研究问题 研究问题一（RQ1）：Java Whyline 是否比断点调试器更快、更成功地帮助开发者定位真实缺陷？

研究问题二（RQ2）：两种工具如何改变开发者浏览文件、使用问题和接近关键函数的路径？

研究方法 研究采用组间实验，两组各 10 名软件工程硕士生，分别使用 Whyline 或具有相同外观的断点调试器，诊断 ArgoUML 的两个真实缺陷。每项任务限时 30 分钟，并记录成功率、时间、文件访问和导航距离。

主要发现 任务 1 中 Whyline 组 10/10 成功，对照组 3/10，且前者约快 2 倍；任务 2 中分别为 4/10 和 0/10。总体上 Whyline 用户约有 3 倍成功率，并更快接近关键代码；但工具更善于找到故障方法，不一定能解释方法为何错误。

贡献与意义 研究把输出选择、执行录像、依赖可视化、书签与问题导航集成为可实证比较的调试界面，并使用真实大型项目而非人工小程序。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：08

名称 How Programmers Debug, Revisited: An Information Foraging Theory Perspective

作者 Joseph Lawrance; Christopher Bogart; Margaret Burnett; Rachel Bellamy; Kyle Rector; Scott D. Fleming 译者

出处 【美国】IEEE Transactions on Software Engineering, 2013, 39(2): 197-215 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试大型代码库时，程序员不断判断下一条线索是否值得追踪。仅用“提出并验证假设”描述这一过程，很难解释他们在文件、方法和调用关系之间的实际导航，也难为工具设计提供直接建议。

研究问题 研究问题一（RQ1）：专业程序员调试时的语言和导航是否主要体现信息气味追踪，而非显式假设？

研究问题二（RQ2）：信息气味与代码拓扑模型能否预测程序员下一步会访问哪里？

研究方法 作者提出基于信息觅食理论的调试模型，并观察 10 名专业程序员调试真实开源程序，分析出声思考与导航日志；随后构建可执行模型，与不考虑信息气味的替代模型比较预测能力。

主要发现 参与者的言语更多涉及寻找和比较线索，而不是陈述完整假设。错误信息、标识符、文件名和调用关系形成信息气味；纳入气味的模型更准确地预测导航，代码拓扑则决定线索间移动成本。

贡献与意义 论文以信息气味（scent）和代码拓扑（topology）两个可观测、可计算的构念解释调试导航，减少对难以直接测量的心理假设的依赖，并把理论转成可执行预测模型。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：09

名称 Mental Procedures in Real-Life Tasks: A Case Study of Electronic Trouble Shooting

作者 Jens Rasmussen; A. Jensen 译者

出处 【英国】Ergonomics, 1974, 17(3): 293-307 页

文献阅读心得（每篇不少于 150 字）：

研究背景 熟练维修人员面对电子设备故障时，不会穷举所有测量，而是在系统、功能单元和部件组成的层级结构中搜索。真实工作还要求兼顾诊断时间、认知负荷和测量成本。

研究问题 研究问题一（RQ1）：熟练电子维修人员如何把设备表示为层级系统并组织故障搜索？

研究问题二（RQ2）：不同搜索例程在观察数量、知识深度和心理加工复杂度上有什么差异？

研究方法 研究在维修人员的正常工作环境中收集口述协议，对真实电子排故过程进行细致编码，分析症状判断、层级切换、测量选择及反复出现的搜索例程。

主要发现 排故可分解为多种循环搜索例程，分别依赖不同深度的内部机理知识。维修人员偏好快速连续的好/坏判断，即使某些观察在信息论上冗余；若目标是减少时间和心理负担，这种做法仍然合理。

贡献与意义 论文较早把真实排故中的认知过程描述为层级系统上的搜索，并揭示“信息最省”与“时间、心智成本最优”并不相同。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：10

名称 Making Sense of Sensemaking 1: Alternative Perspectives

作者 Gary Klein; Brian Moon; Robert R. Hoffman 译者

出处 【美国】IEEE Intelligent Systems, 2006, 21(4): 70-73 页

文献阅读心得（每篇不少于 150 字）：

研究背景 意义建构（sensemaking）在心理学、组织研究、自然情境决策和人机交互（human-computer interaction, HCI）中有多种含义。复杂任务中的理解不是对信息做一次摘要，而是持续寻找联系、解释意外并为下一步行动建立可用认识。

研究问题 研究问题一（RQ1）：不同研究传统如何界定意义建构，它与理解、情境意识等概念有何关系？

研究问题二（RQ2）：哪种定义能解释人在不确定环境中为了预测和行动而持续组织联系？

研究方法 本文是概念综述与立场论文。作者比较多个学科的定义和代表性案例，讨论意义建构的触发条件、目的与分析尺度，并为后续宏认知模型建立概念边界。

主要发现 作者强调意义建构是一种有动机、持续的努力：理解人、地点和事件之间的联系，以预测其发展并有效行动。它常由惊讶、冲突或知识缺口触发，结果是可行动的解释，而非静态信息表征。

贡献与意义 论文跨学科澄清了意义建构的不同视角，把“联系—预测—行动”作为共同核心，为研究真实复杂工作中的理解活动提供了统一入口。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：11

名称 Making Sense of Sensemaking 2: A Macrocognitive Model

作者 Gary Klein; Brian Moon; Robert R. Hoffman 译者

出处 【美国】IEEE Intelligent Systems, 2006, 21(5): 88-92 页

文献阅读心得（每篇不少于 150 字）：

研究背景 人在不确定任务中会借助已有框架筛选数据，数据又可能迫使框架改变。把意义建构理解成固定步骤，会忽略专家在解释、注意分配、反馈和行动之间的往返。

研究问题 研究问题一（RQ1）：数据与解释框架如何相互依存并推动意义建构？

研究问题二（RQ2）：人何时会扩展、质疑、比较、保留或重构当前框架？

研究方法 作者基于自然情境决策研究提出数据—框架（Data/Frame）宏认知模型，并用因果推理、假设承诺、反馈学习、专家差异和确认偏差等经验研究检验模型含义。

主要发现 框架管理注意并定义、连接和过滤数据；异常与不一致可触发质疑或重构。过早形成框架并非必然有害，适度承诺能产生可检验预期；过程反馈通常比只告知成败的结果反馈更有助于改进。

贡献与意义 论文以双向的数据—框架循环替代线性“先收集数据、后得出解释”，并提出连接、扩展、质疑、比较、重构和寻找框架等可观察活动。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：12

名称 A Data-Frame Theory of Sensemaking

作者 Gary Klein; Jennifer K. Phillips; Erica L. Rall; Deborah A. Peluso 译者

出处 【美国】Expertise Out of Context, Mahwah, NJ: Lawrence Erlbaum Associates, 2007: 113-155 页

文献阅读心得（每篇不少于 150 字）：

研究背景 传统微观认知研究多解释人如何理解单词、句子等简单刺激，难以覆盖真实工作中对模糊、矛盾、动态信息形成可行动理解的过程。数据—框架理论（Data-Frame theory）由此转向自然情境中的宏观意义建构。

研究问题 研究问题一（RQ1）：数据如何被框架选择和解释，框架又如何由少量关键锚点被识别或建构？

研究问题二（RQ2）：当数据与框架不一致时，意义建构有哪些可能形式与转换路径？

研究方法 本章综合自然情境决策、专业知识和问题解决研究，借助真实事件材料提出 9 条理论命题，并系统描述连接数据与框架、扩展、质疑、保留、比较、重构和寻找新框架等活动。

主要发现 数据不是完全中性的输入，而是在框架中被辨认和赋义；框架也由关键线索推断。意义建构通常在二者达到足够一致时停止，并服务于“接下来做什么”的功能性理解。专家与新手主要差在可调用框架的丰富度。

贡献与意义 理论同时说明数据驱动和框架驱动过程，明确列出多种非线性活动及其触发关系，可用于分析解释如何被建立、维护和推翻。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：13

名称 AgentGUI: An Interface for Observing and Steering Long-Running AI Agents

作者 Xuan Zhao; Jiwoong Sohn; Qinyue Zheng; Michael Moor 译者

出处 【瑞士】arXiv preprint arXiv:2607.26300, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 长时运行的智能体可同时执行多个任务，但人类监督仍依赖终端输出和分散日志。用户需要在不中断整体工作的情况下掌握轨迹、产物、成本和偏移，并在必要时实施人工或自动纠偏。

研究问题 研究问题一（RQ1）：统一的轨迹可视化能否提高用户理解长时智能体执行的速度和准确性？

研究问题二（RQ2）：人工与自动的管理者式引导（steering）能否在任务漂移时改善最终完成率？

研究方法 系统整合多会话轨迹、工作区快照、人工输入和自动管理模块。8 名硕博参与者在被试内、顺序平衡实验中比较 AgentGUI 与 Hermes 仪表盘（Hermes Dashboard）；另对多种模型各运行 50 次以测试自动纠偏。

主要发现 参与者用 AgentGUI 回答轨迹问题平均快 38%（90 秒对 145 秒， $p = .023$ ），准确率为 93% 对 80%（ $p = .031$ ），且没有速度—准确率交换；自动管理模块在部分模型上将完成率提高最多 34 个百分点。

贡献与意义 论文把并行会话、轨迹理解、工作区产物、人工指令和自动审计放进同一桌面式界面，并用客观理解速度、准确率和 workload 评价可观测性。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：14

名称 An Exploratory Study of How Developers Seek, Relate, and Collect Relevant Information during Software Maintenance Tasks

作者 Amy J. Ko; Brad A. Myers; Michael J. Coblenz; Htet Htet Aung 译者

出处 【美国】IEEE Transactions on Software Engineering, 2006, 32(12): 971-987, DOI: 10.1109/TSE.2006.116 页

文献阅读心得（每篇不少于 150 字）：

研究背景 软件维护不仅需要读懂局部代码，还要在多文件、多工具和多任务之间寻找、关联并暂存相关信息。现代集成开发环境（integrated development environment, IDE）的导航机制可能既提供线索，也制造误导与重复切换。

研究问题 研究问题一（RQ1）：开发者在维护任务中如何搜索、关联和收集相关代码与运行信息？

研究问题二（RQ2）：集成开发环境的线索、依赖导航和交互状态如何支持或妨碍这些活动？

研究方法 研究从 31 名 Java 开发者中选取经验最高的 10 名，要求其在 70 分钟内完成同一 503 行 Java Paint 程序的 5 个维护任务，并接受定时中断。作者逐帧分析屏幕录像、语音和交互日志。

主要发现 开发者平均 35% 的有效时间用于源文件内外的导航，许多跳转是重复且本可避免的；失败搜索常由误导性信息气味开始。记忆不可靠、纸笔缓慢、集成开发环境的交互状态易被后续任务覆盖，均难稳定保存任务上下文。

贡献与意义 论文提出“搜索—关联—收集”的程序理解模型，将信息觅食与集成开发环境的具体交互结合，并以真实多任务和中断条件揭示导航成本及外部记忆需求。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：15

名称 Debugging: An Analysis of Bug-Location Strategies

作者 Irvin R. Katz; John R. Anderson 译者

出处 【美国】Human-Computer Interaction, 1987-1988, 3(4): 351-399, DOI: 10.1207/S15327051HCI0304_2 页

文献阅读心得（每篇不少于 150 字）：

研究背景 具备语言知识的程序员往往能在看到错误行后修正它，真正困难的是从程序行为中定位哪一行有错。调试策略可能因代码归属、可用线索和搜索顺序而改变。

研究问题 研究问题一（RQ1）：熟悉表处理语言（LISP）的学生在定位程序错误时采用哪些策略，错误更接近知识缺陷还是偶发失误？

研究问题二（RQ2）：调试自己的程序与他人程序是否改变定位策略，策略又如何影响检查与修复？

研究方法 论文报告 4 项表处理语言调试实验，比较错误重复性、自然使用的定位策略、自编与他编程序情境，以及不同策略对被检查代码行和后续判断修复的影响。

主要发现 参与者的错误多为不易重复的 slip，通常一旦定位即可修复；他们会使用多种错误定位策略，且自编与他编程序的策略选择不同。策略主要改变搜索哪些代码行，对选中一行后的正确性判断和修复能力影响较小。

贡献与意义 研究把“找错位置”与“判断并修复错误”分解为不同阶段，并通过连续实验说明调试瓶颈并非总是缺少编程知识，而是搜索与定位。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：16

名称 Theory of Troubleshooting: The Developer's Cognitive Experience of Overcoming Confusion

作者 Arty Starr; Margaret-Anne Storey 译者

出处 【美国】ACM Transactions on Software Engineering and Methodology, 2026, DOI: 10.1145/3800945; arXiv:2602.10540 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试研究常聚焦工具和步骤，却较少解释开发者面对意外行为时的内部体验。长时间困惑会持续占用注意、工作记忆和心理模型构建资源，并可能转化为疲劳与项目可持续性风险。

研究问题 研究问题一（RQ1）：开发者在排查意外系统行为时，思考、感受和努力随时间如何变化？

研究问题二（RQ2）：困惑、经验直觉、试探性实验、进展与认知疲劳之间存在怎样的关系？

研究方法 作者访谈 27 名职业开发者，合计 570 年经验，并开展 7 次回访；采用建构主义扎根理论，从 681 条扎根编码形成 8 个核心理论类别，在前 12 份访谈后达到理论饱和，并以参与者反馈检验共鸣。

主要发现 排故从困惑体验启动，经验直觉引导策略，开发者通过“试一试、看结果”缩小解释空间；获得正或负知识都可被体验为进展。持续无进展会耗竭注意并引发补偿努力、盲视和疲劳，最终在“想通了”时解除。

贡献与意义 论文把排故定义为识别、理解并建立意外行为原因心理模型的认知过程，用连贯理论连接情绪、注意、实验、直觉和疲劳，而不只描述技术操作。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：17

名称 The Sensemaking Process and Leverage Points for Analyst Technology as Identified Through Cognitive Task Analysis

作者 Peter Pirolli; Stuart K. Card 译者

出处 【美国】 Proceedings of the 2005 International Conference on Intelligence Analysis, 2005 页

文献阅读心得（每篇不少于 150 字）：

研究背景 情报分析需要从大量异质材料形成结构、假设和可交付结论，但规范性流程很少说明专家真实工作中如何往返搜索、筛选、重组和验证证据。

研究问题 研究问题一（RQ1）：专家分析者如何在信息觅食与意义建构之间循环，将信息转化为模式、洞见和产品？

研究问题二（RQ2）：认知任务分析揭示了哪些可由交互技术降低成本的关键杠杆点？

研究方法 作者采用认知任务分析、分析者访谈和出声思考协议，结合专家图式与信息觅食理论，构建从外部数据源到证据文件、图式、假设和最终报告的双环模型。

主要发现 分析并非线性阅读，而是在探索、富集、利用与表示重构之间机会主义往返；常见外部结构包括资料箱（shoebox）、证据文件（evidence file）和图式（schema）。高成本环节集中在搜索、筛选、重新表示、比较假设和组装证据。

贡献与意义 论文将信息觅食循环（foraging loop）与意义建构循环（sensemaking loop）连接起来，并从每个转换的时间和注意成本推导工具设计杠杆，为总览—筛选—证据—假设界面提供理论基础。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：18

名称 AgentStepper: Interactive Debugging of Software Development Agents

作者 Robert Hutter; Michael Pradel 译者

出处 【德国】arXiv preprint arXiv:2602.06593, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 软件开发智能体会在模型请求、工具调用和代码修改之间形成长轨迹。原始日志虽然保留了大量信息，却缺少适合开发者理解高层行为的结构，也不能像传统调试器那样暂停、单步和检查中间状态。

研究问题 研究问题一（RQ1）：将传统调试中的断点、单步执行和状态检查提升到智能体动作层，能否帮助开发者理解智能体轨迹？

研究问题二（RQ2）：AgentStepper 接入现有软件开发智能体需要多少改动，它是否改善轨迹理解、智能体程序缺陷识别和主观负荷？

研究方法 作者把 AgentStepper 接入 ExecutionAgent、SWE-Agent 和 RepairAgent，统计集成改动量；随后邀请 12 名参与者完成一项轨迹理解任务和两项智能体调试任务，比较 AgentStepper 与自行选择的常规日志工具。

主要发现 三种智能体各需插入 5—7 个应用程序编程接口（application programming interface, API）调用并修改 39—42 行代码。AgentStepper 条件下轨迹理解平均表现由 64% 升至 67%，智能体程序缺陷识别成功率由 17% 升至 60%，挫败感由 5.4/7 降至 2.4/7。

贡献与意义 论文把智能体轨迹表示为“模型—智能体程序”和“智能体程序—工具”两条交织会话，并整合总览、细节、代码变更和断点控制。它是本研究原型最直接的人侧调试先例，也说明“理解轨迹”和“定位运行框架实现缺陷”应分开测量。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：19

名称 AgentSight: System-Level Observability for AI Agents Using eBPF

作者 Yusheng Zheng; Yanpeng Hu; Tong Yu; Andi Quinn 译者

出处 【美国】arXiv preprint arXiv:2508.02736, 2025 页

文献阅读心得（每篇不少于 150 字）：

研究背景 智能体的高层意图存在于模型提示和响应中，实际效果却表现为进程、文件和网络事件。现有工具通常只能看到其中一侧，导致开发者无法判断某个系统行为是否由智能体意图、工具实现或外部环境造成。

研究问题 研究问题一（RQ1）：能否在不修改智能体框架代码的情况下关联模型层语义意图与系统层实际行为？

研究问题二（RQ2）：这种跨层观测能否以可接受的开销识别安全攻击、低效循环和多智能体协调问题？

研究方法 作者提出边界追踪（boundary tracing），利用扩展伯克利包过滤器（extended Berkeley Packet Filter, eBPF）监视内核事件，同时截获传输层安全协议（Transport Layer Security, TLS）加密的模型流量以提取语义意图，再通过实时关联引擎和辅助大语言模型跨进程连接两类事件，并在多种攻击和故障场景中评估。

主要发现 AgentSight 能够检测提示注入、识别浪费资源的推理循环并发现隐藏的多智能体协调瓶颈，运行开销低于 3%。研究也表明，系统级事实和语义解释来自不同观测通道。

贡献与意义 论文具体展示了跨层证据如何被关联，并揭示“直接记录的系统事件”和“经过模型分析得到的语义关系”不能混为同一种证据。它为本研究原型的记录、推导和未知三类证据状态提供了技术边界。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：20

名称 From Failed Trajectories to Reliable LLM Agents: Diagnosing and Repairing Harness Flaws

作者 Mengzhuo Chen; Junjie Wang; Zhe Liu; Yawen Wang; Haiming Zheng; Qing Wang 译者

出处 【中国】arXiv preprint arXiv:2606.06324v2, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 智能体失败往往由执行环境、工具、上下文、生命周期、可观测、验证或治理机制共同塑造。仅依据最终成败调整提示词，难以确定失败证据位于哪一步，也难以把运行现象映射到具体运行框架工件。

研究问题 研究问题一（RQ1）：如何把碎片化运行轨迹编译成能够表达步骤级数据流、控制流和运行框架实现锚点的统一表示？

研究问题二（RQ2）：基于该表示形成的局部诊断和范围化修复，能否在不引入不可接受回归的情况下改善智能体表现？

研究方法 HarnessFix 将原始轨迹与运行框架工件编译为面向运行框架的轨迹中间表示（Harness-aware Trace Intermediate Representation, HTIR），定位责任步骤和实现工件，把重复诊断合并为缺陷记录，再按缺陷类型生成补丁并做回归约束验证；实验覆盖四个公开基准。

主要发现 相较初始运行框架，HarnessFix 在四个基准上的性能提高 6.3 至 18.4 个百分点，并优于人工设计和自演化基线。结果显示，失败轨迹可被组织成指向具体运行框架机制的结构化证据。

贡献与意义 论文证明数据流、控制流和实现锚点可以同时进入面向运行框架的轨迹表示，是与本研究原型最接近的技术工作。其自动修复不是本研究的目标，但 HTIR 所物化的关联类型构成了人侧理解界面的关键比较对象。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：21

名称 Agentic Harness Engineering: Observability-Driven Automatic Evolution of Coding-Agent Harnesses

作者 Jiahang Lin; Shichun Liu; Chengjun Pan; Lizhi Lin; Shihan Dou; Zhiheng Xi; Xuanjing Huang; Hang Yan; Zhenhua Han; Tao Gui; Yu-Gang Jiang 译者

出处 【中国】arXiv preprint arXiv:2604.25850v4, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 智能体运行框架包含工具、中间件、长期记忆、系统提示和运行规则，修改空间异构，轨迹规模巨大，而且一次修改与下一轮结果之间的关系难以归因。自动演化若缺少可观测证据，容易退化为试错。

研究问题 研究问题一（RQ1）：组件、运行经验和修改决策需要怎样的可观测表示，才能形成可验证的运行框架演化闭环？

研究问题二（RQ2）：可观测性驱动自动演化能否提高编码智能体性能，并跨模型迁移而非只适配单一基准？

研究方法 作者提出组件可观测、经验可观测和决策可观测三支柱，在 Terminal-Bench 2 上执行 10 轮运行框架演化，并通过消融和跨模型、跨基准迁移检验各类组件修改的作用。

主要发现 Terminal-Bench 2 的单次通过率（pass@1）由 69.7% 升至 77.0%；冻结后的运行框架在其他模型家族上带来 5.1—10.1 个百分点提升，并以比种子运行框架少 12% 的词元（token）取得 SWE-bench Verified 上的领先结果。增益主要来自工具、中间件和长期记忆，而非系统提示。

贡献与意义 论文把可观测性从日志采集提升为组件、经验和决策三个层次，并要求每次修改都有可证伪预测。它说明本研究不能只研究提示词，而应将上下文和工具等机制放入统一运行框架结构。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：22

名称 AgentLens: Visual Analysis for Agent Behaviors in LLM-Based Autonomous Systems

作者 Jiaying Lu; Bo Pan; Jieyi Chen; Yingchaojie Feng; Jingyuan Hu; Yuchen Peng; Wei Chen 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2025, 31(8): 4182-4197, DOI: 10.1109/TVCG.2024.3394053 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体自治系统产生大量随时间演化的事件、记忆和交互。线性日志难以呈现跨时间行为模式，也难以让用户从总体演化下钻到单个智能体行为及其可能原因。

研究问题 研究问题一（RQ1）：如何把原始执行事件组织成支持多粒度查看的智能体行为模型，并追踪行为之间的潜在因果关系？

研究问题二（RQ2）：层级时间视图、单智能体细节视图和环境监视视图能否支持用户发现并解释复杂行为？

研究方法 作者建立事件处理、行为摘要和原因追踪流程，开发包含概览（Outline）、智能体（Agent）和监视（Monitor）三类联动视图的 AgentLens，并通过两个使用场景和用户研究评价系统。

主要发现 参与者能够沿层级时间线发现行为模式、下钻检查事件，并回看可能影响当前行为的历史操作。系统有效性和可用性得到验证，但部分因果关系依据文本相似度推断，并非直接观测事实。

贡献与意义 论文提供总览—细节联动和原因追踪的成熟视觉设计，也暴露了本研究原型要解决的风险：界面若不说明连线来自日志、算法推断还是缺失信号，使用者可能把潜在关系理解为实际因果。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：23

名称 AgentGraph: Trace-to-Graph Platform for Interactive Analysis and Robustness Testing in Agentic AI Systems

作者 Zekun Wu; Seonglae Cho; Cristian Enrique Munoz Villalobos; Theo King; Umar Mohammed; Emre Kazim; Maria Perez-Ortiz; Sahan Bulathwela; Adriano Koshiyama
译者

出处 【美国】 Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(48): 41721-41723, DOI: 10.1609/aaai.v40i48.42393 页

文献阅读心得（每篇不少于 150 字）：

研究背景 现有智能体可观测平台多记录提示输入输出和运行指标，却仍要求用户手工从线性轨迹恢复任务、工具、数据和人员之间的结构关系。

研究问题 研究问题一（RQ1）：如何把智能体执行日志转换为带类型节点和边的交互知识图，并保持每个图元素可回到原始轨迹？

研究问题二（RQ2）：统一图表示能否同时支持故障分析、优化建议和扰动条件下的稳健性测试？

研究方法 AgentGraph 把智能体、任务、工具、数据输入输出和人建模为节点，用消费、委托、顺序、工具使用、输出交付和人工干预等类型边连接，并让每个元素指向精确轨迹片段（trace span）；系统还加入扰动和因果归因分析。

主要发现 原型能够在同一图中开展基于轨迹的定性故障分析和定量稳健性测试。论文属于演示轨道，主要证明系统能力，尚未提供充分的人类理解效果证据。

贡献与意义 论文将关系图与精确原始证据链接，是本研究原型“关联必须可核验”的直接先例；同时也说明系统功能展示不能替代对理解正确率、误判率和无证据结论的受控评估。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：24

名称 Graph of Trace: Visualizing Execution Traces of Scientific Agents

作者 Tianci Gao; Haoxuan Li; Jian He Li; Tianxiang Zhao; Shi Runze; Weiran Wang; Zezhao Wu; Lu Mi 译者

出处【美国】Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics: System Demonstrations, 2026:297-306, DOI: 10.18653/v1/2026.acl-demo.29 页

文献阅读心得（每篇不少于 150 字）：

研究背景 科学智能体可以自动执行环境配置、代码运行、数据分析和结论生成，但展开后的工作流难以供领域专家检查，限制了结果复核和后续人机协作。

研究问题 研究问题一（RQ1）：如何实时记录细粒度执行事件并把科学智能体工作流组织成可检查的有向图？

研究问题二（RQ2）：结构化轨迹图是否改善领域专家对工作流、失败位置和结果生成过程的理解？

研究方法 系统记录工具调用、代码执行和中间产物，由监视模块构建实时更新的有向图，并提供对话、图和节点细节检查器；作者在复杂科研任务上邀请人工智能、神经科学和生物学专家评价。

主要发现 专家认为结构化轨迹提高了工作流理解、感知可解释性和进一步分析交互的可用性。评价以专家反馈为主，尚未通过同证据基线比较理解准确率和无依据判断。

贡献与意义 论文提供与本研究原型相近的实时轨迹图和总览一节点细节结构，同时构成重要方法学对照：本研究需要把主观可用性扩展为具有客观真值（ground truth）的理解和证据判断实验。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：25

名称 AUTOGEN STUDIO: A No-Code Developer Tool for Building and Debugging Multi-Agent Systems

作者 Victor Dibia; Jingya Chen; Gagan Bansal; Suff Syed; Adam Fourney; Erkang Zhu; Chi Wang; Saleema Amershi 译者

出处 【美国】Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 2024: 72 - 79, DOI: 10.18653/v1/2024.emnlp-demo.8 页

文献阅读心得（每篇不少于 150 字）：

研究背景 多智能体 workflow 涉及模型、工具、角色和编排参数，直接通过代码配置和日志排查门槛较高。开发者需要同时查看系统声明结构和具体运行结果。

研究问题 研究问题一（RQ1）：声明式规范和无代码界面如何降低多智能体 workflow 构建、调试和评价的复杂度？

研究问题二（RQ2）：哪些界面原则能够让模型、工具、智能体和编排关系被复用并在运行中检查？

研究方法 作者基于 AutoGen 开发网页（Web）界面和 Python 应用程序编程接口，以 JavaScript 对象表示法（JavaScript Object Notation, JSON）声明智能体及 workflow，提供拖放式结构编辑、交互运行与调试、结果评估和可复用组件库，并通过系统案例说明设计。

主要发现 AutoGen Studio 把 workflow 结构、组件配置和运行查看统一到一个开发环境中，支持快速原型和非代码式调试。论文主要是系统演示，没有隔离不同呈现方式对理解正确率的影响。

贡献与意义 论文证明“声明结构”和“运行轨迹”可以在同一开发工具中组织，并提供可复用的智能体系统表达方式；本研究进一步关心静态声明与本次运行事实之间的证据差异。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：26

名称 AgentTrace: A Structured Logging Framework for Agent System Observability

作者 Adam AlSayyad; Kelvin Yuxiang Huang; Richik Pal 译者

出处 【美国】arXiv preprint arXiv:2602.10133, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 传统日志偏向操作事件，难以同时表达智能体的模型交互、环境动作和上下文状态。静态审计也难以应对由模型推断产生的非确定行为。

研究问题 研究问题一（RQ1）：智能体运行时日志应覆盖哪些观测面，才能支持调试、安全审计和责任追踪？

研究问题二（RQ2）：结构化日志能否在较少侵入智能体代码的情况下接入现有遥测基础设施？

研究方法 作者提出操作（operational）、认知（cognitive）和上下文（contextual）三类日志面，设计图式化（schema-based）运行时记录机制，并展示其与开放遥测框架（OpenTelemetry）等基础设施的集成方式。

主要发现 框架能够持续记录工具和环境动作、模型相关状态以及上下文信息，为实时监控和事后检查提供共同结构。论文以框架设计为主，尚未验证开发者如何理解这些日志。

贡献与意义 论文把上下文状态明确列为与操作和认知并列的观测面，直接支持本研究聚焦上下文构建与变换；同时提醒研究区分“记录结构完整”与“人能正确理解”两类贡献。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：27

名称 From Agent Traces to Trust: Evidence Tracing and Execution Provenance in LLM Agents

作者 Yiqi Wang; Jiaqi Zhang; Taotao Cai; Zirui Liu; Qingqiang Sun; Zequn Sun; Zhangkai Wu; Mingkai Zhang; Yanming Zhu 译者

出处 【中国】arXiv preprint arXiv:2606.04990, 2026 页

文献阅读心得（每篇不少于 150 字）：

研究背景 最终答案正确与否不能说明证据如何进入结论、工具调用是否合理、记忆怎样影响后续决策，也不能定位执行失败。相关工作分散在检索归因、工具安全、记忆、可观测和调试领域。

研究问题 研究问题一（RQ1）：大语言模型智能体中的证据单元、执行单元和溯源关系可以怎样统一分类？

研究问题二（RQ2）：现有方法在表示、粒度、时间、评价和信任功能上有哪些覆盖与缺口？

研究方法 作者开展系统性综述，从轨迹（trace）来源、证据与执行单元、溯源（provenance）关系、追踪粒度与时机、表示形式和信任功能建立统一分类，并映射数据集、基准和评价指标。

主要发现 现有研究能够追踪检索、工具、记忆和动作的部分来源，但缺少统一的轨迹图式（trace schema）、语义级溯源、真实执行基准和面向恢复的过程评价，隐私与审计基础设施也不成熟。

贡献与意义 论文直接把证据追踪与执行溯源连接起来，为本研究定义“关联证据”提供最新综述框架，也支持把评价从最终答案扩展到过程可核验性和证据边界。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：28

名称 LADYBUG: an LLM Agent DeBUGger for Data-Driven Applications

作者 Joel Rorseth; Parke Godfrey; Lukasz Golab; Divesh Srivastava; Jarek Szlichta
译者

出处 【荷兰】Proceedings of the 28th International Conference on Extending Database Technology, 2025: 1082-1085, DOI: 10.48786/EDBT.2025.94 页

文献阅读心得（每篇不少于 150 字）：

研究背景 数据驱动智能体常以多步工作流生成代码、转换数据并汇总结果。某一步的隐蔽错误可能不触发异常，却污染后续结果，用户需要检查中间输入输出并限定重新执行范围。

研究问题 研究问题一（RQ1）：交互式时间线能否支持用户检查智能体每一步的输入、输出和代码，并在任意步骤介入？

研究问题二（RQ2）：大语言模型辅助调试器如何在用户难以发现隐蔽错误时提出候选错误步骤和干预？

研究方法 作者实现 LADYBUG 演示系统，把智能体执行表示为按时间排列的步骤，允许用户查看中间状态、修改任意步骤并只重算受影响部分，同时加入基于自我反思的大语言模型辅助调试器。

主要发现 系统能在示例数据应用中定位并修正未直接报错的中间错误，并通过依赖关系减少重算范围。论文是演示短文，没有人类对照实验，也不能把大语言模型提出的原因视为已证实事实。

贡献与意义 论文展示了步骤、依赖和局部重算如何共同支持智能体调试。对本研究而言，其更重要的意义是区分可直接检查的步骤事实、系统计算的依赖关系和大语言模型提出的候选解释。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：29

名称 Open Agent Specification: Enabling Cross-Framework Comparison of AI Agents

作者 Soufiane Amini; Yassine Benajiba; Cesare Bernardis; Paul Cayet; et al. 译者

出处 【美国】Proceedings of the ACM Conference on AI and Agentic Systems, 2026: 404-418, DOI: 10.1145/3786335.3813130 页

文献阅读心得（每篇不少于 150 字）：

研究背景 不同智能体框架具有不同的提示处理、工具适配、编排和执行语义。即使智能体设计看似相同，运行时也可能产生不同路径和结果，导致跨框架比较缺少共同参照。

研究问题 研究问题一（RQ1）：如何用统一声明表示固定的智能体结构、数据流和控制流，并在不同运行时中生成可比执行？

研究问题二（RQ2）：相同智能体规范在不同框架中是否仍会出现准确率、时延和执行行为差异？

研究方法 作者提出框架无关的智能体规范（Agent Specification）及标准化评估运行框架，在 LangGraph、CrewAI、AutoGen 和 WayFlow 四种运行时上执行 SimpleQA Verified、 τ^2 -Bench 和 BIRD-SQL 三个基准，并记录统一结构的运行轨迹（trace）。

主要发现 在共享规范下，不同运行时仍表现出显著的准确率、时延和执行差异，说明框架适配器、提示和编排实现会塑造运行行为，不能由静态规范直接推断。

贡献与意义 论文为结构与运行的对照提供了统一表示和跨框架证据，直接支撑本研究区分“预设结构”与“本次实际执行”；它也为构造相同任务、不同运行框架机制的实验材料提供方法。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：30

名称 X-Trace: A Pervasive Network Tracing Framework

作者 Rodrigo Fonseca; George Porter; Randy H. Katz; Scott Shenker; Ion Stoica 译者

出处 【美国】Proceedings of the 4th USENIX Symposium on Networked Systems Design and Implementation, 2007: 271-284 页

文献阅读心得（每篇不少于 150 字）：

研究背景 复杂网络服务跨越应用、协议和管理域，单层日志不能重建一次用户任务经过的完整路径。即使各组件都产生日志，也缺少将分散事件关联到同一任务的机制。

研究问题 研究问题一（RQ1）：如何在跨层、跨应用执行中传播统一任务标识并重建因果任务树？

研究问题二（RQ2）：该机制在 DNS、Web 和覆盖网络等异构系统中能否提供可用于诊断的端到端视图？

研究方法 X-Trace 在初始任务中注入元数据，并沿协议调用、转发和递归请求传播；各组件记录带共同任务标识的事件，系统据此重建任务树，并在 DNS、三层网站和覆盖网络场景中部署。

主要发现 跨组件任务树能把原本分散的日志连接起来并定位错误数据或异常路径；即使只在部分层部署，仍可提供局部诊断价值，但未被记录的分支不能被当作未发生。

贡献与意义 论文奠定了端到端执行溯源的任务树思想，说明可靠关联依赖显式传播的记录机制。它为本研究界定“直接记录”提供技术基础，也说明信号缺失应标为未知。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：31

名称 Pivot Tracing: Dynamic Causal Monitoring for Distributed Systems

作者 Jonathan Mace; Ryan Roelke; Rodrigo Fonseca 译者

出处 【美国】Proceedings of the 25th ACM Symposium on Operating Systems Principles, 2015: 378-393, DOI: 10.1145/2815400.2815415 页

文献阅读心得（每篇不少于 150 字）：

研究背景 分布式系统中的日志和指标通常预先定义且以单组件为中心，发生未知问题时，开发者难以在运行中提出新的跨组件问题，也难以关联不同位置的事件。

研究问题 研究问题一（RQ1）：能否动态定义监测查询，并在跨机器和跨组件事件之间保留因果关系？

研究问题二（RQ2）：动态因果监测能否以低开销定位软件缺陷、错误配置和性能退化等不同根因？

研究方法 作者结合动态插桩与先发生关系连接（happened-before join），使用户可在系统某处定义指标，却按其他组件中的因果先行事件选择、过滤和分组；原型在包含 HDFS、HBase、MapReduce 和 YARN 的 Hadoop 集群中评估。

主要发现 Pivot Tracing 能够跨层查询并定位软件错误、配置问题和慢硬件等多类根因，同时保持较低运行开销。它表明关系可以由明确的因果传播规则计算，而不一定逐条直接记录。

贡献与意义 论文为本研究的“按规则推导”提供清晰先例：关系有可检查规则和输入证据，但仍不同于原生日志事实。界面应把推导方法、覆盖范围和无法关联的事件一起呈现。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：32

名称 Dapper, a Large-Scale Distributed Systems Tracing Infrastructure

作者 Benjamin H. Sigelman; Luiz André Barroso; Mike Burrows; Pat Stephenson; Manoj Plakal; Donald Beaver; Saul Jaspan; Chandan Shanbhag 译者

出处 【美国】Google Technical Report dapper-2010-1, 2010 页

文献阅读心得（每篇不少于 150 字）：

研究背景 大规模互联网服务由不同团队、语言和机器上的组件组成。开发者需要理解一次请求跨组件的路径和耗时，但全面插桩会带来开发负担、运行开销与海量数据。

研究问题 研究问题一（RQ1）：如何在低开销、应用透明和大规模持续部署之间取得平衡，记录端到端请求轨迹？

研究问题二（RQ2）：采样式分布追踪是否能支持开发和运维团队理解系统行为并构建多种诊断工具？

研究方法 Dapper 在少量公共库中插桩，以追踪标识（trace）和跨度标识（span）记录请求层级及时间信息，通过采样控制开销；论文总结系统在 Google 内部两年多的构建、部署、使用和衍生工具经验。

主要发现 公共库插桩和采样使追踪能够在超大规模生产环境持续运行，并支持性能分析、依赖发现和异常诊断。但采样和未插桩区域意味着轨迹天然不完整。

贡献与意义 论文建立了现代分布式追踪的追踪/跨度标识基础，并揭示观测证据的覆盖边界。对本研究而言，界面必须避免把被采样或未插桩造成的空白解释成机制没有运行。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：33

名称 A Controlled Experiment for Program Comprehension through Trace Visualization

作者 Bas Cornelissen; Andy Zaidman; Arie van Deursen 译者

出处 【美国】IEEE Transactions on Software Engineering, 2011, 37(3): 341-355,
DOI: 10.1109/TSE.2010.47 页

文献阅读心得（每篇不少于 150 字）：

研究背景 执行轨迹可视化常被用于程序理解，但早期工具多依赖案例演示，缺少把可视化与常规开发环境直接比较的量化证据。

研究问题 研究问题一（RQ1）：大型执行轨迹可视化是否能提高典型程序理解任务的正确率？

研究问题二（RQ2）：在提供相同目标系统的情况下，可视化是否能减少完成理解任务所需的时间？

研究方法 作者设计 8 项面向代表性软件系统的程序理解任务，以 Eclipse 作为对照条件，以 Eclipse 加 Extravis 执行轨迹可视化作为实验条件，比较完成时间和答案正确性。

主要发现 使用轨迹可视化的实验组完成任务所需时间降低 22%，正确性提高 43%，两项差异均达到统计显著。研究证明结构化轨迹的价值可以用客观理解任务而非满意度评价。

贡献与意义 论文为本研究的三条件受控实验提供直接方法学依据：应保持任务和证据可比，测量理解正确率与时间，并把“可视化好看”与“实际理解更准确”区分开。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：34

名称 Debugging Strategies and Tactics in a Multi-Representation Software Environment

作者 Pablo Romero; Benedict du Boulay; Richard Cox; Rudi Lutz; Sallyann Bryant
译者

出处【英国】International Journal of Human-Computer Studies, 2007, 65(12): 992-1009, DOI: 10.1016/j.ijhcs.2007.07.005 页

文献阅读心得（每篇不少于 150 字）：

研究背景 调试环境同时提供代码、图形和运行输出时，用户不仅要理解每种表示，还要在表示之间切换和建立对应关系。表示越多并不自动带来更好表现。

研究问题 研究问题一（RQ1）：程序员如何把高层调试策略与低层界面操作结合，并在多种表示之间组织搜索？

研究问题二（RQ2）：编程经验、图形表示知识和呈现形式如何影响调试准确率及策略适应？

研究方法 研究观察不同经验水平的程序员在多表示软件环境中完成调试任务，结合任务表现和交互过程分析他们查看代码、图形和输出的时间、切换方式及策略变化。

主要发现 成功者更系统地把代码与输出对应起来，并能随呈现条件调整策略；经验较少者更频繁地在表示间切换，形成重复且低效的浏览模式。掌握外部表示规则与编程经验同样重要。

贡献与意义 论文说明本研究的结构图、轨迹和上下文视图必须有明确对应关系，不能只增加表示数量。评价还应观察跨视图跳转、回退和关系核验，而不只记录最终答案。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：35

名称 Are Automated Debugging Techniques Actually Helping Programmers?

作者 Chris Parnin; Alessandro Orso 译者

出处 【加拿大】Proceedings of the 20th International Symposium on Software Testing and Analysis, 2011: 199-209, DOI: 10.1145/2001420.2001445 页

文献阅读心得（每篇不少于 150 字）：

研究背景 自动故障定位常以错误语句排名为目标，并假设程序员只要看到正确位置就能理解和修复问题。然而真实调试还包含依赖导航、状态检查、重跑和根因理解。

研究问题 研究问题一（RQ1）：现有自动调试研究关于程序员如何使用故障排名的假设是否符合实际调试行为？

研究问题二（RQ2）：调试技术应如何评价，才能反映其是否真正帮助开发者理解根因并完成修复？

研究方法 作者分析自动调试和故障定位方法的常见假设，并通过面向开发者的调试任务考察排名信息如何被检查、解释和用于后续导航，进而反思只以错误位置排名评价工具的做法。

主要发现 程序员不会机械地逐项检查排名，也不能仅凭孤立语句理解根因；即使正确语句排名靠前，用户仍需控制流、数据流、状态和上下文证据才能判断。

贡献与意义 论文确立了“自动定位准确”不等于“人能够理解并行动”的方法学原则。本研究因此应直接测量人的事件—机制映射和证据定位，而不能用自动算法指标替代人侧实验。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：36

名称 Characterizing Provenance in Visualization and Data Analysis: An Organizational Framework of Provenance Types and Purposes

作者 Eric D. Ragan; Alex Endert; Jibonananda Sanyal; Jian Chen 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 31-40, DOI: 10.1109/TVCG.2015.2467551 页

文献阅读心得（每篇不少于 150 字）：

研究背景 可视分析中的溯源信息（provenance）既可指数据来源、系统操作历史，也可指分析者的推理和洞见。概念混用会导致系统记录了大量历史，却不能回答这些记录服务什么任务。

研究问题 研究问题一（RQ1）：可视化与数据分析中的溯源信息可按哪些信息类型和使用目的组织？

研究问题二（RQ2）：不同溯源信息类型应如何影响捕获方式、界面设计和评价方法选择？

研究方法 作者综合多个领域的溯源系统和研究，对记录对象、语义层次、捕获方式及使用目的进行交叉整理，提出组织框架，并讨论类型、目的和评估之间的关系。

主要发现 溯源信息不仅是操作日志，还包括数据、可视状态、分析步骤、推理和洞见等不同层次；回溯、复现、协作、审计和理解等目的需要不同信息，不能由单一历史记录满足。

贡献与意义 论文为本研究区分运行事实、界面推导和人的解释提供概念工具，也说明证据状态必须与具体关系和使用目的绑定，而不能只给整条轨迹一个统一可信度。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：37

名称 Analytic Provenance for Sensemaking: A Research Agenda

作者 Kai Xu; Simon Attfield; T. J. Jankun-Kelly; Ashley Wheat; Phong H. Nguyen; Nallini Selvaraj 译者

出处 【美国】IEEE Computer Graphics and Applications, 2015, 35(3): 56-64, DOI: 10.1109/MCG.2015.50 页

文献阅读心得（每篇不少于 150 字）：

研究背景 意义建构包含信息搜索、假设生成、证据比较和框架修正。若系统只保存点击而不保存分析步骤及其关系，就难以支持反思、恢复中断或追踪不确定性。

研究问题 研究问题一（RQ1）：分析过程中的数据、操作、子任务、假设和推理应以怎样的层级被捕获和呈现？

研究问题二（RQ2）：分析溯源（analytic provenance）如何支持意义建构、协作以及不确定性和信任管理？

研究方法 论文汇总电气电子工程师学会可视化会议（IEEE VIS）相关研讨会和既有研究，围绕溯源信息的捕获、可视化和利用提出研究议程，并用分层模型讨论从低层交互到高层任务语义的推断。

主要发现 低层事件容易自动记录，高层任务和意图难以可靠推断；溯源信息可支持过程反思、探索引导和质量追踪，但推断、隐私、规模化与不确定性传播仍是开放问题。

贡献与意义 论文直接连接溯源信息与数据—框架意义建构，支持本研究把“证据从哪里来、怎样进入结论”作为界面主结构，并要求对自动推断的高层语义显示不确定性。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：38

名称 Capturing and Supporting the Analysis Process

作者 Nazanin Kadivar; Victor Chen; Dustin Dunsmuir; Eric Lee; Cheryl Qian; John Dill; Christopher Shaw; Robert Woodbury 译者

出处 【美国】Proceedings of the IEEE Symposium on Visual Analytics Science and Technology, 2009: 131-138, DOI: 10.1109/VAST.2009.5333020 页

文献阅读心得（每篇不少于 150 字）：

研究背景 分析者会反复调整参数、返回旧状态并探索替代路径，但多数可视分析工具只保存当前结果，不能让人查看、恢复或理解分析过程本身。

研究问题 研究问题一（RQ1）：如何捕获并可视化分析者的交互历史、分支和结果依赖？

研究问题二（RQ2）：可编辑、可回放的分析历史能否支持过程理解、替代路径探索和分析模式复用？

研究方法 作者开发 CzSaw，把用户交互翻译为脚本，生成可编辑的历史视图和结果依赖图，并通过文档集合分析场景展示状态恢复、分支探索和分析流程复用。

主要发现 历史视图使用户能够查看分析进展和替代路径，依赖图则揭示每一步与后续结果之间的逻辑关系；脚本化记录还支持修改和重新执行分析步骤。

贡献与意义 论文提供了“时间历史 + 依赖关系”双重表示的经典先例，与本研究的轨迹和机制并列结构高度对应；它也提示两类视图应联动而非各自展示重复信息。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：39

名称 The Role of Uncertainty, Awareness, and Trust in Visual Analytics

作者 Dominik Sacha; Hansi Senaratne; Bum Chul Kwon; Geoffrey Ellis; Daniel A. Keim 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 240-249, DOI: 10.1109/TVCG.2015.2467591 页

文献阅读心得（每篇不少于 150 字）：

研究背景 可视分析系统从数据、模型到界面和人的解释都会引入或继承不确定性。若使用者看不到不确定性如何传播，就可能对结果形成过强或过弱的信任。

研究问题 研究问题一（RQ1）：不确定性如何在可视分析的数据处理、模型、可视化和人类推理之间传播？

研究问题二（RQ2）：不确定性意识如何影响证据搜索、验证循环和信任形成？

研究方法 作者整合可视分析、认知和信任研究，提出包含知识生成、探索、验证、不确定性传播与信任构建的概念模型，并通过分析场景说明各环节关系。

主要发现 不确定性会在系统组件中继承和累积，使用者的意识决定其是否继续寻找证据、质疑结果或采取行动；信任应建立在可检查证据和验证循环上，而非结果外观。

贡献与意义 论文为本研究的证据状态提供理论支撑：界面不仅要显示关系，还要让使用者意识到关系的证据强度与未知范围，从而减少由完整结构图诱发的过度确定。

华中科技大学设计学院硕士研究生

文献阅读卡

学号：M202570493

姓名：陈思静

序号：40

名称 Why Authors Don't Visualize Uncertainty

作者 Jessica Hullman 译者

出处【美国】IEEE Transactions on Visualization and Computer Graphics, 2020, 26(1): 130-139, DOI: 10.1109/TVCG.2019.2934287 页

文献阅读心得（每篇不少于 150 字）：

研究背景 尽管不确定性表达方法很多，公开可视化仍经常给出确定性的单一叙事。问题不仅是缺少图形技术，还包括作者对受众、说服力和信息复杂度的假设。

研究问题 研究问题一（RQ1）：经常制作可视化的作者为何承认不确定性重要，却仍选择不直接呈现？

研究问题二（RQ2）：哪些工作实践、态度和传播目标维持了不确定性省略的规范？

研究方法 研究调查 90 名经常为他人制作可视化的作者，并访谈 13 名有影响力的可视化设计者；作者据此归纳实践障碍和信念矛盾，提出不确定性省略的修辞模型。

主要发现 作者普遍认可不确定性的价值，但担心它削弱清晰信息、增加受众负担或破坏叙事。现实中不确定性因此经常被省略，完整而确定的图形外观会掩盖推断自由度和证据边界。

贡献与意义 论文解释了为什么“证据状态应显示”并不会自然转化为界面实践。本研究需要验证三类状态怎样呈现才既不造成认知负担，也不让结构图以确定外观掩盖未知。

1 文献综述

大语言模型智能体（large language model agent，以下简称智能体）已由单轮问答系统发展为能够调用工具、访问外部环境、维护上下文并连续执行任务的复合系统。智能体的运行结果由基础模型与提示组织、上下文装配、工具接口、控制循环、状态管理和验证规则共同塑造。本文将这组支撑智能体运行的基础设施称为智能体运行框架（agent harness，以下简称运行框架）。当任务结果出现异常时，开发者需要追踪现象的形成过程、核对支持原因判断的运行记录，并识别现有记录无法回答的问题。

智能体工程（agent engineering）研究已经形成结构化日志、轨迹采集、失败分类、自动归因和运行重放等技术路径。这些技术扩大了可观测范围，也产生了新的交互设计问题：运行记录应如何组织，系统计算的关系应如何说明依据，证据不完整时应如何表达判断边界，以及开发者如何在多个可能原因之间进行比较。本章据此从系统运行评价、开发者故障分析、证据组织与交互呈现、智能体可观测工具及设计评价方法五个方面梳理相关研究。

1.1 AI 智能体运行问题分析的研究基础

1.1.1 从模型评价到系统运行评价

早期大语言模型研究多以准确率、胜率或基准任务得分衡量模型能力。在真实产品中，用户获得的结果还受到提示、检索、工具、界面、业务规则和协作流程影响。van der Maden 等人^[1]访谈了 19 名大语言模型产品实践者，其中 17 人遇到了“结果与可行动性鸿沟”：团队能够收集分数与反馈，却难以据此判断应修改哪个系统环节。Khanna 等人^[2]提出的人工智能行动后复盘方法（After-Action

Review for AI, AAR/AI) 将总体表现分解到具体决策和内部预测, 有助于用户识别已知故障, 但实验结果同时显示该方法仍存在误报。这些研究说明, 最终得分不能代替对系统运行过程的分析, 局部异常也不能直接写成确定根因。

运行框架研究进一步揭示了系统评价的层次性。Chen 等人^[3]将运行框架划分为执行环境与沙箱、工具接口、上下文与记忆、生命周期与编排、可观测、验证评估和治理安全等层次, 失败证据可能分散在多个位置。Lin 等人^[4]将系统提示、工具、中间件、技能、子智能体、长期记忆和配置视为可编辑的框架组件, 并强调组件变更应当可追踪、可比较和可回滚。Amini 等人^[5]在四种运行时上执行相同的智能体声明, 仍观察到准确率、延迟和执行行为的差异。因此, 智能体运行问题分析需要以实际执行记录为基础, 考察不同机制在具体运行中如何发挥作用。

1.1.2 运行轨迹、问题归因与证据边界

智能体执行轨迹 (execution trace) 通常包含模型请求与响应、工具调用与返回值、文件或环境变化、智能体间消息、重试和终止等事件。轨迹能够描述“发生了什么”, 原因判断还需要说明事件之间的关系以及关系成立的依据。Zhang 等人^[6]将多智能体故障归因分为责任智能体和责任步骤两个维度。在 127 个系统、184 个归因任务中, 最佳方法识别责任智能体的准确率为 53.5%, 定位具体步骤的准确率仅为 14.2%。自动归因因而适合提供候选调查范围, 其结果仍需由开发者结合原始记录进行核查。

运行框架修复工具 HarnessFix^[3]将原始轨迹与框架实现编译为面向运行框架的轨迹中间表示 (Harness-aware Trace Intermediate Representation, HTIR), 通过数据流、控制流和实现锚点将失败步骤映射到责任层次。智能体框架工程方法 AHE^[4]则利用组件可观测、经验可观测和决策可观测形成自动演化闭环。这些工作证明了轨迹与运行机制之间的关系可以被计算, 但面向人的界面还需要解释关系的来源、前提和适用范围。

本文将“运行证据”界定为能够支持开发者描述运行事实、提出原因解释或规划验证行动的信息，包括原始事件记录、跨步骤关系、系统生成的分析结果和信息缺失状态。证据呈现涉及信息层级、关系语义、来源追溯、判断状态和交互路径，其评价对象是开发者能否形成正确、充分且可复核的问题解释。

1.2 开发者故障分析的信息行为与认知基础

1.2.1 信息搜寻与层级排查

传统调试研究将故障定位与错误修复区分为相互关联但并不等同的任务。Katz 和 Anderson^[7]发现，程序员即使能够修复已指明位置的错误，也未必能根据异常行为顺利找到该位置。开发者需要在代码、运行状态、输出结果和外部文档之间持续移动，以局部线索逐步缩小问题范围。

Lawrance 等人^[8]运用信息觅食理论（information foraging theory）解释程序员的调试行为。开发者会依据错误消息、标识符、文件名和调用关系形成“信息气味”（information scent），并据此选择是否继续追踪当前路径。Ko 等人^[9]对软件维护活动的观察显示，参与者平均约有 35% 的有效时间用于导航、建立关系和收集信息。Rasmussen 和 Jensen^[10]对电子设备排故的研究则发现，熟练人员会在系统、功能单元和部件之间切换层级，同时权衡线索收益、测量成本和认知负担。以上结果表明，运行证据界面需要同时支持问题范围的逐步收缩和不同分析层级之间的连续转换。

1.2.2 问题导向的证据获取与多表征协调

Ko 和 Myers^[11-13]围绕“为什么发生”与“为什么没有发生”问题（why and why-not questions）开展了一系列研究。其为什么线索调试界面（Whyline）允许用户从可见行为提出问题，再查看相关运行事件和代码位置。实验显示，这种以问题组织执行信息的方式能够缩短部分故障定位时间，并提高参与者完成真实调

试任务的比例。其设计价值在于建立了问题、运行事件与实现位置之间的可追溯关系。

多表征环境中的关键困难是保持视图之间的语义对应。Romero 等人^[14]研究同时呈现代码、输出和图形表示的调试环境，发现用户表现取决于其能否理解外部表示，并在不同表示之间建立联系。Cornelissen 等人^[15]对执行轨迹可视化开展受控实验，在八项程序理解任务中，轨迹可视化组的用时减少 22%，答案正确性提高 43%。该结果支持结构化轨迹对程序理解的促进作用，也说明表征效果与任务类型、用户经验和视图协调成本有关。

1.2.3 解释框架的形成与更新

故障分析包含从观察现象到形成原因解释的认知转换。Klein 等人^[16-18]将意义建构（sensemaking）描述为分析者利用既有经验组织信息，并在新线索出现后持续调整解释的过程；其数据—框架理论（Data-Frame theory）进一步指出，数据既被当前框架选择和解释，也可能扩展、质疑或替换该框架。在智能体运行问题中，解释框架可能表现为对工具调用、上下文遗漏、状态覆盖或停止条件的原因假设；后续证据可能支持该假设，也可能要求开发者比较其他解释。

Pirolli 和 Card^[19]通过认知任务分析，将复杂分析划分为信息觅食循环和意义建构循环：前者负责搜索、筛选和整理材料，后者负责建立证据结构、生成假设并形成结论。Kadivar 等人^[20]开发的 CzSaw 可视分析系统记录分析历史、依赖关系和分支，允许分析者返回旧状态并探索替代路径。Xu 等人^[21]区分低层事件、分析动作、子任务和总体任务，并指出语义层级越高，系统越难仅依据交互日志可靠推断人的意图。运行问题分析工具因而需要区分机器可记录的操作与分析者主动形成的判断。

Starr 和 Storey^[22]根据 27 名开发者的访谈，将故障排查概括为困惑、试探、观察和恢复等过程，并指出困惑会占用注意与工作记忆。界面应帮助开发者保留当前问题、候选原因和已核对证据，使其在跨视图导航或分析中断后能够恢复判

断上下文。

1.2.4 心智模型、解释与适当依赖

可解释人工智能（explainable artificial intelligence, XAI）研究区分了系统生成解释与用户形成正确理解。Miller^[23]综合哲学、认知心理学和社会心理学研究，指出人类解释具有选择性、对比性和社会性，单向输出特征重要度并不必然改善理解。Abdul 等人^[24]对 289 篇论文及其引用网络的分析也表明，可解释、可问责与可理解系统需要算法研究与人机交互研究共同推进。

解释工具还会改变用户对系统能力的判断。Kaur 等人^[25]通过 11 名数据科学家的情境调查和 197 人问卷发现，专业用户同样可能误用或过度信任解释工具，并且难以准确说明部分可视化的含义。Sieker 等人^[26]的实验显示，解释提高了用户对系统能力的主观评价，却没有同步提高其识别系统局限的能力。Buçinca 等人^[27]研究的认知强制交互通过延迟建议、要求独立判断等方式降低了用户对错误人工智能建议的过度依赖，同时增加了交互成本。证据呈现的评价因此需要联合考察答案正确性、证据使用和信心水平，以判断使用者是否形成了适当依赖（appropriate reliance）。

多智能体界面中的心智模型还受到角色数量、交接关系和意见一致性的影响。Pareek 等人^[28]使用不同界面方案作为研究探针，发现用户会依据代理角色、任务转移和相互批评等线索判断系统可靠性。Kumar 等人^[29]对真实开发者—智能体协作的研究显示，持续检查、分阶段验证和主动干预仍是有效协作的重要组成部分。这些结果说明，结构线索和社会线索能够帮助理解，也可能在缺少实质证据时产生不恰当的可靠性感知。

1.3 运行证据的组织与交互呈现

1.3.1 多层级运行信息的结构化表征

智能体运行信息具有时间、组件、数据和控制等多个组织维度。时间线适合呈现事件顺序，调用树适合展示层级关系，数据流图适合追踪输入输出的传递，状态视图则用于比较运行前后的变化。单一表征难以覆盖全部分析任务，界面需要明确各种关系的语义，并在概览与原始记录之间保持稳定的定位方式。

Vicente 和 Rasmussen^[30]提出的生态界面设计（ecological interface design）强调，界面应呈现工作领域中具有约束作用的对象与关系，使操作者能够在非预设情境下理解系统状态并采取行动。应用于智能体运行分析，工作领域中的关键对象包括任务、模型请求、工具、上下文片段、状态对象和系统配置；关键关系则包括调用、传递、变换、覆盖和终止。该理论为运行证据的信息分层和关系表达提供了设计依据。

结构化表征仍需控制聚合带来的信息损失。轨迹概览能够缩小搜索范围，但压缩过程可能省略关键参数、异常返回值或消息边界。设计上需要保留由概览返回原始事件的路径，并说明聚合规则、覆盖范围和可能遗漏的信息。

1.3.2 证据关联与分析溯源

分布式追踪研究为跨步骤证据关联提供了成熟的数据结构。Fonseca 等人^[31]提出的跨层追踪系统 X-Trace 通过显式传播任务标识，将跨应用、协议和管理域的事件重建为任务树。Sigelman 等人^[32]提出的分布式追踪基础设施 Dapper 使用追踪标识（trace ID）和跨度标识（span ID）表示一次请求的分布式路径。Mace 等人^[33]提出的动态追踪方法 Pivot Tracing 依据先发生关系连接跨组件事件，并支持在运行过程中查询新的关系。这些工作说明，可靠关联依赖稳定标识、上下文传播和明确规则；采样、未插桩组件或标识传播中断都会留下信息空白。

可视分析领域将分析溯源（analytic provenance）扩展到人的分析过程。Ragan

等人^[34]将溯源信息区分为数据、可视化、交互、洞见和理由等类型，并强调记录对象应与使用目的相匹配。Xu 等人^[21]指出，从低层交互自动推断高层任务与意图存在语义不确定性，分析记录应支持回看、恢复、协作和质量检查。Kadivar 等人^[20]通过可编辑历史和结果依赖图呈现分析路径、分支与中间结果之间的联系。

面向智能体运行问题，证据溯源包含两个方向：其一，从原因判断返回原始事件，确认数据来源、生成条件和完整性；其二，从某一事件追踪其后续传播，判断该事件对最终结果的影响范围。交互界面需要保持两个方向的一致性，并记录系统生成关系所使用的输入和规则。

1.3.3 证据状态、不确定性与信息缺口

运行证据具有不同的可核验程度。调用参数、返回值和状态写入属于可返回源记录的运行事实；依据追踪标识、数据相似或程序规则建立的关系属于系统推断；开发者围绕原因形成的解释属于人的判断；未采集字段、不可见工具状态和无法复现的环境差异则构成信息缺口。上述状态在分析中的作用不同，不宜采用相同的视觉层级和措辞。

Sacha 等人^[35]将不确定性视为贯穿数据采集、模型处理、视觉表达和人的解释全过程的属性。Hullman^[36]调查了 90 名可视化作者并访谈 13 名设计者，发现作者虽然承认不确定性信息具有价值，却常因担心界面复杂、说服力下降和读者负担而省略此类信息。Dritsa 和 Houben^[37]对设计研究者使用数据可视化的研究进一步表明，不确定性可能来自数据质量、分析参数和使用者背景，设计需要帮助使用者辨认来源，并判断其对结论的影响。

Ehsan 等人^[38]提出的技术接缝显化解释方法（Seamful XAI）关注数据、模型和基础设施边界对使用者行动能力的影响。该研究表明，适度呈现系统限制与技术接缝，有助于使用者识别可操作范围。在运行问题分析中，信息缺口可以与受影响的候选原因及补充检查相连接，使开发者能够选择重放、增加埋点、对照测试或环境核查等验证行动。

“运行事实、系统推断、用户判断和信息缺口”并非简单的高、中、低可信度。直接记录可能不完整，系统推断可以在前提满足时具有较高可靠性，人的判断也可能综合多项证据。证据状态设计需要回答四个问题：信息来自何处，经过何种处理，支持何种主张，还缺少哪些材料。

1.4 AI 智能体可观测与交互调试研究

1.4.1 运行轨迹采集与系统可观测

智能体可观测性（observability）研究首先需要确定记录范围。结构化日志框架 AgentTrace^[39]将日志分为操作、认知和上下文三个平面，用以组织模型交互、环境动作和上下文变化。系统级可观测工具 AgentSight^[40]同时捕捉模型侧语义信息与操作系统层事件，扩展了对外部进程行为的覆盖。开放智能体规范（Open Agent Specification）^[5]则尝试以统一声明支持不同智能体框架之间的运行比较。这些工作提高了运行材料的可获得性和可计算性，但其研究重点主要是记录范围、数据结构和系统开销。

分层可观测数据并不会自动形成面向开发者的解释。内核事件属于直接观测，高层意图及两者之间的对应关系可能依赖规则或模型推断；相同事件在任务、工具、上下文和状态视图中的含义也不同。可观测基础设施需要通过信息架构和交互操作转化为可核对的分析材料。

1.4.2 轨迹浏览、关系分析与运行干预

现有智能体调试工具可按主要交互方式分为轨迹浏览、关系分析和运行干预三类。行为分析工具 AgentLens^[41]使用层级时间视图呈现多智能体行为的演变，并支持从整体模式进入具体行为。长任务观察工具 AgentGUI^[42]同时展示任务、轨迹、产物和成本；在 8 人实验中，参与者定位关键轨迹信息的平均用时由 145 秒降至 90 秒，答案正确率由 80% 提高到 93%。这类工具证明了概览与细节

联动的价值，但候选原因和自动建议仍需标明其推断性质。

关系分析工具使用图结构呈现跨步骤依赖。智能体图分析平台 Agent-Graph^[43]将智能体、任务、工具、输入输出和人员组织成知识图谱，每个图元素均可返回对应轨迹片段。轨迹图系统 Graph of Trace^[44]将科学研究智能体的执行事件组织为持续更新的有向图，支持领域专家检查工作流程和中间步骤。图结构能够表达长链依赖，但节点、边和聚合规则需要与用户任务相匹配，否则视觉连线容易被理解为已经确认的因果关系。

运行干预工具将观察与验证操作结合。多智能体交互调试工具 AGDebugger^[45]支持暂停、重置和修改历史消息。其 14 人实验显示，交互调试有助于定位部分问题，但参与者在选择干预位置和修改方式时仍经常失败。软件开发智能体调试工具 AgentStepper^[46]引入断点、单步执行、中间状态检查和现场编辑；在 12 人实验中，参与者识别智能体实现缺陷的成功率由 17% 提高到 60%，一般轨迹理解成绩则仅由 64% 提高到 67%。用户能够操作轨迹，并不意味着已经形成正确的问题解释。

无代码智能体开发工具 AutoGen Studio^[47]提供 workflow 配置、运行试验和消息查看能力，数据应用调试工具 LADYBUG^[48]支持逐步检查输入输出、局部干预和受影响步骤的重新计算。此类工具降低了比较替代路径的成本，也使观察、判断与系统修改紧密相连。证据尚不充分时的修改可能产生新的混杂因素，因此界面需要保留干预前的判断、所依据的证据和预期结果。

表 1.1 代表性 AI 智能体运行分析工具比较

代表工具	主要表征	核心交互	现有评价重点
AGDebugger ^[45]	多智能体消息 轨迹	暂停、重置、编辑消息	形成性访谈与 14 人实验，关注问题定位和干预
AgentGUI ^[42]	任务、轨迹、产物与成本视图	观察、人工纠偏与自动纠偏	8 人实验，测量时间、正确率和工作负担
AgentStepper ^[46]	结构化会话与代码变化	断点、单步执行、现场编辑与状态检查	12 人实验，测量轨迹理解和缺陷识别
AgentLens ^[41]	层级时间视图	概览、筛选、下钻和原因追踪	使用情景与用户研究，关注行为分析
AgentGraph ^[43]	交互式知识图谱	图浏览与原始轨迹回溯	以系统能力与案例展示为主
Graph of Trace ^[44]	实时有向工作流图	过程检查与阶段回顾	领域专家评价，关注工作流可理解性

1.4.3 自动分析结果的人因局限

自动失败归因和修复研究将轨迹处理为候选原因、责任步骤或修复建议。此类结果依赖日志覆盖、分类规则、模型能力和评测标签，其技术准确率不能直接代表开发者的实际收益。Parnin 和 Orso^[49]研究自动故障定位工具后指出，算法将错误语句排在前列，并不意味着程序员能够理解根因；真实调试还需要沿数据依赖和控制依赖导航、检查状态并通过重运行验证假设。

面向开发者的运行分析工具因此需要把自动结果组织为可检查的主张：说明支持主张的原始记录、关联规则和适用前提，提供竞争解释与反驳材料，并在必需信号缺失时保留未知状态。相应评价也应测量用户最终形成的判断，而不只测量算法检测率或界面操作速度。

1.5 证据呈现的设计研究与评价方法

1.5.1 形成性研究与表征设计

证据呈现设计需要建立在开发者实际分析活动的观察之上。关键事件访谈、案例回放、出声思考和认知任务分析可用于识别线索来源、搜索路径、判断转折和信息缺口。真实案例能够保留工作情境、噪声和不完整数据，统一案例则便于比较不同参与者的证据选择和判断过程。两类材料结合可以兼顾生态效度与任务可比性。

设计探索阶段应将信息层级、关系语义和交互入口转化为可比较的表征方案。Pareek 等人^[28]以不同多智能体界面作为研究探针，分析界面结构如何影响用户对角色、任务转移和可靠性的理解。这种研究方法适合在完整原型实现之前检验表征假设，并识别视觉结构可能引发的判断偏差。

形成性发现、设计要求与界面机制之间需要建立可追踪关系。每项主要功能应说明其回应的分析困难，并在后续评价中对应至少一项可观察结果。该做法能够避免将一般性的界面偏好直接解释为设计有效性。

1.5.2 证据呈现的评价维度

综合调试研究、可视分析和人与人工智能交互（Human-AI Interaction）研究，证据呈现可从四个维度评价。第一，分析结果，包括原因判断的正确性、候选范围和结论完整性。第二，证据使用，包括所引材料的相关性、充分性、来源可追溯性，以及事实与推断是否匹配。第三，判断过程，包括候选原因比较、反证查

找、新证据引发的判断更新和信息缺口识别。第四，验证行动，包括后续检查区分竞争解释的能力、预期信息收益和实施成本。

任务完成时间、交互操作量和主观负荷可用于描述效率与使用成本。信心水平需要与判断正确性联合分析，以识别证据充分时的合理信心、证据不足时的谨慎判断和错误结论下的过度信心。评价指标由结果扩展到依据、过程和行动，能够更完整地检验证据呈现对分析质量的影响。

1.5.3 实验条件与分析方法

证据呈现研究需要区分底层信息能力与上层交互组织的作用。实验条件应使用相同运行材料和关系计算结果，依次比较常规时间轨迹、增加跨步骤关系的证据关联界面，以及进一步支持候选原因、正反证据、信息缺口和验证行动的证据分析界面。该设置可以分别检验结构化关联与分析过程支持的增量作用。

对于由多个参与者和多个案例构成的实验，线性混合效应模型或广义线性混合效应模型能够同时处理个体差异与案例差异。质性访谈、出声思考和交互日志则用于解释定量结果，区分界面未提供关键线索、参与者未发现线索和参与者发现线索后仍作出错误推断等情况。

1.6 国内外研究进展与本研究定位

国内研究已围绕智能时代的人机交互、人机协同、人工智能决策可解释性及其评价方法展开。范俊君等人^[50]讨论了智能时代人机交互中的心理模型、交互原则与评价框架。范向民等人^[51]梳理了人机交互与人工智能从交替发展到协同共进的关系。孔祥维等人^[52]和李瑶等人^[53]分别从人工智能决策与评价方法角度总结了可解释性研究。邢颖^[54]则对可解释人工智能在软件工程中的技术方法进行了综述。这些研究为以人为中心的解释设计和评价提供了理论基础，直接面向智能体运行证据的人因研究仍相对有限。

国外研究已经形成从程序调试、分布式追踪、可视分析到智能体交互工具的连续脉络。信息觅食和问题导向调试研究解释了开发者如何寻找线索；分布式追踪和分析溯源研究建立了事件关联与分析历史的数据基础；不确定性、解释和适当依赖研究说明了呈现方式对判断与信心的影响；近期智能体工具则提供了轨迹采集、图结构分析、运行重放和交互干预能力。

现有研究仍存在四项与本课题直接相关的不足。第一，多数工具以事件类型、框架组件或代理角色组织信息，与开发者围绕异常症状和候选原因展开的分析路径并不完全一致。第二，原始记录、系统推断和用户判断常处于相近的视觉层级，关系来源与证据强度表达不足。第三，信息缺口通常表现为空白或缺失字段，尚未与受影响的判断和补充验证行动建立联系。第四，现有评价主要关注系统性能、算法准确率、任务效率或主观可用性，对证据使用质量、判断更新和验证行动的考察较少。

本研究以 AI 智能体运行问题分析为应用情境，将运行轨迹视为需要被组织、解释和核验的证据材料。研究将从开发者实际分析活动出发，建立包含证据来源、关系、状态和完整性的呈现框架，设计支持候选原因比较、正反证据核对、信息缺口识别和验证行动规划的交互原型，并通过分层对照实验评价判断正确性、证据充分性、不确定性校准和验证行动质量。

1.7 本章小结

相关研究为智能体运行问题分析提供了三方面基础。程序调试与意义建构研究解释了开发者如何搜索线索、形成候选原因并依据新证据更新判断；分布式追踪、分析溯源和不确定性研究提供了组织证据来源、关系与边界的方法；智能体可观测和交互调试工具则证明了长轨迹浏览、关系分析、运行回放和干预的技术可行性。

现有研究尚未充分说明不同证据呈现方式如何影响开发者的问题解释、证

据核对与后续验证。本研究将证据呈现作为连接可观测数据、开发者分析活动和交互设计的核心对象，在保持工程材料真实性的基础上，通过形成性研究、表征设计和对照实验建立设计学与人与人工智能交互研究的实证贡献。

2 选题报告

2.1 研究背景

人工智能（artificial intelligence, AI）智能体通过大语言模型、工具系统、运行状态和控制逻辑的协同完成复杂任务。智能体运行框架（agent harness）负责组装上下文、调度模型与工具、维护状态并控制任务流程，其运行质量直接影响智能体的任务表现。在多步骤任务中，早期上下文遗漏、工具返回异常、状态覆盖或停止条件偏差均可能向后传播，形成最终结果错误。

当前开发实践主要借助日志、调用链和运行轨迹检查问题。随着任务长度和系统复杂度增加，运行记录呈现出事件数量多、信息粒度差异大、跨步骤关系隐含和数据完整性有限等特征。开发者需要在多种材料之间建立联系，从异常症状形成候选原因，寻找支持或反驳证据，并通过重放、补充记录或对照测试进一步验证。

运行问题分析的质量既取决于可观测数据，也取决于证据的组织与呈现方式。时间顺序、数据依赖、状态变化和自动归因结果分别支持不同类型的判断；来源、证据强度和信​​息缺口则决定结论的可信范围。证据呈现由此成为连接系统记录与开发者判断的关键交互环节。

本研究题目为“面向 AI 智能体运行问题分析的证据呈现与交互设计研究”。研究将以智能体运行框架的执行轨迹为材料基础，考察开发者如何获取、关联和评价运行证据，探索证据来源、关系、状态和完整性的交互呈现方式，并通过用户研究检验其对问题分析质量的影响。

2.2 研究目的与意义

2.2.1 研究目的

本研究拟建立面向 AI 智能体运行问题分析的证据呈现框架，形成相应的交互设计原则和原型，并通过对照实验评价设计效果。具体目标包括：识别开发者在运行问题分析中的证据需求与判断困难；研究不同证据组织方式对信息获取和归因判断的影响；设计支持候选原因比较、证据核对、信息缺口识别和验证行动规划的交互工具；构建以分析质量为核心的评价指标。

2.2.2 理论意义

第一，将开发者调试研究拓展至具有概率性行为、跨步骤传播和部分可见特征的 AI 智能体系统，补充该情境下的信息行为与判断研究。第二，综合信息觅食、数据—框架理论（Data-Frame theory）、分析溯源、不确定性表达和适当依赖等理论，建立运行证据呈现与开发者分析活动之间的解释框架。第三，从判断结果、证据使用、分析过程和验证行动四个维度构建设计评价方法，为复杂 AI 系统的交互研究提供可操作的测量路径。

2.2.3 实践意义

研究成果可为 AI 智能体开发平台、可观测系统和调试工具提供信息架构与交互设计依据，包括运行证据的层级组织、跨步骤关系的表达、自动推断的来源说明、信息缺口的呈现以及验证操作的连接方式。相关设计有助于开发者提高问题定位、复盘沟通和协作分析的效率与质量。

2.3 国内外研究现状

调试与程序理解研究揭示了开发者围绕问题开展信息搜寻、线索关联和假设检验的过程。Ko 和 Myers^[11]以“为什么发生”和“为什么没有发生”问题组织调试信息；Lawrance 等人^[8]运用信息觅食理论解释开发者的搜索路径；Katz 和 Anderson^[7]则区分了故障位置发现与错误修复。Klein 等人^[18]提出的数据一框架理论，以及 Pirolli 和 Card^[19]、Xu 等人^[21]与 Kadivar 等人^[20]对分析过程的研究进一步说明，复杂分析包含解释框架的建立、证据补充、矛盾识别和判断更新。

可视分析和人与人工智能交互（Human-AI Interaction）研究关注证据来源、不确定性、解释与信任之间的关系。Sacha 等人^[35]和 Hullman^[36]分别从不确定性传播与可视化实践角度说明了证据边界表达的重要性。Sieker 等人^[26]发现，解释可能提高用户对系统能力的主观评价，却未同步提高其识别系统局限的能力。Ehsan 等人^[38]提出的技术接缝显化解释方法进一步表明，呈现数据、模型与基础设施边界能够帮助使用者判断系统限制与可操作范围。

AI 智能体与分布式系统研究形成了轨迹采集、跨组件追踪、图结构分析、失败归因和交互式重放等技术能力。Fonseca 等人^[31]、Mace 等人^[33]和 Sigelman 等人^[32]建立了跨组件追踪与关系查询的技术基础；AgentTrace^[39]、AgentGraph^[43]和 AgentStepper^[46]则分别探索了结构化记录、图分析和交互式调试。现有工具主要按照事件类型、框架组件或代理角色组织信息，对开发者围绕候选原因开展的证据比较与判断更新支持有限。相关实验也多采用系统性能、检测准确率和任务效率指标，对证据使用质量、信息缺口识别和后续验证行动的测量较少。

基于上述进展，本研究聚焦三个研究空间：其一，识别开发者在 AI 智能体运行问题分析中的证据获取与判断规律；其二，建立证据来源、关系、状态和完整性的呈现结构；其三，评价证据呈现与分析交互对判断正确性、证据充分性和验证行动的影响。

2.4 研究问题

研究问题一（RQ1）：开发者在分析 AI 智能体运行问题时，如何获取、关联和评价运行证据，主要存在哪些信息理解与判断困难？

该问题关注开发者从异常症状到原因判断的实际过程，分析其信息入口、查看路径、候选原因、证据引用、判断转折、信息缺口和验证行动。

研究问题二（RQ2）：运行证据的组织层级、关联方式与不确定性表达如何影响开发者对运行过程的理解、证据核对和归因判断？

该问题比较时间顺序、数据依赖、状态变化、候选原因和证据状态等不同表征要素，考察其对信息查找、关系理解、替代解释考虑和判断信心的影响。

研究问题三（RQ3）：基于证据链和分析过程支持的交互设计能否提升运行问题判断的正确性、证据充分性、不确定性校准和验证行动质量？

该问题通过分层对照实验评价设计原型，并分析界面条件、参与者经验和案例特征之间的关系。

2.5 研究内容与技术路线

研究由运行问题分析行为研究、证据呈现设计、交互原型实现和设计评价四部分构成。各阶段依次形成证据需求、设计原则、原型功能和实证结论。

2.5.1 运行问题分析行为研究

首先构建 AI 智能体运行问题案例集，并以关键事件访谈、真实案例回放和统一任务中的出声思考研究开发者的分析行为。计划招募 10–14 名具有 AI 智能体开发或复杂系统调试经验的参与者。真实案例回放用于获取完整的工作情境与经验知识，统一案例任务用于比较不同参与者的证据搜索路径和判断方式。

研究记录参与者的起始线索、信息查看顺序、候选原因、证据引用、判断变化、信息缺口和验证行动。资料分析采用开放编码与理论引导编码相结合的方法。

法：以实际行为形成初始编码，再用信息觅食理论和数据一框架理论解释信息路径与判断更新。两名研究者对部分材料独立编码，形成编码手册后完成全量分析。

本阶段将产出运行问题分析活动模型、典型证据需求、主要判断困难和设计机会，为后续表征方案与实验任务提供依据。

2.5.2 证据呈现方式的设计探索

根据形成性研究结果，从四个维度开展证据呈现设计：

- 1) **证据来源**：呈现事件的生成组件、时间、输入输出和原始记录入口；
- 2) **证据关系**：表达时间顺序、调用层级、数据传递、状态影响和人工建立的判断关系；
- 3) **证据状态**：区分运行事实、系统推断、用户判断以及各自的依据；
- 4) **证据完整性**：标记缺失记录、不可见状态和待验证关系，并关联可执行的补充检查。

研究将制作 3–5 种低保真表征方案，比较以时间、对象、问题和候选原因为入口的信息组织方式。计划邀请 6–8 名开发者参加比较式走查，并邀请 3–5 名人机交互（human-computer interaction, HCI）或开发者工具专家开展启发式评审。评价内容包括信息层级、关系语义、证据可追溯性、不确定性表达、交互连续性和使用成本。

本阶段将形成证据呈现框架、设计原则和原型信息架构。

2.5.3 交互原型设计与实现

原型暂命名为“AI 智能体运行证据分析工作台”。系统以结构化轨迹为数据基础，整合时间、调用、数据流和状态变化等关系，并提供以下功能：

- 1) **症状与证据定位**：由异常输出、任务节点或状态差异进入相关运行事件；

- 2) **跨步骤证据追踪**: 查看输入、上下文片段、工具结果和状态对象的来源及传播路径;
- 3) **候选原因管理**: 建立候选原因, 并分别关联支持证据、反驳证据和待核查材料;
- 4) **证据状态表达**: 呈现记录事实、系统推断和用户判断的来源与更新状态;
- 5) **信息缺口管理**: 说明缺失内容及其影响的判断, 并记录补充证据的方法;
- 6) **验证行动规划**: 将重放、补充埋点、对照测试和环境检查与候选原因连接;
- 7) **分析过程记录**: 保存关键证据、判断变化和验证结果, 支持回看与协作复核。

所有系统生成的关联和候选提示均保留计算来源与原始记录入口。原型将记录视图切换、证据查看、候选原因编辑和判断提交等交互数据, 为后续过程分析提供基础。

2.5.4 设计评价与综合分析

正式实验初步计划招募 30—45 名具有软件开发经验的参与者, 采用被试内或混合设计, 最终方案依据预实验中的任务时长和学习效应确定。正式样本量将在预实验后结合效应量、参与者差异和案例差异, 通过模拟功效分析确定。每名参与者完成多个难度相近、故障类型不同的案例, 案例与条件顺序采用拉丁方平衡。

表 2.1 实验条件与变量控制

条件	界面能力	研究目的
A 时间轨迹	时间线、事件详情、搜索和筛选	建立常规运行轨迹分析基线
B 证据关联	A 的全部能力，以及跨步骤来源、数据依赖和状态关系	评价结构化证据关联的作用
C 证据分析	B 的全部能力，以及候选原因、正反证据、信息缺口、验证行动和判断历程	评价分析过程交互支持的作用

三种条件采用相同的底层运行数据；B 与 C 使用相同的系统计算关系，以控制信息覆盖和算法能力差异。实验结束后通过半结构化访谈了解参与者的界面理解、策略选择和主观评价。

2.6 研究材料与案例构建

案例材料由公开或自建 AI 智能体任务的真实运行改编，覆盖上下文构建、工具调用、状态管理和停止条件等典型问题。每个案例应具备可识别的异常症状、跨步骤证据链、至少一个合理的竞争解释和一项有效验证行动；部分案例包含真实的信息缺口，用于考察参与者对证据边界的处理。

案例采用“主张-证据”结构进行专家标注。标注单元包括运行事实、候选原因、支持证据、反驳证据、可接受推断、未决信息和验证行动。两名熟悉 AI 智能体系统的研究者独立完成标注，通过讨论或第三位专家解决分歧，并记录标

注依据。案例标注用于建立评分标准和评价界面条件下的证据使用质量。

预实验将检验案例难度、信息覆盖、任务时长和评分可操作性。案例之间在事件数量、关键证据距离、候选原因数量和信息缺口程度上进行平衡。

2.7 评价指标与分析方法

表 2.2 设计评价指标

评价维度	操作化方式	指标类型
判断正确性	原因判断与案例标注的一致程度、候选范围完整性和错误排除情况	主要结果指标
证据充分性	引用证据的相关性、覆盖度、来源可追溯性及事实与推断的匹配程度	主要结果指标
不确定性校准	结论保留程度、信息缺口识别与信心水平相对于证据质量的匹配程度	主要结果指标
验证行动质量	行动区分竞争解释的能力、预期信息收益和实施成本	主要结果指标
判断更新	新证据出现后的结论变化、变化方向及更新依据	过程指标
分析效率	完成时间、证据查看量、跳转次数和操作路径长度	补充指标
认知负荷与体验	美国国家航空航天局任务负荷指数（NASA Task Load Index, NASA-TLX）或简化负荷量表、可用性和主观偏好	补充指标

判断正确性与证据充分性由两名评分者依据案例标注独立评分，至少 20% 的样本用于计算评分一致性。信心水平与判断正确性联合分析，用于识别合理信心、谨慎判断和高信心错误等不同状态。

定量分析根据因变量类型采用线性或广义线性混合效应模型，将参与者与案例设为随机效应，将界面条件、经验水平和任务顺序设为固定效应。统计结果报告效应量与置信区间，并进行多重比较校正。出声思考、访谈和交互日志采用主题分析与序列分析，用于解释各条件下的证据搜索路径和判断变化。

2.8 研究框架



图 2.1 面向 AI 智能体运行问题分析的研究技术路线

研究以开发者分析行为为需求基础，以证据呈现框架为设计核心，以交互原型为研究载体，并通过分层实验评价设计要素的作用。形成性研究、表征设计和实验结果之间构成迭代关系。

2.9 可行性、风险与伦理

2.9.1 研究可行性

研究可复用现有智能体运行框架、轨迹记录和测试任务，技术实现重点为轨迹数据映射、证据关系组织和交互联动，无需训练新的基础模型。案例范围集中于可重复的典型运行问题，适合在硕士研究周期内完成。参与者可通过校内开发者、企业合作团队与开源社区招募。

2.9.2 研究风险与控制

参与者经验差异可能影响证据理解和任务表现，研究将记录专业背景、设置基础能力测量并在统计模型中控制。案例将由真实运行改编，以增强任务真实性，同时通过统一材料保证条件可比性。多功能界面可能产生学习成本和新颖效应，研究将设置训练任务、平衡实验顺序并记录操作成本。专家标注可能受到经验判断影响，研究将采用双人独立标注、分歧记录和第三位专家复核。

2.9.3 研究伦理与数据管理

参与者将签署知情同意书，并可随时退出研究。真实案例回放需移除代码、密钥、客户数据和组织标识；研究仅保存完成分析所需的脱敏片段。屏幕、语音和交互日志采用加密存储，转写材料以编号替代身份。企业案例在无法充分脱敏时，将由研究者构建具有等价问题结构的测试案例。

2.10 进度安排

表 2.3 研究进度计划

阶段	时间	主要任务与成果
研究准备与案例构建	2026.09–2026.10	补充文献，完成伦理材料，采集运行记录并立案例标注手册
形成性研究	2026.11–2027.01	开展案例回放、统一任务和访谈，形成分析活动模型与证据需求
设计探索与原型预测	2027.02–2027.06	比较表征方案，完成交互原型、专家评审和小规模预实验
正式实验	2027.07–2027.10	完成功效分析、预注册、正式实验及访谈资料收集
综合分析与论文初稿	2027.11–2028.02	完成统计分析、质性分析、设计原则归纳和论文初稿
论文修改与答辩	2028.03–2028.05	完成论文修改、送审、答辩准备和研究材料整理

2.11 预期成果与创新点

预期成果包括：AI 智能体运行问题案例与“主张-证据”标注集、开发者运行问题分析活动模型、运行证据呈现框架与交互设计原则、证据分析工作台原型，以及一项比较三类界面条件的用户实验。

研究创新点包括：

- 1) **研究视角**：研究运行证据进入开发者判断与行动的过程，连接可观测技术与分析行为；
- 2) **设计框架**：以证据来源、关系、状态和完整性为维度，构建运行问题分析的信息架构；
- 3) **交互机制**：整合候选原因、正反证据、信息缺口与验证行动，并保持原始轨迹可追溯；
- 4) **评价方法**：采用分层对照实验，综合评价判断、证据、不确定性校准和验证行动质量。

参考文献

- [1] Van Der Maden W, Sadek M, Xiao Z. Results-Actionability Gap: Understanding How Practitioners Evaluate LLM Products in the Wild[C]//Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems. 2026: 1-17.
- [2] Khanna R, Dodge J, Anderson A. Finding AI's Faults with AAR/AI: An Empirical Study[J]. ACM Transactions on Interactive Intelligent Systems, 2022, 12(1): 1:1-1:33.
- [3] Chen M, Wang J, Liu Z. From Failed Trajectories to Reliable LLM Agents: Diagnosing and Repairing Harness Flaws[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2606.06324>. arXiv: 2606.06324 [cs.SE].
- [4] Lin J, Liu S, Pan C. Agentic Harness Engineering: Observability-Driven Automatic Evolution of Coding-Agent Harnesses[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2604.25850>. arXiv: 2604.25850.
- [5] Amini S, Benajiba Y, Bernardis C. Open Agent Specification: Enabling Cross-Framework Comparison of AI Agents[C]//Proceedings of the ACM Conference

- on AI and Agentic Systems. 2026: 404-418.
- [6] Zhang S, Yin M, Zhang J. Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems[C]//Proceedings of Machine Learning Research: vol. 267. 2025: 76583-76599.
- [7] Katz I R, Anderson J R. Debugging: An Analysis of Bug-Location Strategies[J]. Human-Computer Interaction, 1987-1988, 3(4): 351-399.
- [8] Lawrance J, Bogart C, Burnett M. How Programmers Debug, Revisited: An Information Foraging Theory Perspective[J]. IEEE Transactions on Software Engineering, 2013, 39(2): 197-215.
- [9] Ko A J, Myers B A, Coblenz M J. An Exploratory Study of How Developers Seek, Relate, and Collect Relevant Information during Software Maintenance Tasks[J]. IEEE Transactions on Software Engineering, 2006, 32(12): 971-987.
- [10] Rasmussen J, Jensen A. Mental Procedures in Real-Life Tasks: A Case Study of Electronic Trouble Shooting[J]. Ergonomics, 1974, 17(3): 293-307.
- [11] Ko A J, Myers B A. Debugging Reinvented: Asking and Answering Why and Why Not Questions about Program Behavior[C]//Proceedings of the 30th International Conference on Software Engineering. 2008: 301-310.

- [12] Ko A J, Myers B A. Designing the Whyline: A Debugging Interface for Asking Questions about Program Behavior[C]//Proceedings of the 2004 ACM Conference on Human Factors in Computing Systems. 2004: 151-158.
- [13] Ko A J, Myers B A. Finding Causes of Program Output with the Java Whyline [C]//Proceedings of the 27th ACM Conference on Human Factors in Computing Systems. 2009: 1569-1578.
- [14] Romero P, Du Boulay B, Cox R. Debugging Strategies and Tactics in a Multi-Representation Software Environment[J]. International Journal of Human-Computer Studies, 2007, 65(12): 992-1009.
- [15] Cornelissen B, Zaidman A, Van Deursen A. A Controlled Experiment for Program Comprehension through Trace Visualization[J]. IEEE Transactions on Software Engineering, 2011, 37(3): 341-355.
- [16] Klein G, Moon B, Hoffman R R. Making Sense of Sensemaking 1: Alternative Perspectives[J]. IEEE Intelligent Systems, 2006, 21(4): 70-73.
- [17] Klein G, Moon B, Hoffman R R. Making Sense of Sensemaking 2: A Macrocognitive Model[J]. IEEE Intelligent Systems, 2006, 21(5): 88-92.
- [18] Klein G, Phillips J K, Rall E L. A Data-Frame Theory of Sensemaking[M]//

- Expertise Out of Context. 2007: 113-155.
- [19] Pirolli P, Card S K. The Sensemaking Process and Leverage Points for Analyst Technology as Identified Through Cognitive Task Analysis[C]//Proceedings of the 2005 International Conference on Intelligence Analysis. 2005.
- [20] Kadivar N, Chen V, Dunsmuir D. Capturing and Supporting the Analysis Process[C]//Proceedings of the IEEE Symposium on Visual Analytics Science and Technology. 2009: 131-138.
- [21] Xu K, Attfield S, Jankun-Kelly T J. Analytic Provenance for Sensemaking: A Research Agenda[J]. IEEE Computer Graphics and Applications, 2015, 35(3): 56-64.
- [22] Starr A, Storey M A. Theory of Troubleshooting: The Developer's Cognitive Experience of Overcoming Confusion[J/OL]. ACM Transactions on Software Engineering and Methodology, 2026. DOI: 10.1145/3800945.
- [23] Miller T. Explanation in Artificial Intelligence: Insights from the Social Sciences [J/OL]. Artificial Intelligence, 2019, 267: 1-38. DOI: 10.1016/j.artint.2018.07.007.
- [24] Abdul A, Vermeulen J, Wang D, et al. Trends and Trajectories for Explain-

- able, Accountable and Intelligible Systems: An HCI Research Agenda[C/OL]//
 Proceedings of the 2018 CHI Conference on Human Factors in Computing Sys-
 tems. 2018: 582:1-582:18. DOI: 10.1145/3173574.3174156.
- [25] Kaur H, Nori H, Jenkins S, et al. Interpreting Interpretability: Understanding
 Data Scientists' Use of Interpretability Tools for Machine Learning[C/OL]//
 Proceedings of the 2020 CHI Conference on Human Factors in Computing Sys-
 tems. 2020: 1-14. DOI: 10.1145/3313831.3376219.
- [26] Sieker J, Kramer M, Escoffier T, et al. The Illusion of Competence: Evaluating the
 Effect of Explanations on Users' Mental Models of Visual Question Answering
 Systems[C/OL]//Proceedings of the 2024 Conference on Empirical Methods in
 Natural Language Processing. 2024: 19459-19475. DOI: 10.18653/v1/2024.emnlp-main.1084.
- [27] BUÇINCA Z, Malaya M B, Gajos K Z. To Trust or to Think: Cognitive
 Forcing Functions Can Reduce Overreliance on AI in AI-Assisted Decision-
 Making[J/OL]. Proceedings of the ACM on Human-Computer Interaction, 2021,
 5(CSCW1): 188:1-188:21. DOI: 10.1145/3449287.
- [28] Pareek S, Govers J, Als N K K, et al. Sensemaking in Multi-Agent LLM

- Interfaces: How Users Interpret Transitions, Roles, and Reliability[C/OL]//
 Proceedings of the 2026 CHI Conference on Human Factors in Computing Sys-
 tems. 2026: 1-20. DOI: 10.1145/3772318.3791157.
- [29] Kumar A, Bajpai Y, Gulwani S, et al. Why AI Agents Still Need You: Find-
 ings from Developer-Agent Collaborations in the Wild[C/OL]//Proceedings of the
 40th IEEE/ACM International Conference on Automated Software Engineering.
 2025. DOI: 10.48550/arXiv.2506.12347.
- [30] Vicente K J, Rasmussen J. Ecological Interface Design: Theoretical Foundations
 [J/OL]. IEEE Transactions on Systems, Man, and Cybernetics, 1992, 22(4): 589-
 606. DOI: 10.1109/21.156574.
- [31] Fonseca R, Porter G, Katz R H. X-Trace: A Pervasive Network Tracing Frame-
 work[C]//Proceedings of the 4th USENIX Symposium on Networked Systems
 Design and Implementation. 2007: 271-284.
- [32] Sigelman B H, Barroso L A, Burrows M. Dapper, a Large-Scale Distributed Sys-
 tems Tracing Infrastructure: dapper-2010-1[R]. Google, 2010.
- [33] Mace J, Roelke R, Fonseca R. Pivot Tracing: Dynamic Causal Monitoring for
 Distributed Systems[C]//Proceedings of the 25th ACM Symposium on Operating

Systems Principles. 2015: 378-393.

- [34] Ragan E D, Endert A, Sanyal J. Characterizing Provenance in Visualization and Data Analysis: An Organizational Framework of Provenance Types and Purposes [J]. IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 31-40.
- [35] Sacha D, Senaratne H, Kwon B C. The Role of Uncertainty, Awareness, and Trust in Visual Analytics[J]. IEEE Transactions on Visualization and Computer Graphics, 2016, 22(1): 240-249.
- [36] Hullman J. Why Authors Don't Visualize Uncertainty[J]. IEEE Transactions on Visualization and Computer Graphics, 2020, 26(1): 130-139.
- [37] Dritsa D, Houben S. How Design Researchers Make Sense of Data Visualizations in Data-Informed Design Processes: The Role of Uncertainty[J/OL]. ACM Transactions on Computer-Human Interaction, 2024, 31(6): 72:1-72:53. DOI: 10.1145/3685268.
- [38] Ehsan U, Liao Q V, Passi S, et al. Seamful XAI: Operationalizing Seamful Design in Explainable AI[J/OL]. Proceedings of the ACM on Human-Computer Interaction, 2024, 8(CSCW1): 119:1-119:29. DOI: 10.1145/3637396.

- [39] Alsayyad A, Huang K Y, Pal R. AgentTrace: A Structured Logging Framework for Agent System Observability[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2602.10133>. arXiv: 2602.10133.
- [40] Zheng Y, Hu Y, Yu T. AgentSight: System-Level Observability for AI Agents Using eBPF[PP/OL]. arxiv(2025) [2026-09-20]. <https://arxiv.org/abs/2508.02736>. arXiv: 2508.02736.
- [41] Lu J, Pan B, Chen J. AgentLens: Visual Analysis for Agent Behaviors in LLM-Based Autonomous Systems[J]. IEEE Transactions on Visualization and Computer Graphics, 2025, 31(8): 4182-4197.
- [42] Zhao X, Sohn J, Zheng Q. AgentGUI: An Interface for Observing and Steering Long-Running AI Agents[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2607.26300>. arXiv: 2607.26300.
- [43] Wu Z, Cho S, Villalobos C E M. AgentGraph: Trace-to-Graph Platform for Interactive Analysis and Robustness Testing in Agentic AI Systems[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 40: 48. 2026:41721-41723.
- [44] Gao T, Li H, Li J H. Graph of Trace: Visualizing Execution Traces of Scientific

- Agents[C]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics: System Demonstrations. 2026: 297-306.
- [45] Epperson W, Bansal G, Dibia V. Interactive Debugging and Steering of Multi-Agent AI Systems[C]//Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems. 2025: 156:1-156:15.
- [46] Hutter R, Pradel M. AgentStepper: Interactive Debugging of Software Development Agents[PP/OL]. arxiv(2026) [2026-09-20]. <https://arxiv.org/abs/2602.06593>. 3. arXiv: 2602.06593.
- [47] Dibia V, Chen J, Bansal G. AutoGen Studio: A No-Code Developer Tool for Building and Debugging Multi-Agent Systems[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2024: 72-79.
- [48] Rorseth J, Godfrey P, Golab L. LADYBUG: an LLM Agent DeBUGger for Data-Driven Applications[C]//Proceedings of the 28th International Conference on Extending Database Technology. 2025: 1082-1085.
- [49] Parnin C, Orso A. Are Automated Debugging Techniques Actually Helping Programmers?[C]//Proceedings of the 20th International Symposium on Software

Testing and Analysis. 2011: 199-209.

- [50] 范俊君, 田丰, 杜一, 等. 智能时代人机交互的一些思考[J/OL]. 中国科学: 信息科学, 2018, 48(4): 361-375. DOI: 10.1360/N112017-00221.
- [51] 范向民, 范俊君, 田丰, 等. 人机交互与人工智能: 从交替浮沉到协同共进[J/OL]. 中国科学: 信息科学, 2019, 49(3): 361-368. DOI: 10.1360/N112018-00181.
- [52] 孔祥维, 唐鑫泽, 王子明. 人工智能决策可解释性的研究综述[J/OL]. 系统工程理论与实践, 2021, 41(2): 524-536. DOI: 10.12011/SETP2020-1536.
- [53] 李瑶, 左兴权, 王春露, 等. 人工智能可解释性评估研究综述[J/OL]. 导航定位与授时, 2022, 9(6): 13-24. DOI: 10.19306/j.cnki.2095-8110.2022.06.003.
- [54] 邢颖. 基于可解释性人工智能的软件工程技术方法综述[J/OL]. 计算机科学, 2023, 50(5): 3-11. DOI: 10.11896/jsjcx.221100159.

华中科技大学

研究生（文献阅读与选题）报告

☐文献阅读、☐选题、☐文献阅读与选题、☐论文中期进展

题目：面向 AI 智能体运行问题分析的证据呈现与交互设计研究

学号 M202570493

姓名 陈思静

专业 设计学

指导教师 何心

院（系、所） 设计学院