



硕士学位论文开题答辩

工具调用型大语言模型智能体故障诊断的 信息表征与交互设计研究

华中科技大学 | 设计学院 | 设计学

答辩人：陈思静

学号：M20270493

导师：何心

日期：2026/09/24

汇报内容

01	选题依据	研究来源、背景、目的及意义
02	国内外研究综述	错误溯源任务、已知困难、工具评价与研究不足
03	研究问题与方法	对象与理论、形成性研究、设计与评价
04	研究框架	研究阶段、产出与衔接
05	计划进度	2026.09—2028.05

1.1 研究来源：开发中的故障诊断

任务失败后，开发者需要把**最终症状**与分散的**运行记录**联系起来，判断问题发生在哪一步。

- 01

看到失败


错误回答或执行中断
- 02

查阅记录

模型请求、工具调用、状态变化
- 03

解释原因


说明可疑事件如何影响结果




Hutter 与 Pradel, 2026, AgentStepper, Fig. 1。已有开发工具示例，展示开发者与运行事件、模型和工具的关系。

1.2 研究背景：失败涉及多个环节


工具调用型智能体交替进行模型请求、外部工具调用和状态更新。最终症状可能来自前面多个运行环节。



MAST, Fig. 1: 原研究的多智能体任务结果；数值不代表本课题单个主要智能体的失败率。



MAST, Fig. 2: 故障可涉及规格、协同和验证；仅作相关故障范围参照。



ReAct 作者项目图：推理、行动和环境观察交替，提示需要跨步骤回查。

[2] YAO S, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//ICLR. 2023.
[3] CEMRI M, et al. Why Do Multi-Agent LLM Systems Fail?[C]//NeurIPS. 2025.

1.3 研究目的及意义

识别现有工具下的错误溯源困难，选择一项关键困难提出交互设计，并检验其能否改善有依据的原因判断。



理论意义


补充自然语言记录、概率性输出和外部工具混合情境下的开发者诊断经验；形成有适用条件的设计原则。

实践意义

形成可复现案例、研究原型与评分材料，为调试界面的信息组织和检查操作提供依据。

2.1.1 从任务失败回查运行过程

ReAct 展示了推理、行动和环境观察交替发生的任务过程。最终症状可能由多个运行步骤共同造成。



Yao 等, ReAct 作者项目页方法示意 (无论文图号)

分析起点

任务目标与失败表现

回查对象

模型输出、工具交互与状态传递

诊断结果

说明可疑步骤与失败的联系

2.1.2 运行记录与自动归因提供的基础


运行追踪

跨组件标识、事件采集和查询使部分运行事实可以关联。

自动归因

责任主体、可疑步骤或框架缺陷定位可以提供检查线索。

交互设计仍需回答：开发者怎样理解这些记录，并核验原因解释？




Zheng 等，2025，AgentSight，Fig. 1。图示跨层观测范围，不代表自动归因效果。

[5] FONSECA R, et al. X-Trace: A Pervasive Network Tracing Framework[C]//NSDI. 2007: 271–284.
[6] ZHENG Y, et al. AgentSight: System-Level Observability for AI Agents Using eBPF[EB/OL]. arXiv:2508.02736, 2025.
[7] CHEN M, et al. From Failed Trajectories to Reliable LLM Agents: Diagnosing and Repairing Harness Flaws[EB/OL]. arXiv:2606.06324, 2026.

2.2.1 长轨迹检查与原因判断

开发者既要识别错误，也要决定检查或修改哪里。交互操作可用时，运行理解仍可能耗时。



Epperson 等, 2025, AGDebugger, Fig. 2: 识别错误与尝试修复的循环。

阅读负担

长对话需要逐条检查

上下文理解

理解步骤之间的信息使用


效果判断

修改后仍需核验新运行


2.2 开发者错误溯源中的已知困难

2.2.2 信息查找与系统理解

Whyline 的两幅原图展示了从异常输出提问、再回到相关执行事件的入口与路径。



Ko 与 Myers, 2009, Whyline, Fig. 1: 从可见输出提出问题。



Ko 与 Myers, 2009, Whyline, Fig. 2: 回查相关执行事件。


程序调试研究说明信息线索与导航成本会影响理解；工具调用型智能体中，哪些材料关系最难判断仍需在目标人群中观察。

[9] KO A J, MYERS B A. Finding Causes of Program Output with the Java Whyline[C]//CHI. 2009: 1569—1578.


[10] LAWRENCE J, et al. How Programmers Debug, Revisited: An Information Foraging Theory Perspective[J]. IEEE TSE, 2013, 39(2): 197—215.

2.3 现有交互工具的能力与评价


2.3.1 浏览、复盘与比较



AgentLens：层级轨迹与行为分析。Lu 等，作者页面图片。



AAR/AI：预期、实际行为与原因复盘。Khanna 等，2022, Fig. 17。




ChainForge：提示、模型与输出比较。Arawjo 等，2024, Fig. 1。

研究任务分别是社会模拟行为分析、游戏故障发现与提示输出探索；效果证据不能直接等同于工具调用型智能体的原因判断。

[11] LU J, et al. AgentLens: Visual Analysis for Agent Behaviors in LLM-Based Autonomous Systems[J]. IEEE TVCG, 2025, 31(8): 4182–4197.
[12] KHANNA R, et al. Finding AI’s Faults with AAR/AI: An Empirical Study[J]. ACM TiIS, 2022, 12(1): 1–33.
[13] ARAWJO I, et al. ChainForge: A Visual Toolkit for Prompt Engineering and LLM Hypothesis Testing[C]//CHI. 2024.

2.3 现有交互工具的能力与评价

2.3.2 轨迹组织与逐步调试




Graph of Trace：对话、轨迹图与节点详情。Gao 等，2026，Fig. 2。

系统能力

事件关联、逐步检查与原始记录访问

已有评价

专家反馈或特定缺陷定位任务



AgentStepper：运行记录、活动与代码状态联合检查。Hutter 与 Pradel，2026，Fig. 2。

仍需检验


目标情境下的原因判断与依据质量

[14] GAO T, et al. Graph of Trace: Visualizing Execution Traces of Scientific Agents[C]//ACL System Demonstrations. 2026: 297–306.
[1] HUTTER R, PRADEL M. AgentStepper: Interactive Debugging of Software Development Agents[EB/OL]. arXiv:2602.06593, 2026.

2.4 研究不足与本课题切入点

2.4.1 已有研究尚需回答的问题

AgentStepper 在原研究的缺陷定位任务中报告改善；整体工具同时提供结构化轨迹、事件摘要和中间代码变更。



Hutter 与 Pradel, 2026, AgentStepper, Fig. 4。图中数值属于原研究参与者与任务，不是本课题结果。

尚需明确的困难

哪些已有能力下的判断障碍在目标场景仍持续出现？

尚需明确的设计作用

一项具体交互改变如何影响原因判断及其证据使用？

2.4 研究不足与本课题切入点

2.4.2 区分诊断障碍，确定设计问题

事实未被记录


关键运行事实缺失

材料难以访问或关联

已有记录的入口或关系不清

材料已取得但难以解释

难以区分多个原因假设




Wu 等，2026，AgentGraph，Fig. 1B：关系图联到原始轨迹。该图是已有工具示例，三类障碍仍须由本研究确认。

选择核心困难时考察出现范围、诊断后果、材料可获得性、设计可介入性和实验可检验性。

[15] WU Z, et al. AgentGraph: Trace-to-Graph Platform for Interactive Analysis and Robustness Testing in Agentic AI Systems[C]//AAAI. 2026: 41721–41723.

3.1 研究问题



主要结果是有依据的原因判断；完成时间与使用体验用于解释结果。


3.2 诊断任务：案例、证据与评分

一次任务从失败结果开始；每个案例区分**实际故障**与**参与者可见材料**，避免只按原因名称评分。




上图为教学示意，2024 / 2023 的年份差异不是正式实验案例；正式案例须经专家核查和预实验。

3.3 理论基础：信息觅食与意义建构




找到线索：从异常输出发问并进入执行记录。Whyline, Fig. 1。



组织材料：沿事件关系回到原始轨迹。AgentGraph, Fig. 1B；界面示例并非理论模型原图。


本研究分析路径



访谈与观察中编码材料访问、搜索线索、原因假设、检查行动和判断变化；开放编码保留理论未解释的资料。

[10] LAWRENCE J, et al. How Programmers Debug, Revisited: An Information Foraging Theory Perspective[J]. IEEE TSE, 2013, 39(2): 197–215.
[16] PIROLI P, CARD S K. The Sensemaking Process and Leverage Points for Analyst Technology as Identified Through Cognitive Task Analysis[C]//International Conference on Intelligence Analysis. 2005.
[17] KLEIN G, MOON B, HOFFMAN R R. Making Sense of Sensemaking 2: A Macrocognitive Model[J]. IEEE Intelligent Systems, 2006, 21(5): 88–92.

3.4 研究方法总览



4 研究框架：从困难识别到效果验证


RQ1 发现问题：形成性研究




RQ2 提出设计：围绕一项关键困难



RQ3 验证方案：对照评价与新案例检验



5 研究计划：2026.09—2028.05





硕士学位论文开题答辩

感谢聆听！

华中科技大学 | 设计学院 | 设计学

答辩人：陈思静

学号：M20270493

导师：何心

日期：2026/09/24