



華中科技大學
Huazhong University of Science and Technology

面向信任校准的AI辅助决策交互设计研究

Research on AI-Assisted Decision-making Interaction Design for Trust Calibration

答辩人：朱静文

指导教师：何心



华中科技大学
Huazhong University of Science and Technology

目录Content

01 选题背景与意义-绪论

03 研究方法 with 思路

02 研究现状-文献综述

04 研究条件 with 研究计划

01 选题背景与意义

研究背景

研究问题概述

研究意义



华中科技大学
Huazhong University of Science and Technology

问题背景 “AI辅助决策+高风险场景的高速发展”

ai+医疗

ai+工业

ai+航空航天

...

腾讯觅影 · AI 胃镜筛查：0.01 秒识别癌前病变影像，诊断准确率超 90%，筛查效率提升 4 倍以上。

华为盘古大模型 · 智慧煤矿：融合多源传感数据实现顶板压力预测、刀具磨损监测等，井下人员减少 20% - 30%，掘进效率提升约 18%，事故率下降超 25%。



NASA 的毅力号火星车：采用 AI 技术实现了火星车的自主导航与避障，更好完成了火星表面的探测任务。

...

提高决策效率


提升安全性与风险管控能力

...




问题背景 “AI辅助决策+高风险场景的发展困境”

黑箱与脱离回路问题



黑箱模型：深度学习模型决策逻辑不透明，造成人类对ai的信任不足。1次错误建议可能导致设备损坏甚至人员伤亡。



脱离环路：人类过度信任并依赖 AI 导致技能退化、情境意识下降，系统故障时无法及时接管。比如小米智驾事故的发生。

宏观治理原则 “落地难”

《人工智能安全治理框架》2.0 版

《人工智能全球治理行动计划》

微软《负责任AI标准》

谷歌《AI原则》


《OECD AI Principles overview》

《EU Artificial Intelligence Act》


...

研究问题的核心定位

黑箱与脱离回路问题：对AI的过度信任或信任不足，其本质是信任校准失衡，即人对AI系统的信任水平与系统实际可靠性不匹配，从而导致决策风险增加。




宏观治理原则落地难问题：其中的重要原因包括缺少“AI治理操作化的桥梁”，即对于设计师可复用的交互设计模式。



研究问题的核心定位

缺乏信任校准考量：一线工作人员不信任AI辅助决策系统，导致系统利用率低并且难以收集到反馈数据进行模型优化。

缺乏设计要素实证研究：多数研究聚焦于可解释性，脱离生产实际。在开发ai辅助决策系统时，缺少关键设计要素的实证研究。



核心问题：通过系统化的设计与评估，探索如何将信任校准因素纳入交互设计过程，并最终形成一系列可复用的设计模式，尝试构建更安全、更高效、更可信赖的AI辅助决策系统。

研究目标



研究意义

理论意义：通过在高风险场景下对特定交互设计原则的实证检验，将信任校准纳入交互设计研究，扩展人-AI交互设计理论。

实践意义：产出一套经过验证的、面向信任校准的交互设计模式，能够直接指导工业制造、能源、航空航天等关键领域的UX设计师、产品经理和系统工程师。


国内研究：实践导向，聚焦“场景应用”

核心成果：医疗（罕见病 AI 诊疗模型 PUMCH-GENESIS ）、工业（AI 监测实时预警 ）



国外研究：理论先行，聚焦“可解释性（XAI）”

里程碑：DARPA XAI 项目（2015 启动），开发 LIME 等解释技术，强调“解释要让用户理解”



国际研究趋势（数据来源：WoS）

国内研究：重应用、轻原创，底层创新不足

不足：

1. 基础理论 “跟跑”
2. 数据治理矛盾
3. 伦理规制滞后
4. 场景适配失衡

1. 误诊责任不明，仅 23% 患者知 AI 逻辑
2. 70% 医疗研究聚焦三甲影像，基层被忽视

国外研究：理论先行，聚焦 “可解释性 (XAI)”

不足：

1. 标准实践脱节
2. 公平性形式化
3. 治理碎片化
4. 协同单向度

1. 美国FDA 审批 18 个月，中小企业创新受阻
2. 司法系统 “公平检测” 存在算法偏见，仍致少数族裔保释率低


信任校准的“本质”是“恰当信任”

信任校准：引导用户信任水平与系统实际能力、可靠性相匹配的过程 / 状态。

- 过度信任：驾驶员完全依赖 AI 决策辅助，忽略系统误判导致车祸。



- 信任不足：医生拒绝使用 AI 给出的精准病灶识别建议。




信任校准的“操作化框架”

Merritt 等人提出三维度框架（实证研究的核心工具）：

感知准确性：某一时间点，用户对 AI 可靠性的感知是否接近实际值。

感知敏感性：AI 可靠性变化时，用户能否快速察觉。

信任敏感性：用户察觉可靠性变化后，能否调整信任。



MERRITT S M, LEE D, UNNERSTALL J L, et al. Are Well-Calibrated Users Effective Users? Associations Between Calibration of Trust and Performance on an Automation-Aided Task[J]. Human Factors, 2015, 57(1): 34-47.



信任校准的 “实现路径与理论模型”

双路径模型（实践导向）：Huang 和 Li 提出 “信任抑制 + 信任提升” 双策略

信任抑制：针对过度信任（如告知用户 AI 在 “复杂工况下误差率会升高”）

信任提升：针对信任不足（如展示 AI 过往 100 次决策的准确率数据）

模型类型	核心观点	代表研究
纵向视角模型	信任是长期演变的，引入 “关系资产”（情感资源）预测信任稳定性	de Visser et al. (2020)
计算模型	用 POMDPs、解析模型量化信任动态，实现系统自适应校准	Akash et al. (2020)
认知机制模型	只有 “有意义的拟人化”（如语音语调传递不确定性）能校准信任	Carter et al. (2024)

信任校准的 “关键影响因素”

系统因素：

透明度：动态置信度显示、错误归因

拟人化：表面拟人化无用，语音语调传递信息等有效

界面设计：警惕 “信任垃圾”（好看但无实质数据支撑的可视化）


用户因素：

初始信任：“信任型” 用户比 “多疑型” 用户更易过度依赖 AI

专业知识：领域专家更能识别 AI 错误，自身能力是 “天然校准工具”

情境因素：

高风险环境下，用户对信任的敏感度提升，需更精准的校准设计



信任校准的“关键影响因素”

策略：Huang 和 Li 提出 “信任校准策略”

(如告知用户 AI 在 “复杂” 任务中的准确率数据)

POP V L, SHREWSBURY A, DURSO F T. Individual Differences in the Calibration of Trust in Automation[J]. Human Factors, 2015, 57(4): 545-556.

信任校准的“关键影响因素”



系统因素：

透明度：动态置信度显示、错误归因

拟人化：表面拟人化无用，仅有语音语调等传递信息有效

界面设计：警惕 “信任垃圾” （好的可视化可能导致糟糕的信任校准）

用户因素：



认知机制模型

CARTER O B J, LOFT S, VISSER T A W. Meaningful Communication but not Superficial Anthropomorphism Facilitates Human-Automation Trust Calibration: The Human-Automation Trust Expectation Model (HATEM)[J]. Human Factors, 2024, 66(11): 2485-2502.

信任校准设计

WALL E, MATZEN L, EL-ASSADY M, et al. Trust Junk and Evil Knobs: Calibrating Trust in AI Visualization[C]//2024 IEEE 17th Pacific Visualization Conference, PACIFICVIS. Piscataway: IEEE Computer Soc, 2024: 22-31.

可复用的现有研究


信任校准的“三维度框架”

实现路径与理论模型

测量方法与干预策略

需整合的现有研究

关键影响因素



信任校准关键要素清单

文献回顾与核心洞见

1. 理论范式的演进

研究焦点已从追求静态的“高信任”，演变为管理动态的“信任校准”过程。

2. 设计策略的复杂性

存在“设计悖论”，之前的人机交互设计范式存在失效现象，需走向新的人-AI的交互设计范式。

3. 关键研究缺口

丰富的学术理论与可操作的工程实践之间存在鸿沟。

研究问题与解决路径

我们需要系统性地综合现有知识：

必须将文献中零散、有时相互矛盾的因素，转化为一套针对高风险工业场景的、连贯且可操作的设计原则。

需要在模拟情境中检验这些原则：

不能止步于理论推演，必须通过受控实验，严格测量这些整合性设计对用户信任、决策绩效及认知负荷的综合因果效应。

我们需要将成果转化为可复用的交互设计模式：

研究的最终目的，是**将经过实证检验的原则，提炼为一套结构化的交互设计模式，真正弥合理论与实践的鸿沟。**

I 研究内容

- 01 基于 PRISMA 2020 年版指南，对人机交互领域中与信任校准相关的实证研究进行系统性检索、筛选与分析，形成结构化的“信任校准关键要素清单”，为后续设计原则提炼提供循证基础。
- 02 采用改良德尔菲法，联合领域专家将文献梳理的信任校准要素转化为适用于高风险场景的可操作设计原则。
- 03 设计高保真原型，模拟高风险环境，通过受控实验实证检验设计原则对信任校准的因果效应。
- 04 对实验结果进行数据分析，将分析结果抽象得到设计原则，形成可复用的信任校准交互设计模式

研究方法

01

文献研究法：将严格遵循 PRISMA 2020 协议，围绕“高风险场景 AI 辅助决策信任校准”核心主题展开。形成结构化文献分析结果，为后续设计原则提炼与实证研究奠定循证基础。

02

案例分析法：搜集高风险场景下 AI 辅助决策系统的应用案例，重点聚焦国内外该领域信任校准相关的可解释界面设计实例。

03

归纳分析法：通过归纳分析法对人机交互领域信任校准相关文献进行归纳、演绎与分析，结合高风险场景 AI 辅助决策的风险刚性、人类主导等核心特点，归纳出面向信任校准的可解释 AI UI/UX 设计策略；为后续高风险场景下信任校准型 AI 辅助决策系统的设计实践提供参考与指导。


04

定性定量分析法：采用定性与定量分析结合的方法对设计调查结果进行分析。

05

改良德尔菲法：改良德尔菲法是优化后的结构化专家共识法，通过多轮匿名调研与反馈规避偏见、收敛意见。其适用于高风险 AI 辅助决策等场景，可将理论要素转化为落地方案。

研究框架



04 研究条件与计划


研究条件

研究计划



华中科技大学
Huazhong University of Science and Technology

研究团队 为协同设计奠定基础



用户研究与交互设计团队：
华中科技大学机械科学与工程学院
工业设计系老师团队



人工智能算法开发团队：
华中科技大学人工智能自动化
学院团队



工业制造企业合作资源：
中天科技集团

研究计划

阶段	核心任务	交付成果 / 里程碑
第一阶段：PRISMA系统性文献综述 (2025.10 - 2025.12)	先最终确定研究问题与综述方案，再执行数据库检索并完成文献去重，随后依次开展标题与摘要筛选、全文筛选及数据提取工作，最后通过综合分析撰写综述章节。	里程碑1： 系统性文献综述完成； 信任校准关键要素清单
第二阶段：德尔菲法研究 (2026.01 - 2026.03)	制定专家遴选标准并完成专家组招募，设计第一轮问卷并进行试行以优化内容，随后实施第一轮调研并开展主题分析梳理初步反馈，最后推进第二、三轮调研并通过共识分析达成专家对核心设计原则的一致意见。	里程碑2： 确定高共识度的核心设计原则
第三阶段：受控实验 (2026.04 - 2026.09)	先完成详细的实验设计并提交伦理审查申请以确保研究合规，再开展交互原型的开发与测试以搭建实验工具，随后通过预实验检验流程并针对性优化，最后正式招募实验参与者并完成所有数据的收集工作。	里程碑3： 完整实验数据集的收集与备份
第四阶段：数据分析与论文撰写 (2026.10 - 2027.05)	首先对实验数据进行清洗、处理与统计分析以验证设计原则效果，随后综合实验结果提炼并撰写信任校准交互设计模式，进而完成论文引言、方法、讨论等其余章节的撰写，最后开展论文修改、格式调整工作，为论文提交与答辩做好准备。	里程碑4： 学位论文撰写、修改与提交审查



華中科技大學
Huazhong University of Science and Technology

感谢聆听，请各位老师批评指正！

答辩人：朱静文
指导教师：何心

